SEP TECNOLÓGICO NACIONAL MÉXICO

INSTITUTO TECNOLÓGICO DE TIJUANA
DEPARTAMENTO DE INGENIERÍA EN SISTEMAS Y COMPUTACIÓN

INFORME TÉCNICO DE RESIDENCIA PROFESIONAL

“SISTEMA DE APOYO DIAGNÓSTICO PARA DETECCIÓN DE INFARTO AGUDO AL MIOCARDIO MEDIANTE REDES NEURONALES EN ELECTROCARDIOGRAMAS”

PRESENTA:
ALEJANDRO NARVÁEZ MATA
22210325
OCHOA MORÁN VÍCTOR ALEJANDRO
22210329

BAJO LA ASESORÍA:
INTERNA: MIGUEL ÁNGEL LÓPEZ RAMÍREZ
EXTERNA: GILBERTO QUIÑONEZ PALACIO

TIJUANA, B.C. AGOSTO/DICIEMBRE 2026

Agradecimientos

Queremos agradecer a nuestras familias por brindarnos el apoyo durante toda nuestra etapa escolar; gracias a ello concluimos esta etapa, muy importante en nuestras vidas y en nuestra formación.

De igual manera, queremos agradecer a nuestro profesor, el Dr. Miguel Ángel López Ramírez, por darnos la oportunidad y la confianza de llevar este proyecto de la mano con él.

Asimismo, agradecemos al Dr. Gilberto Quiñonez Palacio por su guía y sabiduría al realizar el proyecto en conjunto con nosotros.

Finalmente, agradecemos al Instituto Tecnológico de Tijuana por habernos dado la oportunidad de realizar nuestra residencia profesional, donde aplicamos todo el conocimiento adquirido en la institución a lo largo de estos años.

Muchas gracias a todos.

Resumen

Las enfermedades del corazón son la principal causa de muerte en el mundo y el infarto agudo al miocardio (IAM) es una de sus formas más graves. Para sospechar un infarto, la prueba más rápida y barata es el electrocardiograma (ECG) de 12 derivaciones, pero leerlo bien requiere experiencia, y esa experiencia no siempre está disponible en el primer lugar al que llega un paciente. Este informe describe CardiologIA, un sistema de apoyo que recibe un electrocardiograma y estima la probabilidad de que muestre un patrón compatible con infarto, además de señalar en qué partes del trazo se apoyó para decidirlo.

El corazón del sistema es una red neuronal residual unidimensional (ResNet1D) de 8.7 millones de parámetros, entrenada con PTB-XL, un conjunto público de 21 799 electrocardiogramas de 18 869 pacientes revisados por cardiólogos. Antes de entrar a la red, cada señal se limpia con un filtro de 0.5 a 40 Hz, se normaliza y se ajusta a 10 segundos a 100 muestras por segundo. El umbral de decisión se eligió en un grupo de validación para detectar al menos 85 de cada 100 infartos y después se aplicó, sin tocarlo, a un grupo de prueba de 2 198 electrocardiogramas de pacientes que la red nunca vio.

En ese grupo de prueba el modelo detectó 84 de cada 100 infartos (sensibilidad 0.840, intervalo de confianza del 95 %: 0.808–0.871), descartó correctamente 84 de cada 100 registros sin infarto (especificidad 0.843) y obtuvo un área bajo la curva ROC de 0.925, cifra comparable con los mejores modelos publicados para PTB-XL. Como en la práctica muchos

electrocardiogramas existen solo en papel, el sistema también lee PDF, escaneos y fotografías de la hoja impresa: detecta la cuadrícula, recupera los trazos y los convierte en señal. Con una versión del modelo ajustada a ese formato, la sensibilidad es de 0.844 y la especificidad de 0.852 aun viendo solo una cuarta parte de cada derivación, y en 2 000 hojas simuladas el sistema recuperó la señal del 97.8 % al 99.8 % de los documentos, con sensibilidad de 0.91 a 0.93.

Para saber si el modelo funciona fuera de PTB-XL, lo probamos sin ningún reajuste en bases de otros países. En la base china de Shandong (25 770 electrocardiogramas) detectó el 96.5 % de los infartos con un área bajo la curva de 0.984, y en la base alemana de diagnóstico de PTB el 85.8 %, aunque marcó como sospechosos a más pacientes con otras enfermedades del corazón de lo deseable. Con 928 fotografías reales de hojas impresas en Pakistán, el modelo de hojas impresas detectó 90 de cada 100 infartos sin haber visto nunca una hoja real; después de ajustarlo con esas mismas fotografías, en una medición con hojas que cada modelo no había visto, detectó 93 de cada 100 con solo 4 falsas alarmas entre 284 trazos normales. Como ese ajuste empeoró el desempeño con hojas de otro estilo, la aplicación usa el modelo ajustado para fotografías JPG y el anterior para PDF y PNG. La tendencia a dar falsas alarmas en pacientes con otras enfermedades del corazón es la principal limitación del sistema y se discute con detalle.

La aplicación web permite subir el archivo, ver el resultado con una escala de probabilidad, un nivel de certeza, un mapa Grad-CAM sobre el trazo, la relación de ese mapa con la onda Q, el segmento ST y la onda T, y un historial de análisis. CardiologIA es un prototipo académico de apoyo a la lectura del ECG: no sustituye al médico ni es un dispositivo médico certificado.

Palabras clave: infarto agudo al miocardio, electrocardiograma, aprendizaje profundo, ResNet1D, PTB-XL, Grad-CAM, digitalización de ECG impresos, validación externa.

Índice de contenido

Agradecimientos 2

Resumen 2

Glosario 15

Capítulo I. Introducción 18

1.1 Descripción de la institución 18

1.2 Objetivos 19

1.2.1 Objetivo general 19

1.2.2 Objetivos específicos 20

1.3 Justificación 20

1.4 Planteamiento del problema 21

1.5 Alcance 22

1.6 Limitaciones 23

1.7 Organización del documento 24

Capítulo II. Marco teórico 25

2.1 ECG de 12 derivaciones (ElectroCardioGrama) 25

2.1.1 El corazón como un sistema eléctrico 26

2.1.2 Las doce derivaciones 26

2.1.3 Las ondas de un latido 28

2.1.4 El papel del electrocardiograma y el formato 3 × 4 29

2.2 IAM (Infarto Agudo al Miocardio) 30

2.2.1 Las huellas del infarto en el electrocardiograma 31

2.3 Redes neuronales convolucionales profundas 32

2.3.1 Inteligencia artificial y aprendizaje automático 33

2.3.2 Redes neuronales 34

2.3.3 Convolución en una dimensión 36

2.4 Redes Residuales Profundas (ResNet) 37

2.4.1 Una forma sencilla de verlo 38
2.4.2 Redes residuales para el electrocardiograma: estado del arte 38
2.5 Data set PTB-XL 39
2.6 Del trazo a los números: señales digitales 40
2.6.1 Ruido y filtrado 40
2.6.2 Normalización 41
2.7 Explicabilidad: abrir la caja negra con Grad-CAM 41
2.8 ¿Cómo se mide si el sistema funciona? 42
2.8.1 La matriz de confusión 42
2.8.2 Sensibilidad, especificidad y valores predictivos 43
2.8.3 La curva ROC y el área bajo la curva 44
2.8.4 Elegir el punto de corte sin hacer trampa 44
2.8.5 Intervalos de confianza por bootstrap 45
2.9 Digitalización de electrocardiogramas impresos 45
2.10 Herramientas de software utilizadas 46
2.11 Consideraciones éticas 46
Capítulo III. Desarrollo y resultados 48
3.1 Análisis de requerimientos 48
3.1.1 Requerimientos funcionales 48
3.1.2 Requerimientos no funcionales 49
3.1.3 Usuarios del sistema 49
3.2 Metodología de desarrollo 49
3.2.1 Fases del proyecto 50
3.2.2 Cronología del desarrollo 50
3.2.3 Organización del trabajo 51
3.3 Arquitectura general del sistema 51
3.4 Preparación del conjunto de datos 52

3.4.1 PTB-XL en números 52
3.4.2 Calidad de la señal 54
3.4.3 Definición de la etiqueta 54
3.4.4 Partición por pacientes 54
3.4.5 Desbalance de clases 55
3.5 Preprocesamiento de la señal 55
3.6 Lectura de archivos y detección de la frecuencia de muestreo 56
3.6.1 ¿Por qué hace falta estimar la frecuencia? 56
3.6.2 La idea: solo una frecuencia da un corazón creíble 57
3.6.3 Evaluación del estimador 57
3.7 Diseño del modelo ResNet1D 58
3.8 Entrenamiento del modelo 60
3.8.1 Aumento de datos 60
3.8.2 Configuración 61
3.8.3 Desarrollo del entrenamiento 62
3.8.4 ¿Y si entrenamos más? Experimentos de continuación 62
3.9 Elección del punto de corte 63
3.10 Lectura de electrocardiogramas impresos 64
3.10.1 Supuestos del formato 65
3.10.2 Paso a paso 65
3.10.3 Un ejemplo completo 66
3.10.4 Hojas sintéticas para entrenar y evaluar 69
3.10.5 Un modelo ajustado al papel 69
3.10.6 Ajuste con hojas reales 70
3.10.7 Qué modelo usa la aplicación para cada documento 71
3.11 Explicabilidad 72
3.11.1 Implementación de Grad-CAM unidimensional 72

3.11.2 Relación con la onda Q, el segmento ST y la onda T 73
3.11.3 Cómo interpretar el mapa 73
3.12 Casos de uso 74
3.13 Servidor y API 78
3.14 Base de datos 79
3.15 Interfaz de usuario 79
3.15.1 Carga del archivo 80
3.15.2 Resultado 80
3.15.3 Desempeño y limitaciones 81
3.15.4 Explicación visual 82
3.15.5 La vista de la red neuronal 83
3.15.6 Demostración pública 84
3.16 Pruebas del sistema 84
3.17 Resultados con señales digitales 85
3.17.1 Métricas principales 85
3.17.2 Curvas ROC y de precisión 87
3.17.3 ¿Por qué no usar el corte de 0.5? 88
3.17.4 ¿Dónde se equivoca el modelo? 88
3.18 Resultados con electrocardiogramas impresos 90
3.18.1 Vista 3 × 4 de las señales de prueba 90
3.18.2 Digitalización de punta a punta 92
3.18.3 ¿Sirvió el ajuste con hojas digitalizadas? 93
3.18.4 Un caso que cambia de decisión 93
3.19 Validación externa 94
3.19.1 Señales digitales de otros países 94
3.19.2 Fotografías reales de hojas impresas 96
3.19.3 Qué tanto marca el sistema según el tipo de trazo 99

3.20 Cumplimiento de los objetivos 99
3.21 Comparación con la literatura 100
3.22 Discusión y limitaciones 101
3.23 Productos entregables 103
Capítulo IV. Conclusiones 105
4.1 Conclusiones generales 105
4.2 Respuesta a las preguntas de investigación 106
4.3 Competencias desarrolladas 107
4.4 Trabajo futuro 107
4.5 Lo que aprendimos en el camino 108
4.6 Recomendaciones 109
Referencias 110
Anexos 113
Anexo A. Manual de uso 113
A.1 Abrir la aplicación 113
A.2 Preparar el archivo 113
A.3 Analizar 113
A.4 Leer el resultado 114
A.5 Mensajes de error frecuentes 114
Anexo B. Guía de instalación 115
Anexo C. Reproducir los experimentos 116
Anexo D. Estructura del proyecto 116
Anexo E. Interfaz de programación (API) 117
Anexo F. Registro de decisiones técnicas 118
Anexo G. Resultados detallados de la digitalización 119

Índice de figuras

Figura 1. Organigrama del Instituto Tecnológico de Tijuana. 19

Figura 2. Electrodos colocados en el tórax para registrar el electrocardiograma. 25

Figura 3. Las doce derivaciones de un mismo electrocardiograma de PTB-XL. Cada fila es una "vista" distinta de la misma actividad eléctrica durante 10 segundos. 28

Figura 4. Un latido con sus ondas principales. Las bandas de color marcan las ventanas que el sistema usa para relacionar el mapa de explicabilidad con la onda Q, el segmento ST y la onda T. 29

Figura 5. Formato de impresión 3 × 4. Cada derivación se observa solo durante 2.5 segundos (zonas sombreadas); la tira de ritmo de la parte inferior muestra la derivación II completa. .. 30

Figura 6. Derivación II antes y después del filtrado de 0.5 a 40 Hz. La línea base deja de ondular y el trazo conserva la forma de las ondas. 41

Figura 7. Valor predictivo positivo y negativo en función de la prevalencia del infarto, con la sensibilidad (0.84) y especificidad (0.843) del modelo digital. 44

Figura 8. Recorrido de un electrocardiograma dentro del sistema, desde que se sube en el navegador hasta que se muestra el resultado. 52

Figura 9. Distribución de PTB-XL por superclase diagnóstica y por edad y sexo. 53

Figura 10. Aciertos del estimador de frecuencia de muestreo por frecuencia real y duración del registro (3 600 pruebas en el pliegue 10). 58

Figura 11. Estructura de la red ResNet1D: un tallo de entrada, cuatro etapas residuales y una cabeza de clasificación. 59

Figura 12. Ejemplo de aumento de datos sobre la derivación II: la señal original y una versión modificada con cambio de amplitud, ruido, deriva y desplazamiento. 61

Figura 13. Evolución de la pérdida y del AUC-ROC en entrenamiento y validación. La línea vertical marca la época 12, cuyo modelo se conservó. 62

Figura 14. Experimento de 100 épocas adicionales: el desempeño en entrenamiento sigue subiendo mientras el de validación cae. Es una ilustración clara del sobreajuste. 63

Figura 15. Distribución de las probabilidades que asigna el modelo en el grupo de prueba, separada por diagnóstico real. La línea marca el punto de corte de 0.3204. 64

Figura 16. Etapas del digitalizador de electrocardiogramas impresos. 65

Figura 17. Hoja impresa en formato 3 × 4 con tira de ritmo, generada a partir del electrocardiograma 63 de PTB-XL. 67

Figura 18. La misma hoja como si se hubiera fotografiado con un celular: perspectiva, iluminación irregular y fondo. 68

Figura 19. Comparación entre la señal original (gris) y la recuperada por el digitalizador a partir de la foto (rojo). Cada derivación solo se recupera en su cuarto de tiempo; la derivación II se recupera completa gracias a la tira de ritmo. 68

Figura 20. Mapa Grad-CAM sobre cuatro derivaciones del electrocardiograma 63 de PTB-XL (infarto anteroseptal). El rojo más intenso señala los momentos que más pesaron en la decisión. 73

Figura 21. Pantalla de inicio de CardiologIA con la descripción de la herramienta y el área de carga de archivos. 80

Figura 22. Resultado de un caso de ejemplo: veredicto, escala de probabilidad con el punto de corte, certeza y comparación con el diagnóstico de referencia. 81

Figura 23. Panel de desempeño y limitaciones del modelo, desplegado debajo del resultado. 82

Figura 24. Sección de explicabilidad: derivaciones del plano frontal con el mapa Grad-CAM de fondo y la curva de influencia. 82

Figura 25. Reparto de la activación por componente del latido, segmentos con mayor activación y tabla de análisis recientes. 83

Figura 26. Vista tridimensional de la red neuronal con los cinco casos de prueba disponibles y la leyenda de capas. 84

Figura 27. Matriz de confusión del modelo digital en el grupo de prueba con el corte de 0.3204. 86

Figura 28. Curva ROC del modelo digital en el grupo de prueba. El punto marca el corte de 0.3204. 87

Figura 29. Curva de precisión contra sensibilidad del modelo digital en el grupo de prueba. 88

Figura 30. Curva ROC del modelo de impresos (etapa 2) sobre la vista 3 × 4 de los electrocardiogramas de prueba. El punto marca el corte propio de esa vista (0.3347). 91

Figura 31. Sensibilidad y especificidad por tipo de documento, antes y después del ajuste del modelo con hojas digitalizadas. 93

Figura 32. Sensibilidad, especificidad y AUC-ROC en PTB-XL y en las bases externas. En Mendeley se muestran el modelo de la etapa 2 y el modelo ajustado con hojas reales, medido fuera de pliegue. 95

Figura 33. Entrada que recibe el modelo después de digitalizar una fotografía real del grupo de infarto de Mendeley. Cada derivación ocupa su cuarto de tiempo y la tira de ritmo (II) aparece completa. Los valores están normalizados. 96

Figura 34. Curva ROC fuera de pliegue del modelo ajustado con hojas reales (infarto frente a normal, 523 hojas). El punto marca el corte de 0.9494. 97

Figura 35. Porcentaje de electrocardiogramas marcados como infarto en cada grupo de las bases externas. En rojo, los grupos con infarto; en naranja, los grupos con hallazgos isquémicos; en azul, el resto. 99

Índice de tablas

Tabla 1. Relación aproximada entre derivaciones con cambios, región del corazón y arteria implicada. 31

Tabla 2. Trabajos de referencia sobre aprendizaje profundo aplicado al electrocardiograma. 39

Tabla 3. Los cuatro resultados posibles de una prueba diagnóstica. 42

Tabla 4. Herramientas de software del proyecto. 46

Tabla 5. Requerimientos funcionales del sistema. 48

Tabla 6. Requerimientos no funcionales del sistema. 49

Tabla 7. Fases del proyecto y actividades principales. 50

Tabla 8. Hitos del desarrollo según el historial del repositorio. 50

Tabla 9. Características generales de PTB-XL versión 1.0.3. 52

Tabla 10. Registros de PTB-XL por superclase diagnóstica (un registro puede tener varias). 53

Tabla 11. Subtipos de infarto más frecuentes en PTB-XL. 53

Tabla 12. Problemas de calidad anotados en PTB-XL. 54

Tabla 13. Partición de PTB-XL utilizada en el proyecto. 55

Tabla 14. Formatos de entrada aceptados por el sistema. 56

Tabla 15. Porcentaje de aciertos del estimador de frecuencia según la frecuencia real y la duración del registro. 57

Tabla 16. Configuración de la ResNet1D estándar. 59

Tabla 17. Configuración del entrenamiento del modelo digital. 61

Tabla 18. Comparación del modelo adoptado con los experimentos de continuación. 63

Tabla 19. Tipos de documento simulados para entrenar y evaluar la lectura de hojas impresas. 69

Tabla 20. Resultado del ajuste con hojas reales en cada pliegue de la validación cruzada. 71

Tabla 21. Modelos utilizados por la aplicación según el tipo de entrada. 71

Tabla 22. Resumen de los casos de uso del sistema. 74

Tabla 23. Caso de uso CU-01: analizar un electrocardiograma digital. 74

Tabla 24. Caso de uso CU-02: analizar un electrocardiograma impreso. 75

Tabla 25. Caso de uso CU-03: forzar la frecuencia de muestreo. 75

Tabla 26. Caso de uso CU-04: ver un caso de ejemplo. 75

Tabla 27. Caso de uso CU-05: interpretar la explicación visual. 76

Tabla 28. Caso de uso CU-06: consultar el desempeño y las limitaciones. 76

Tabla 29. Caso de uso CU-07: consultar el historial de análisis. 76

Tabla 30. Caso de uso CU-08: explorar la vista de la red neuronal. 77

Tabla 31. Caso de uso CU-09: preparar los datos y entrenar el modelo. 77

Tabla 32. Caso de uso CU-10: evaluar el modelo y validar en bases externas. 77

Tabla 33. Rutas de la API. 78

Tabla 34. Campos principales de la respuesta del análisis. 78

Tabla 35. Estructura de la tabla registros_analisis. 79

Tabla 36. Pruebas funcionales del sistema. 84

Tabla 37. Resultados del modelo digital en el grupo de prueba (pliegue 10, 2 198 electrocardiogramas). 86

Tabla 38. Sensibilidad del modelo digital por tipo de infarto (un trazo puede tener más de un tipo). 89

Tabla 39. Especificidad del modelo digital según el diagnóstico de los trazos sin infarto. 89

Tabla 40. Desempeño del modelo digital por sexo y por grupo de edad. 90

Tabla 41. Desempeño en la vista 3 × 4 de los 2 198 electrocardiogramas de prueba. 90

Tabla 42. Calidad de la digitalización por tipo de documento (500 hojas de cada tipo). 92

Tabla 43. Desempeño de punta a punta del modelo de la etapa 2 (corte 0.3623) por tipo de documento. 92

Tabla 44. Bases de datos usadas en la validación externa. 94

Tabla 45. Desempeño del modelo digital (corte 0.3204) en bases externas. 94

Tabla 46. Desempeño en las hojas reales de Mendeley: infarto (239) frente a normal (284). 97

Tabla 47. Porcentaje de hojas de Mendeley marcadas como infarto, por grupo. 98

Tabla 48. Cumplimiento de los objetivos específicos del anteproyecto. 99

Tabla 49. Comparación con trabajos de referencia. 100

Tabla 50. Productos entregables del proyecto. 103

Tabla 51. Mensajes de error frecuentes y qué hacer. 114

Tabla 52. Variables de configuración principales. 115

Tabla 53. Scripts para reproducir los experimentos. 116

Tabla 54. Rutas de la API. 117

Tabla 55. Campos de la respuesta del análisis. 117

Tabla 56. Decisiones técnicas principales y su justificación. 118

Tabla 57. Conteos por tipo de documento con el modelo de la etapa 2 (corte 0.3623) y el de la etapa 1 (corte 0.4303). 119

Glosario

Este glosario reúne las siglas y los términos que aparecen a lo largo del informe. Las definiciones están escritas pensando en un lector que no es especialista ni en cardiología ni en inteligencia artificial, y describen el sentido con el que usamos cada palabra en este proyecto.

Aprendizaje profundo. Rama de la inteligencia artificial que usa redes neuronales con muchas capas. En lugar de programar reglas a mano, la red aprende a partir de ejemplos cuáles patrones distinguen un caso de otro.

API. Interfaz de programación de aplicaciones. Es la "ventanilla" por la que la página web le pide al servidor que analice un archivo y por la que el servidor devuelve el resultado.

AUC-ROC. Área bajo la curva ROC. Es un número entre 0.5 y 1 que resume qué tan bien separa el modelo los casos con infarto de los casos sin infarto, sin depender de un umbral. Un valor de 0.5 equivale a lanzar una moneda; un valor de 1 sería una separación perfecta.

Aumento de datos. Técnica de entrenamiento que crea versiones ligeramente modificadas de cada electrocardiograma (con un poco de ruido, más o menos amplitud o un pequeño desplazamiento) para que la red aprenda lo esencial y no memorice detalles.

Bootstrap. Método estadístico que repite muchas veces el cálculo de una métrica sobre muestras tomadas al azar del conjunto de prueba. Sirve para estimar el intervalo de confianza de esa métrica.

Certeza. En la interfaz, indica qué tan lejos quedó la probabilidad del punto de corte. Lejos del corte la certeza es alta; muy cerca, es baja.

CNN. Red neuronal convolucional. Tipo de red que analiza los datos con pequeños filtros que se deslizan sobre la señal, de forma parecida a como uno recorre un trazo con la vista buscando formas conocidas.

Derivación. Cada una de las doce "vistas" eléctricas del corazón que entrega un electrocardiograma (I, II, III, aVR, aVL, aVF y V1 a V6).

Digitalización. Proceso de convertir la imagen de un electrocardiograma impreso en una señal numérica, es decir, en una lista de valores de voltaje a lo largo del tiempo.

ECG. Electrocardiograma. Registro de la actividad eléctrica del corazón tomado con electrodos sobre la piel.

Época. Una vuelta completa de la red por todos los ejemplos de entrenamiento.

Especificidad. De cada 100 personas sin infarto, cuántas reconoce el modelo como "sin infarto". Una especificidad baja significa muchas falsas alarmas.

F1. Medida que combina en un solo número la sensibilidad y la precisión (qué proporción de las alarmas eran infartos reales).

FastAPI. Herramienta de Python con la que construimos el servidor del sistema.

Filtro pasa-banda. Filtro que deja pasar solo las frecuencias dentro de un rango (aquí de 0.5 a 40 Hz) y elimina las que quedan fuera, como la deriva lenta de la línea base o el ruido eléctrico rápido.

Frecuencia de muestreo. Número de valores por segundo con que un equipo guarda la señal. Se mide en hercios (Hz). Un ECG a 500 Hz guarda 500 valores por segundo de cada derivación.

Grad-CAM. Técnica de explicabilidad que, a partir de los gradientes de la red, construye un mapa que indica en qué momentos del trazo se apoyó más el modelo para su decisión.

Hiperparámetro. Ajuste que se elige antes de entrenar (por ejemplo, la tasa de aprendizaje o el tamaño de lote) y que no aprende la red por sí misma.

IAM. Infarto agudo al miocardio. Muerte de una parte del músculo del corazón porque una arteria coronaria se tapa y deja de llevarle sangre.

Intervalo de confianza (IC 95 %). Rango de valores dentro del cual esperamos que esté el valor real de una métrica con un 95 % de confianza. Cuanto más angosto, más precisa la estimación.

Pliegue (fold). Cada una de las diez partes en que los autores de PTB-XL dividieron el conjunto. Los pacientes de un pliegue no aparecen en otro.

PTB-XL. Conjunto público de electrocardiogramas de 12 derivaciones de 10 segundos, publicado en PhysioNet, con diagnósticos asignados por cardiólogos. Es la base principal del proyecto.

PyTorch. Biblioteca de Python para construir y entrenar redes neuronales.

ResNet / ResNet1D. Red residual. Arquitectura en la que cada bloque suma su entrada a su salida mediante un "atajo", lo que permite entrenar redes profundas. La versión 1D trabaja sobre señales en el tiempo en lugar de imágenes.

Sensibilidad. De cada 100 personas con infarto, cuántas detecta el modelo. Una sensibilidad baja significa infartos que pasan sin ser detectados.

Sobreajuste. Situación en la que la red memoriza los ejemplos de entrenamiento y empeora con casos nuevos. Es como un alumno que se aprende las respuestas del examen de práctica sin entender el tema.

SQLite. Base de datos ligera guardada en un solo archivo, donde el sistema registra el historial de análisis.

Umbral o punto de corte. Probabilidad a partir de la cual el sistema dice "compatible con IAM". En este proyecto no es 50 %, sino 32 % para señales digitales, 36 % para PDF e imágenes PNG y 95 % para fotografías de hojas reales; cada uno se eligió en datos de validación para detectar al menos 85 de cada 100 infartos.

Validación externa. Prueba del modelo con datos de hospitales y países distintos a los que se usaron para entrenarlo, sin reajustar nada.

VPP y VPN. Valor predictivo positivo y negativo. El VPP responde "si el sistema dice infarto, ¿qué tan probable es que lo sea?"; el VPN responde "si dice que no, ¿qué tan probable es que de verdad no lo sea?". Ambos dependen de qué tan frecuente es el infarto en la población.

WFDB. Formato de archivos de PhysioNet para señales fisiológicas. Un registro lleva un archivo de cabecera (.hea) con la descripción y un archivo de datos (.dat) con las muestras.

Capítulo I. Introducción

1.1 Descripción de la institución

La institución en donde se realiza el presente proyecto de residencia profesional es el Tecnológico Nacional de México, campus Instituto Tecnológico de Tijuana, unidad Tomás Aquino, perteneciente al Sistema Nacional de Institutos Tecnológicos.

MISIÓN

Contribuir a la formación integral de profesionistas e investigadores líderes en la innovación y el desarrollo tecnológico de la región, del país y del mundo; con alto sentido de responsabilidad social, a través de un servicio educativo de calidad, con equidad y pertinencia.

VISIÓN

Ser una institución rectora de la educación superior tecnológica, la investigación científica y el desarrollo tecnológico en la Región Noroeste del País, con proyección a nivel nacional e internacional.

Todo este proyecto se realiza en el Departamento de Ingeniería en Sistemas y Computación, que da seguimiento académico a las residencias de los estudiantes de Ingeniería en Sistemas Computacionales. La residencia es de corte interno: no se realizó dentro de una empresa, sino en el propio instituto, bajo la asesoría interna del Dr. Miguel Ángel López Ramírez y la asesoría externa del Dr. Gilberto Quiñonez Palacio. Esta modalidad permitió trabajar un problema de investigación aplicada con libertad para probar distintas soluciones, medir cada una y quedarnos con la que mejor responde a la pregunta planteada.

Organigrama: Instituto Tecnológico de Tijuana



Figura 1. *Organigrama del Instituto Tecnológico de Tijuana.*

La unidad Tomás Aquino se encuentra en Calzada del Tecnológico 12950, colonia Tomás Aquino, C.P. 22414, Tijuana, Baja California. Ahí se llevaron a cabo las reuniones de seguimiento con los asesores y las presentaciones de avance.

1.2 Objetivos

Los objetivos se plantearon en el anteproyecto aprobado al inicio de la residencia. Los conservamos tal cual para poder compararlos al final con lo que realmente se logró; en el Capítulo III se revisa uno por uno.

1.2.1 Objetivo general

Desarrollar un sistema de software de apoyo diagnóstico que, mediante el uso de redes neuronales convolucionales profundas entrenadas sobre el dataset PTB-XL, sea capaz de analizar electrocardiogramas de 12 derivaciones y clasificar, con un desempeño clínicamente aceptable en sensibilidad y especificidad, la presencia o ausencia de Infarto Agudo al Miocardio, proporcionando al usuario una visualización interpretable de las regiones de la señal que motivaron el diagnóstico.

1.2.2 Objetivos específicos

- Preparar el dataset PTB-XL mediante filtrado (0.5–40 Hz), normalización y segmentación, garantizando un mínimo del 90 % de registros utilizables para el entrenamiento.
- Implementar y entrenar una ResNet 1D en PyTorch ajustando parámetros para alcanzar una sensibilidad y especificidad ≥ 85 % en la clasificación de IAM.
- Evaluar el modelo utilizando como métricas de validación la sensibilidad (proporción de casos de IAM correctamente detectados), la especificidad (proporción de casos sin IAM correctamente descartados), el F1-Score (balance entre precisión y exhaustividad) y el AUC-ROC (capacidad global de discriminación del modelo), comparando los resultados con los de Ribeiro et al. (2020) como línea base.
- Implementar Grad-CAM 1D para identificar regiones del ECG asociadas a los hallazgos del IAM: onda Q patológica, supradesnivel ST e inversión de onda T.
- Desarrollar una interfaz web que permita cargar un ECG, ejecutar la clasificación y visualizar el diagnóstico, la señal resaltada y el nivel de confianza.

Durante el desarrollo agregamos tres metas que no estaban en el anteproyecto, pero que resultaron necesarias para que el sistema fuera útil fuera del laboratorio: leer electrocardiogramas impresos (PDF, escaneo o fotografía), detectar automáticamente la frecuencia de muestreo de los archivos digitales y probar el modelo en bases de datos de otros países.

1.3 Justificación

Las enfermedades cardiovasculares son la principal causa de muerte a nivel mundial, y el IAM es uno de los eventos más letales cuando no se detecta a tiempo; en México, además, el tiempo que transcurre entre el inicio de los síntomas y el tratamiento suele ser largo. El ECG de 12 derivaciones es la herramienta más accesible para detectarlo, pero su interpretación requiere entrenamiento especializado que no siempre está disponible. Por ello, se propone un sistema de IA que apoye esta interpretación de forma objetiva y rápida, ayudando al personal médico de primer y segundo nivel y, de forma indirecta, a los pacientes con sintomatología cardiovascular. Su utilidad es doble: académica, al integrar procesamiento de señales, deep learning y desarrollo de software; y práctica, como prototipo comprobable con el estado del arte (dataset PTB-XL), con miras a una futura validación clínica.

Según la Organización Mundial de la Salud, la cardiopatía isquémica, que incluye al infarto, es la principal causa de muerte en el mundo (OMS, 2021), y en México las enfermedades del

corazón ocupan también el primer lugar entre las causas de defunción que reporta el INEGI. Las guías internacionales recomiendan tomar e interpretar un electrocardiograma en los primeros diez minutos desde que el paciente llega con síntomas (Ibanez et al., 2018; Byrne et al., 2023), porque cada minuto sin tratamiento significa más músculo perdido.

En los últimos años varios grupos de investigación demostraron que las redes neuronales profundas pueden leer electrocardiogramas con un desempeño cercano al de un especialista (Hannun et al., 2019; Ribeiro et al., 2020). Sin embargo, esos sistemas suelen quedarse en artículos científicos o en productos comerciales cerrados. Nuestro proyecto busca llevar ese conocimiento a una herramienta abierta, que cualquier persona pueda revisar, ejecutar en una computadora común y probar con sus propios archivos, incluidos los electrocardiogramas que solo existen en papel.

El proyecto también se justifica por la forma en que se evalúa. No basta con decir que un modelo "acierta el 90 %". Un sistema de apoyo en salud debe decir cuántos infartos deja pasar, cuántas falsas alarmas genera, cuánta incertidumbre hay en esas cifras y cómo se comporta con pacientes de otros lugares. Este informe dedica buena parte de su extensión a esas preguntas, porque son las que importan a quien tendría que confiar en la herramienta.

Beneficiarios

- **Médicos generales y personal de primer contacto**, que podrían usar el sistema como una segunda lectura cuando no hay un cardiólogo disponible.
- **Estudiantes de medicina**, que pueden comparar su propia lectura del trazo con la del sistema y observar en qué zonas se fijó.
- **Cardiólogos**, como herramienta de priorización cuando reciben muchos estudios a la vez.
- **Pacientes**, de forma indirecta, si la herramienta ayuda a que un infarto se reconozca unos minutos antes.
- **La comunidad académica del ITT**, que cuenta con un sistema documentado y reproducible sobre el cual se pueden construir trabajos futuros.

1.4 Planteamiento del problema

Cuando una persona llega a urgencias con dolor en el pecho, una de las primeras cosas que se hacen es tomarle un electrocardiograma. En unos minutos, diez electrodos registran la actividad eléctrica del corazón y la imprimen en una hoja cuadriculada. Esa hoja puede decir mucho: si el ritmo es normal, si hay un bloqueo en la conducción o si una parte del corazón

está sufriendo por falta de sangre. Pero para que diga algo, alguien tiene que saber leerla, y leerla bien lleva años de práctica.

Los cambios que produce un infarto pueden ser evidentes, como una gran elevación del segmento ST, o sutiles, como una onda Q apenas más ancha de lo normal o una onda T que se invierte en pocas derivaciones. Un cardiólogo con experiencia los reconoce con relativa facilidad; un médico general en un turno nocturno, con varios pacientes a la vez, puede pasarlos por alto. Y en muchos centros de primer contacto no hay cardiólogo.

A esto se suma una dificultad práctica que descubrimos durante el desarrollo: la mayoría de los electrocardiogramas no se guardan como archivo digital, sino como una hoja impresa o un PDF que genera el propio equipo. Muchas herramientas de investigación solo aceptan la señal numérica, lo que las vuelve inútiles para quien tiene en la mano una hoja de papel o una foto en su celular.

El problema que atendimos puede resumirse así: **hace falta una herramienta de apoyo que, a partir de un electrocardiograma de 12 derivaciones, ya sea como archivo digital o como hoja impresa, estime de forma rápida y explicable la probabilidad de un patrón compatible con infarto, y que comunique con claridad cuánto se puede confiar en ese resultado.**

Preguntas que guiaron el trabajo

- ¿Puede una red neuronal entrenada con datos públicos alcanzar una sensibilidad y una especificidad de al menos 85 % para distinguir electrocardiogramas con infarto de los que no lo tienen?
- ¿Se puede mostrar al usuario en qué parte del trazo se apoyó la red, de modo que la decisión no sea una “caja negra”?
- ¿Se puede recuperar la señal a partir de una hoja impresa, un escaneo o una foto sin perder demasiada información?
- ¿Qué tan bien se comporta el modelo con electrocardiogramas de otros hospitales y otros países, que nunca vio durante su entrenamiento?
- ¿Cómo presentar el resultado a un profesional de la salud de forma que entienda tanto la respuesta como sus límites?

1.5 Alcance

El proyecto entrega un prototipo funcional completo. Eso incluye:

- La preparación de los datos de PTB-XL: lectura, filtrado, normalización, partición por pacientes y etiquetado binario de infarto.
- El diseño, el entrenamiento y la evaluación de una red ResNet1D, junto con experimentos de entrenamiento que documentan por qué se eligió la versión final.
- Un procedimiento para elegir el punto de corte de forma objetiva y la estimación de intervalos de confianza de todas las métricas.
- La explicación visual de cada resultado con Grad-CAM y su relación aproximada con la onda Q, el segmento ST y la onda T.
- La lectura de archivos digitales en varios formatos con detección automática de la frecuencia de muestreo.
- La digitalización de electrocardiogramas impresos en formato 3 × 4 a partir de PDF, escaneos o fotografías, y modelos ajustados a ese tipo de entrada.
- La validación externa en cuatro bases de datos de China, Alemania, Estados Unidos y Pakistán.
- Un servidor web, una base de datos de historial y una interfaz gráfica para profesionales de la salud, además de una demostración pública en GitHub Pages.

1.6 Limitaciones

Es igual de importante decir lo que el proyecto no hace. Lo resumimos aquí y lo retomamos con más detalle al final del Capítulo III.

- **No es un dispositivo médico.** No tiene certificación sanitaria ni se probó de forma prospectiva con pacientes de una unidad médica de Tijuana. Su uso es académico y demostrativo.
- **No distingue un infarto agudo de uno antiguo.** La etiqueta de PTB-XL que usamos para entrenar reúne ambos.
- **Solo responde una pregunta.** El sistema dice si el trazo es compatible o no con infarto. No diagnostica arritmias, bloqueos, hipertrofias ni otras enfermedades.
- **Un resultado negativo no descarta un infarto.** Alrededor de 16 de cada 100 infartos del grupo de prueba no fueron detectados por el modelo digital, y hay infartos que no producen cambios en el electrocardiograma.
- **Genera falsas alarmas**, sobre todo en pacientes con otras enfermedades del corazón.
- **El mapa de Grad-CAM es orientativo.** Indica dónde se fijó la red, no prueba que ahí exista una lesión.

- **La lectura de hojas impresas tiene condiciones.** Funciona con el formato 3 × 4 a 25 mm/s y 10 mm/mV; las fotografías tomadas en ángulo, con sombras fuertes o cortadas pueden digitalizarse mal.

1.7 Organización del documento

El **Capítulo II** reúne los conceptos necesarios para entender el proyecto: qué es un electrocardiograma, cómo se ve un infarto en él, cómo funcionan las redes neuronales y las residuales, qué contiene PTB-XL, cómo se miden los resultados y qué otros trabajos existen. Está escrito para que lo pueda seguir alguien sin formación médica ni de inteligencia artificial.

El **Capítulo III** es el núcleo del informe. Describe los requerimientos, la metodología de trabajo, la preparación de los datos, el diseño y el entrenamiento del modelo, la lectura de archivos y de hojas impresas, la explicabilidad, los casos de uso, la arquitectura del software y la interfaz. Después presenta todos los resultados y los compara con los objetivos y con la literatura. Termina con las limitaciones y los productos entregables.

El **Capítulo IV** recoge las conclusiones, las competencias desarrolladas y las líneas de trabajo futuro. Al final se encuentran las **referencias** y los **anexos**, con un manual de uso, una guía de instalación, la estructura del proyecto y ejemplos de las respuestas del sistema.

Capítulo II. Marco teórico

2.1 ECG de 12 derivaciones (ElectroCardioGrama)

El electrocardiograma de 12 derivaciones, o ECG, es una prueba médica esencial. Es un procedimiento no invasivo que se encarga de capturar y registrar la actividad eléctrica del corazón desde múltiples perspectivas, y al final aporta una imagen detallada de su funcionamiento.

Se lleva a cabo colocando electrodos en zonas específicas del cuerpo del paciente. Estos se encargan de tomar las señales eléctricas generadas por los latidos del corazón. Las señales que se registran son amplificadas por una máquina de ECG, que las refleja visualmente en forma de ondas.

Las 12 derivaciones se obtienen mediante la combinación de diferentes electrodos; de esta manera se puede visualizar la actividad cardiaca desde diferentes perspectivas.

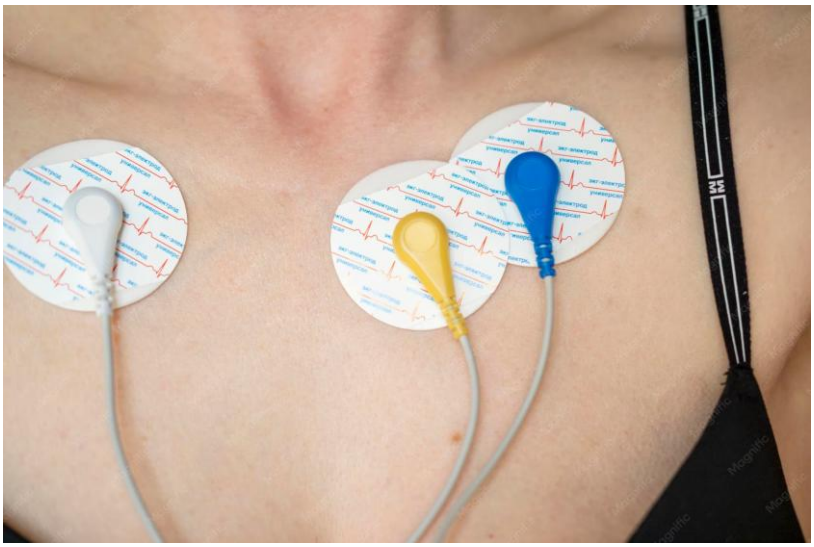


Figura 2. *Electrodos colocados en el tórax para registrar el electrocardiograma.*

La utilización de esta prueba es útil para diferentes diagnósticos, que podrían ser:

Diagnóstico de arritmias

Este diagnóstico permite a los especialistas identificar si el corazón está latiendo a un ritmo más rápido de lo normal, más lento o de manera irregular.

Detección de infarto de miocardio

Este tipo de infarto se produce cuando una arteria coronaria se bloquea y el oxígeno deja de llegar a una parte del corazón. El ECG de 12 derivaciones es capaz de mostrar una serie de

cambios visibles en las ondas eléctricas que indican que el músculo cardiaco ha sufrido un daño.

Monitorización de enfermedades cardiacas

El ECG resulta de especial utilidad para dar seguimiento a pacientes que cuentan con alguna enfermedad cardiaca ya conocida, a fin de evaluar la eficacia de los tratamientos y detectar posibles complicaciones.

Evaluación de efectos de los medicamentos

Cuando el paciente toma medicación que afecta el ritmo cardiaco y la función del corazón, es habitual realizar pruebas para monitorizar sus efectos y ajustar la dosis para minimizar riesgos.

Diagnóstico de otras condiciones cardiacas

Junto a las arritmias y los infartos, el ECG de 12 derivaciones puede emplearse en el diagnóstico de otras afecciones cardiacas, como la **pericarditis** (inflamación del pericardio), la **miocarditis** (inflamación del miocardio) y la disfunción del nodo sinusal.

2.1.1 El corazón como un sistema eléctrico

El corazón es un músculo que funciona como una bomba: se contrae para expulsar la sangre y se relaja para volver a llenarse. Lo que muchas personas no saben es que cada contracción empieza con una pequeña señal eléctrica. Sin esa chispa, el músculo no se movería.

La señal nace en un grupo de células especiales ubicado en la aurícula derecha, llamado nodo sinusal, que actúa como el marcapasos natural. Desde ahí la electricidad recorre las dos aurículas, que se contraen; luego llega a un segundo punto de control, el nodo auriculoventricular, donde se frena un instante para dar tiempo a que la sangre pase a los ventrículos; y finalmente baja por unas “vías rápidas” (el haz de His y sus ramas) que la reparten por los dos ventrículos, que se contraen con fuerza. Después, las células se recargan para el siguiente latido. Este ciclo se repite entre 60 y 100 veces por minuto en reposo.

Una buena forma de imaginarlo es una ola en un estadio: cada persona se levanta cuando su vecino se levanta, y la ola recorre las gradas en un orden preciso. El electrocardiograma es, en el fondo, una forma de observar esa ola desde fuera del cuerpo.

2.1.2 Las doce derivaciones

La actividad eléctrica del corazón es muy pequeña, del orden de milésimas de voltio, pero alcanza la superficie de la piel. Un electrocardiógrafo la capta con electrodos y la dibuja como

una línea que sube y baja a lo largo del tiempo. Cuando la electricidad se acerca a un electrodo, la línea sube; cuando se aleja, baja.

El estudio estándar usa diez electrodos: cuatro en las extremidades y seis en el pecho. A partir de ellos el equipo calcula doce **derivaciones**, que son como doce cámaras que miran el mismo partido desde ángulos distintos:

- **Derivaciones de las extremidades (plano frontal):** I, II, III, aVR, aVL y aVF. Miran el corazón de frente, como si estuviéramos parados delante del paciente.
- **Derivaciones precordiales (plano horizontal):** V1 a V6. Rodean el pecho desde el lado derecho del esternón hasta el costado izquierdo y miran el corazón como si lo cortáramos en rodajas horizontales.

Cada derivación ve mejor una región del corazón. Por eso, cuando un infarto daña la cara inferior del corazón, los cambios aparecen sobre todo en II, III y aVF; cuando daña la cara anterior, aparecen en V1 a V4. Esta relación entre derivaciones y regiones es la base de la lectura clínica y la retomaremos más adelante.

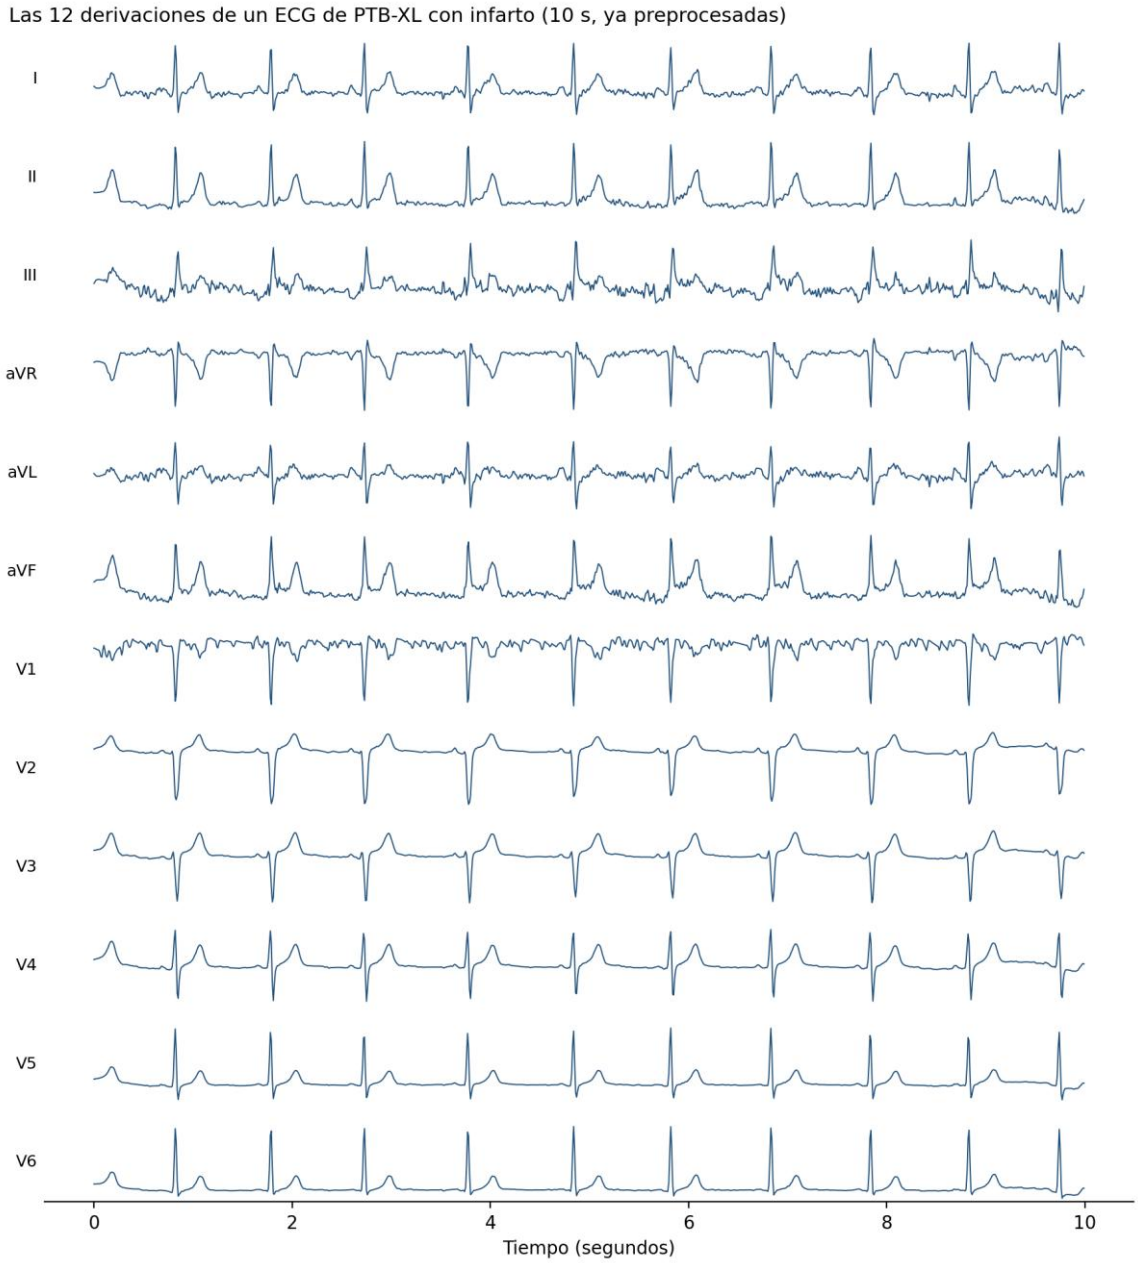


Figura 3. *Las doce derivaciones de un mismo electrocardiograma de PTB-XL. Cada fila es una "vista" distinta de la misma actividad eléctrica durante 10 segundos.*

2.1.3 Las ondas de un latido

Si miramos con cuidado un solo latido en una derivación, vemos siempre la misma secuencia de ondas, a las que por convención se les asignaron letras:

- **Onda P:** pequeña joroba que corresponde a la activación de las aurículas.
- **Complejo QRS:** el pico alto y angosto que todos asociamos con un electrocardiograma. Corresponde a la activación de los ventrículos. La **onda Q** es la pequeña bajada que a veces aparece justo antes del pico R.

- **Segmento ST:** el tramo plano que sigue al QRS. Normalmente está al mismo nivel que la línea de base.
- **Onda T:** joroba redondeada que corresponde a la recuperación (repolarización) de los ventrículos.

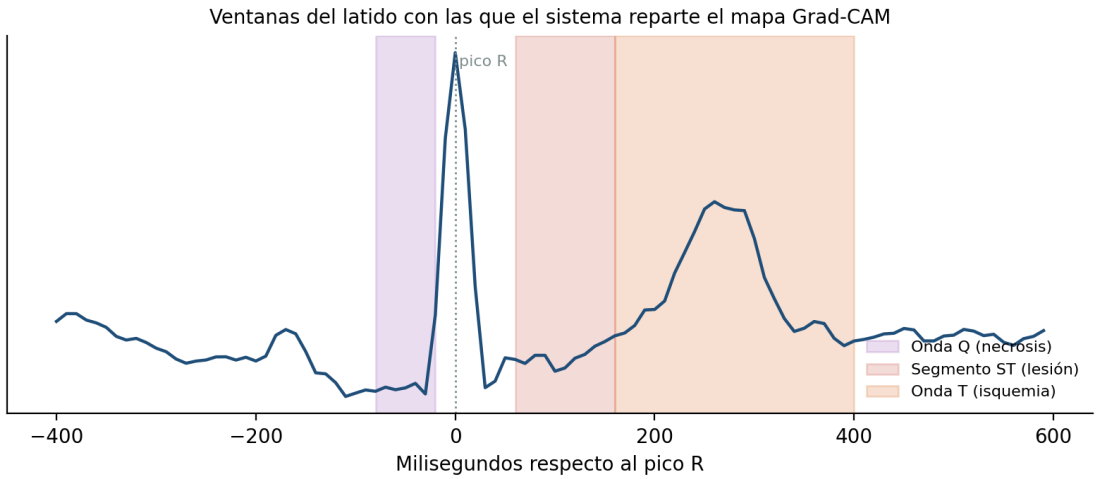


Figura 4. *Un latido con sus ondas principales. Las bandas de color marcan las ventanas que el sistema usa para relacionar el mapa de explicabilidad con la onda Q, el segmento ST y la onda T.*

2.1.4 El papel del electrocardiograma y el formato 3 × 4

Por tradición, el electrocardiograma se imprime sobre papel cuadriculado con medidas estandarizadas. Cada cuadrito pequeño mide 1 mm por lado y cada cuadro grande, 5 mm. A la velocidad habitual de 25 mm por segundo, un milímetro horizontal equivale a 40 milisegundos y un cuadro grande a 200 milisegundos. En vertical, la calibración habitual es de 10 mm por milivoltio, así que un milímetro equivale a 0.1 mV. Gracias a esta convención, cualquier persona puede medir duraciones y alturas con solo contar cuadritos.

La distribución más común en la hoja es el formato **3 × 4**: tres renglones con cuatro columnas, de modo que cada derivación aparece durante solo 2.5 segundos (I, aVR, V1 y V4 en el primer renglón; II, aVL, V2 y V5 en el segundo; III, aVF, V3 y V6 en el tercero). Debajo suele añadirse una o más **tiras de ritmo**, generalmente de la derivación II, que muestran los 10 segundos completos. Este detalle es importante para el proyecto: una hoja impresa no contiene los 10 segundos de las doce derivaciones, sino solo una cuarta parte de cada una.

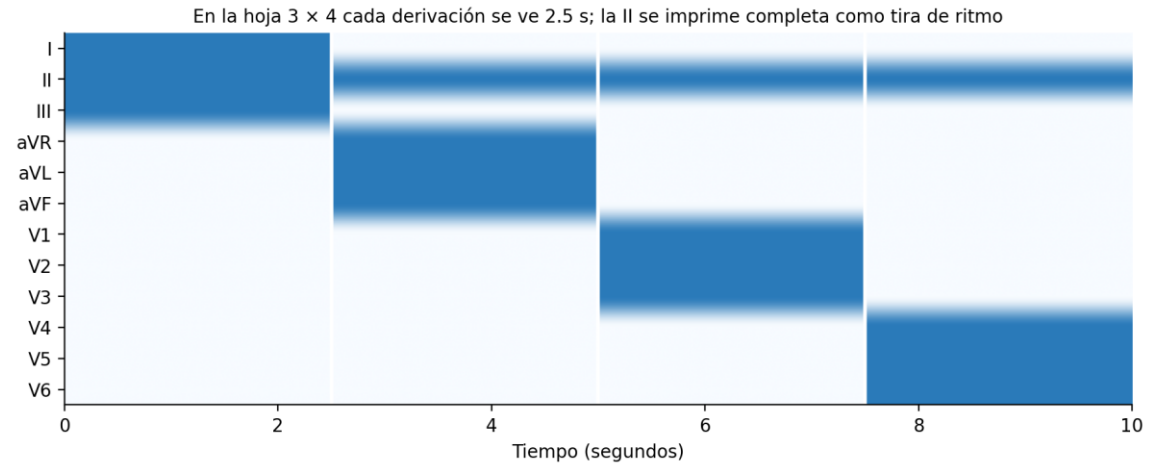


Figura 5. *Formato de impresión 3 × 4. Cada derivación se observa solo durante 2.5 segundos (zonas sombreadas); la tira de ritmo de la parte inferior muestra la derivación II completa.*

2.2 IAM (Infarto Agudo al Miocardio)

El Infarto Agudo al Miocardio es un síndrome coronario agudo. Se caracteriza por la aparición brusca de un cuadro de sufrimiento isquémico (falta de riego) en una parte del músculo del corazón, producido por la obstrucción aguda y total de una de las arterias coronarias que lo alimentan.

Las arterias coronarias son los tubos que llevan sangre al propio músculo del corazón. Con los años, en sus paredes se pueden acumular placas de grasa y calcio. Si una placa se rompe, se forma encima un coágulo que puede tapar la arteria por completo en cuestión de minutos. La parte del músculo que dependía de esa arteria se queda sin oxígeno: primero sufre (isquemia), luego se lesiona y, si la falta de sangre dura lo suficiente, muere (necrosis). Eso es un infarto agudo al miocardio.

La Cuarta Definición Universal del Infarto (Thygesen et al., 2018) establece que se habla de infarto cuando hay daño del músculo cardiaco, demostrado por la elevación de una proteína en sangre llamada troponina, junto con evidencia de isquemia: síntomas como dolor en el pecho, cambios nuevos en el electrocardiograma, aparición de ondas Q, imágenes que muestren músculo que ya no se mueve o un coágulo visto en un cateterismo. En otras palabras, el electrocardiograma es una pieza central del diagnóstico, pero no la única.

En la práctica clínica se distinguen dos grandes tipos según lo que muestra el electrocardiograma al llegar el paciente:

- **Infarto con elevación del segmento ST (IAMCEST):** suele indicar que la arteria está completamente tapada. Requiere abrirla de inmediato, ya sea con un cateterismo o con medicamentos que disuelven el coágulo.
- **Infarto sin elevación del segmento ST (IAMSEST):** la arteria puede estar parcialmente tapada. El electrocardiograma puede mostrar descenso del ST, ondas T invertidas o incluso ser normal, y el diagnóstico depende más de la troponina.

Existe un tercer escenario relevante para este proyecto: el **infarto antiguo**. Cuando un paciente tuvo un infarto hace meses o años, la zona muerta se convierte en cicatriz y deja huellas permanentes en el electrocardiograma, sobre todo ondas Q. Un electrocardiograma puede, por tanto, mostrar signos de infarto aunque el paciente esté estable en ese momento. Como veremos, la base de datos con la que entrenamos no separa el infarto reciente del antiguo.

2.2.1 Las huellas del infarto en el electrocardiograma

Los libros de cardiología describen una secuencia típica de cambios que, de forma simplificada, se relaciona con tres etapas del daño:

- **Isquemia → onda T alterada.** En los primeros minutos la onda T puede volverse más alta y puntiaguda ("hiperaguda"), y más adelante invertirse.
- **Lesión → segmento ST desplazado.** El ST se eleva por encima de la línea de base en las derivaciones que miran la zona afectada, y a menudo desciende en las derivaciones opuestas (cambios "en espejo").
- **Necrosis → onda Q patológica.** Cuando el músculo ya murió, deja de generar electricidad y aparece una onda Q ancha (40 ms o más) o profunda (más de un cuarto de la altura del QRS). Esta onda suele quedarse para siempre.

La localización de los cambios ayuda a saber qué arteria se tapó. La tabla siguiente resume la relación clásica:

Tabla 1. *Relación aproximada entre derivaciones con cambios, región del corazón y arteria implicada.*

Región afectada	Derivaciones donde se ven los cambios	Arteria habitualmente implicada
Inferior	II, III, aVF	Coronaria derecha (a veces circunfleja)
Anteroseptal	V1, V2, V3	Descendente anterior
Anterior	V3, V4	Descendente anterior
Lateral	I, aVL, V5, V6	Circunfleja o ramas diagonales
Anterior extenso	V1 a V6, I, aVL	Descendente anterior proximal

Hay que subrayar que estas reglas tienen excepciones. Un bloqueo de rama, un marcapasos, una hipertrofia del ventrículo o ciertas alteraciones de los electrolitos pueden producir cambios parecidos sin que exista un infarto. Al revés, algunos infartos, sobre todo en la cara posterior del corazón, se ven poco en el electrocardiograma de 12 derivaciones. Esa ambigüedad es justo lo que hace difícil la lectura y lo que pone un límite al desempeño de cualquier sistema automático.

2.3 Redes neuronales convolucionales profundas

Las redes neuronales convolucionales (Convolutional Neural Networks, CNN), introducidas por LeCun et al. (1989), constituyen una arquitectura especializada de red neuronal diseñada para procesar datos con estructura de cuadrícula, como series temporales (cuadrícula unidimensional) o imágenes (cuadrícula bidimensional). Su desarrollo responde a una limitación de las redes densas tradicionales: estas últimas no consideran que, en una imagen, los píxeles cercanos entre sí guardan una correlación mucho mayor que los píxeles distantes. Las CNN explotan esa propiedad extrayendo características locales a partir de pequeñas subregiones de la imagen, las cuales se combinan progresivamente en capas posteriores para detectar patrones de mayor complejidad, hasta generar una representación global de la imagen.

A diferencia de una red neuronal densa, en la que cada capa se define por una matriz de pesos bidimensional, en una CNN las neuronas se organizan en tres dimensiones: ancho, alto y profundidad. Esta disposición permite reducir drásticamente el número de parámetros del modelo, ya que los pesos que conectan las neuronas se comparten espacialmente.

Una arquitectura convolucional típica sigue el esquema [INPUT – CONV – RELU – POOL – FC], donde cada componente cumple una función específica:

- **Capa de entrada (INPUT):** contiene los valores de píxeles de la imagen (por ejemplo, tres canales para RGB). En el caso del ECG son las 12 derivaciones.
- **Capa convolucional (CONV):** aplica un conjunto de filtros aprendibles de tamaño reducido (por ejemplo, 3×3 o 5×5) que se desplazan sobre la entrada calculando productos punto entre los pesos del filtro y la región local a la que están conectados, generando así mapas de activación. Esta capa se define mediante cuatro hiperparámetros: número de filtros (K), tamaño del filtro (F), paso o stride (S) y relleno o padding (P).
- **Capa de activación (ReLU):** introduce no linealidad aplicando la función max(0, x) sin alterar las dimensiones del volumen.

- **Capa de agrupación (POOL):** reduce progresivamente las dimensiones espaciales (ancho y alto) mediante una operación de submuestreo, habitualmente max-pooling, disminuyendo así el número de parámetros y el riesgo de sobreajuste. Esta capa no incorpora pesos aprendibles.
- **Capa totalmente conectada (FC):** integra la información extraída por las capas anteriores para producir las puntuaciones finales de clasificación.

Existen ciertas reglas de diseño generalmente aceptadas: emplear filtros pequeños con stride de 1 y un padding que preserve las dimensiones espaciales de la entrada, así como utilizar capas de pooling con campos receptivos de 2×2 y salto de 2.

A lo largo de la evolución de este tipo de arquitecturas se han propuesto diversos modelos de referencia. LeNet fue una de las primeras aplicaciones exitosas, orientada al reconocimiento de dígitos (LeCun et al., 1998). AlexNet (Krizhevsky et al., 2012) popularizó el uso de las CNN en visión artificial al obtener resultados sobresalientes en el desafío ImageNet. Posteriormente surgieron arquitecturas como ZFNet, GoogLeNet —que introdujo el módulo Inception para reducir el número de parámetros— y VGGNet, que demostró la importancia de la profundidad de la red para mejorar el rendimiento. Finalmente, las Redes Residuales Profundas (ResNet), propuestas por He et al. (2016), incorporaron conexiones de salto (skip connections) que permiten a la información fluir directamente entre capas no consecutivas, mitigando el problema de la degradación del gradiente en redes muy profundas y consolidándose como una de las arquitecturas de referencia en la actualidad.

Para entender cómo se usan estas redes en el proyecto conviene explicar, con palabras sencillas, qué es aprender para una computadora, cómo se entrena una red y cómo se adapta la convolución a una señal como el electrocardiograma.

2.3.1 Inteligencia artificial y aprendizaje automático

La inteligencia artificial es un campo amplio que busca que las computadoras realicen tareas que normalmente requieren inteligencia humana. Dentro de ella, el **aprendizaje automático** es la parte que no programa reglas a mano, sino que deja que la computadora las descubra a partir de ejemplos.

Imaginemos cómo aprende un residente de cardiología. Nadie le da una fórmula exacta para reconocer un infarto; ve cientos de electrocardiogramas, cada uno con el diagnóstico de un experto, y poco a poco su cerebro aprende qué patrones importan. El aprendizaje automático supervisado funciona de forma parecida: le damos a la computadora miles de

electrocardiogramas junto con la respuesta correcta (“infarto” o “no infarto”) y un procedimiento matemático va ajustando el modelo para que sus respuestas se parezcan cada vez más a las correctas.

Entrenamiento, validación y prueba

Una regla de oro del aprendizaje automático es no evaluar a un modelo con los mismos ejemplos con los que aprendió, igual que un buen profesor no pone en el examen final exactamente los ejercicios que resolvió en clase. Por eso los datos se dividen en tres grupos:

- **Entrenamiento:** los ejemplos con los que el modelo aprende. Es la gran mayoría.
- **Validación:** un grupo aparte que se usa durante el desarrollo para tomar decisiones, como cuándo dejar de entrenar o qué punto de corte usar. Es como el examen de práctica.
- **Prueba:** un grupo que se guarda bajo llave y se usa una sola vez, al final, para medir el desempeño real. Es el examen final.

En datos médicos hay una precaución adicional: un mismo paciente puede tener varios estudios. Si un estudio de un paciente queda en entrenamiento y otro del mismo paciente en prueba, el modelo podría “reconocer” al paciente en lugar de aprender a reconocer el infarto, y las cifras saldrían infladas. La partición debe hacerse por pacientes, no por estudios.

2.3.2 Redes neuronales

Una red neuronal artificial es un modelo matemático inspirado, de forma muy libre, en las neuronas del cerebro. Su unidad básica es la neurona artificial: recibe varios números, multiplica cada uno por un “peso”, suma los resultados y pasa esa suma por una función sencilla llamada **función de activación**. Los pesos son los que se ajustan durante el entrenamiento; son, por así decirlo, el conocimiento de la red.

Una sola neurona puede hacer poco. La fuerza de las redes está en organizarlas en **capas**: la primera capa recibe los datos, las capas intermedias transforman la información paso a paso y la última entrega la respuesta. Cuando hay muchas capas intermedias hablamos de **aprendizaje profundo**. Cada capa aprende a reconocer patrones un poco más complejos que la anterior: en un electrocardiograma, las primeras capas podrían detectar subidas y bajadas bruscas; las siguientes, formas como un pico o una joroba; y las últimas, combinaciones como “onda Q ancha seguida de ST elevado en varias derivaciones”.

La función de activación ReLU

Si las neuronas solo sumaran y multiplicaran, por muchas capas que pusiéramos la red solo podría aprender relaciones en línea recta. La función de activación introduce "curvas" en el razonamiento. La más usada hoy es ReLU, que es muy simple: si el número es positivo lo deja pasar; si es negativo lo convierte en cero. A pesar de su sencillez, permite a la red representar relaciones muy complejas.

¿Cómo aprende una red?

El entrenamiento es un proceso de prueba y corrección que se repite miles de veces:

1. La red recibe un grupo pequeño de electrocardiogramas, llamado **lote**, y da su respuesta para cada uno.
2. Una **función de pérdida** compara esas respuestas con las correctas y produce un número que mide qué tan equivocada estuvo la red. Usamos la entropía cruzada, que castiga mucho cuando la red está muy segura de una respuesta incorrecta.
3. Mediante un procedimiento llamado retropropagación se calcula, para cada peso, en qué dirección habría que moverlo para reducir el error. A esa dirección se le llama **gradiente**.
4. Un **optimizador** mueve todos los pesos un pequeño paso en esa dirección. El tamaño del paso se llama **tasa de aprendizaje**.

Una buena analogía es bajar una montaña con niebla: no vemos el valle, pero sí sentimos hacia dónde baja el terreno bajo nuestros pies. Damos un paso en esa dirección, volvemos a tantear y repetimos. Si los pasos son muy grandes podemos pasarnos del valle; si son muy pequeños, tardaremos demasiado. Por eso es común empezar con pasos medianos y reducirlos cuando dejamos de avanzar, que es lo que hicimos con un programador de tasa de aprendizaje.

El optimizador que utilizamos es **AdamW** (Kingma y Ba, 2015; Loshchilov y Hutter, 2019). Adam adapta el tamaño del paso para cada peso según cómo se ha comportado su gradiente en los pasos anteriores, lo que lo hace robusto y fácil de usar. La "W" indica una forma correcta de aplicar el decaimiento de pesos, una técnica que mantiene los pesos pequeños y ayuda a que la red no memorice.

Cada vez que la red ha visto todos los ejemplos de entrenamiento una vez, se completa una **época**. Un entrenamiento típico dura decenas de épocas.

El sobreajuste y cómo combatirlo

El mayor riesgo al entrenar una red es el **sobreajuste**. Una red con millones de pesos tiene capacidad suficiente para memorizar cada ejemplo de entrenamiento, incluido su ruido. Cuando eso sucede, su desempeño en entrenamiento sigue mejorando, pero con datos nuevos empeora. Es el alumno que memoriza el solucionario: saca diez en las tareas y reprueba el examen.

La forma de detectarlo es vigilar el desempeño en validación al final de cada época. Mientras ambas curvas mejoran juntas, la red está aprendiendo; cuando la de validación se estanca o empeora mientras la de entrenamiento sigue mejorando, la red está memorizando. En el Capítulo III mostramos este fenómeno con un experimento de 100 épocas. Las técnicas que usamos para combatirlo son:

- **Parada temprana:** se guarda el modelo de la época con mejor desempeño en validación y se detiene el entrenamiento si pasan varias épocas sin mejora.
- **Dropout:** durante el entrenamiento se "apagan" al azar algunas neuronas en cada paso, lo que obliga a la red a no depender de una sola pista (Srivastava et al., 2014).
- **Decaimiento de pesos:** penaliza los pesos muy grandes.
- **Normalización por lotes:** estabiliza los valores que circulan entre capas y facilita el entrenamiento (Ioffe y Szegedy, 2015).
- **Aumento de datos:** se crean variaciones realistas de cada ejemplo, de modo que la red nunca ve dos veces exactamente el mismo electrocardiograma.

2.3.3 Convolución en una dimensión

En una red "tradicional", cada neurona de una capa se conecta con todas las de la anterior. Para un electrocardiograma de 12 derivaciones y 1 000 muestras eso significaría 12 000 entradas por neurona, una cantidad enorme de pesos que además ignora algo evidente: en una señal, los valores cercanos en el tiempo están relacionados entre sí.

Las **redes neuronales convolucionales** (LeCun et al., 1989; LeCun et al., 1998) resuelven este problema con una idea elegante. En lugar de mirar toda la señal de golpe, usan **filtros** pequeños, por ejemplo de 7 muestras de largo, que se deslizan a lo largo del trazo. En cada posición, el filtro calcula qué tanto se parece ese pedazo de señal a la forma que el filtro "busca". El resultado es un nuevo trazo, llamado mapa de activación, que es alto donde aparece esa forma y bajo donde no.

Es parecido a buscar una palabra en un texto con una lupa que recorremos de izquierda a derecha. La lupa es la misma en todo el recorrido; por eso el filtro reconoce una onda Q ancha tanto si aparece en el segundo 2 como en el segundo 8. Una capa tiene decenas o cientos de filtros, cada uno especializado en una forma distinta, y las capas posteriores combinan esas formas en patrones más complejos.

Entre capas se suele reducir la longitud del trazo, ya sea con un salto del filtro mayor a uno (stride) o con una operación de **agrupamiento** que se queda con el valor más alto de cada pequeño tramo. Así, las capas profundas ven una porción cada vez mayor de la señal con menos detalle, igual que cuando nos alejamos de un cuadro para apreciar la composición completa.

Las redes convolucionales se hicieron famosas en el reconocimiento de imágenes, en particular desde que AlexNet ganó la competencia ImageNet en 2012 (Krizhevsky et al., 2012). Para señales como el electrocardiograma se usa la versión **unidimensional**: el filtro se desliza solo a lo largo del tiempo y combina, en cada posición, las doce derivaciones a la vez.

2.4 Redes Residuales Profundas (ResNet)

ResNet (Residual Network) es una arquitectura de red neuronal profunda propuesta por Kaiming He y su equipo en Microsoft Research en 2015 (He et al., 2016), creada para resolver un problema que impedía entrenar redes con muchas capas: entre más profunda era una red, más difícil era entrenarla, ya que el gradiente se desvanecía al retroceder por tantas capas y, en lugar de mejorar, el rendimiento empeoraba. Para solucionarlo, ResNet introduce las conexiones de salto (skip connections), que permiten que la información se salte una o varias capas y llegue de forma directa más adelante en la red, sumándose a lo que esas capas ya habían calculado.

Gracias a esto, cada bloque de la red ya no tiene que aprender una transformación completa desde cero, sino solo una pequeña corrección (llamada residuo) sobre lo que entra, lo cual es mucho más fácil de optimizar y evita que el gradiente se pierda al retropropagarse. Existen varias versiones de esta arquitectura (ResNet-18, 34, 50, 101 y 152, nombradas según su número de capas), y gracias a este diseño se logró entrenar por primera vez redes de más de 100 capas de forma confiable, lo que le permitió ganar el ImageNet Large Scale Visual Recognition Challenge en 2015 y convertirse en una de las arquitecturas más usadas hasta hoy en visión por computadora.

2.4.1 Una forma sencilla de verlo

Una comparación útil es la de un documento que pasa por varios revisores. En una red tradicional, cada revisor reescribe el documento desde cero a partir de la versión anterior, y con muchos revisores el mensaje original se pierde. En una red residual, cada revisor solo anota correcciones al margen, y el texto original siempre viaja completo. Con este diseño, He et al. lograron entrenar redes de más de cien capas y ganaron la competencia ImageNet de 2015.

Cada **bloque residual** de nuestro modelo contiene dos convoluciones, cada una seguida de normalización por lotes, con una activación ReLU y un dropout entre ellas. El atajo suma la entrada del bloque a su salida, y el resultado pasa por una última ReLU. Cuando el bloque cambia el número de canales o la longitud del trazo, el atajo usa una convolución de tamaño 1 para que ambos lados de la suma tengan la misma forma.

2.4.2 Redes residuales para el electrocardiograma: estado del arte

La aplicación del aprendizaje profundo al electrocardiograma ha avanzado mucho en la última década. Revisamos los trabajos que más influyeron en nuestras decisiones.

Hannun et al. (2019) entrenaron una red convolucional de 34 capas con más de 90 000 registros de un solo canal obtenidos con monitores ambulatorios. La red clasificó 12 tipos de ritmo con un desempeño comparable al de cardiólogos certificados. Este trabajo mostró que una red profunda puede aprender directamente de la señal cruda, sin que alguien le diga dónde está cada onda.

Attia et al. (2019) usaron electrocardiogramas de 12 derivaciones de la Clínica Mayo para detectar algo que un humano no puede ver a simple vista: la disfunción del ventrículo izquierdo. Fue una muestra de que la red puede encontrar patrones sutiles que van más allá de las reglas clásicas.

Ribeiro et al. (2020) entrenaron una red residual unidimensional con más de dos millones de electrocardiogramas de 12 derivaciones de la red de telesalud de Minas Gerais, en Brasil, para reconocer seis anomalías. Su red superó a residentes de cardiología y de medicina en varias de ellas. Es la referencia directa de nuestro enfoque: una ResNet1D que recibe las doce derivaciones como canales. No obstante, no es el mismo experimento: ellos usaron otra base, otras clases y otro protocolo, por lo que sus cifras no son comparables una a una con las nuestras.

Wagner et al. (2020) publicaron PTB-XL, el conjunto que usamos, y **Strodthoff et al. (2021)** publicaron con él un banco de pruebas que compara muchas arquitecturas con un protocolo idéntico. En la tarea de clasificar las cinco superclases diagnósticas, las mejores redes, entre ellas varias redes residuales unidimensionales, obtuvieron un área bajo la curva promedio cercana a 0.93. Ese trabajo nos dio dos cosas: la justificación para usar una red residual 1D a 100 Hz y una referencia realista de qué tan alto se puede llegar con estos datos.

Tabla 2. *Trabajos de referencia sobre aprendizaje profundo aplicado al electrocardiograma.*

Trabajo	Datos	Tarea	Aporte para este proyecto
Hannun et al., 2019	≈91 000 registros de 1 derivación	12 ritmos	Una red profunda aprende de la señal cruda
Attia et al., 2019	ECG de 12 derivaciones, Clínica Mayo	Disfunción ventricular	La red detecta patrones no evidentes
Ribeiro et al., 2020	≈2.3 millones de ECG de 12 derivaciones	6 anomalías	ResNet1D con las 12 derivaciones como canales
Wagner et al., 2020	PTB-XL, 21 799 ECG	Conjunto de datos	Base pública con pliegues por paciente
Strodthoff et al., 2021	PTB-XL	Superclases y otras tareas	Referencia de desempeño (AUC ≈ 0.93)

Más recientemente, la competencia **PhysioNet Challenge 2024** propuso digitalizar y clasificar electrocardiogramas a partir de imágenes de hojas impresas, reconociendo que gran parte de los estudios del mundo existen solo en papel. Esa iniciativa coincidió con una necesidad que detectamos en nuestro propio proyecto y que atendimos con un digitalizador propio.

2.5 Data set PTB-XL

El data set PTB-XL es un conjunto amplio de electrocardiogramas clínicos de 12 derivaciones y 10 segundos de duración (Wagner et al., 2020). Los datos de la forma de onda en bruto fueron anotados por hasta dos cardiólogos, que asignaron potencialmente múltiples declaraciones de ECG a cada registro. Las 71 declaraciones diferentes cumplen con el estándar SCP-ECG y cubren diagnóstico, forma y ritmo. Para garantizar la comparabilidad de los algoritmos de aprendizaje automático entrenados con el conjunto de datos, se proporcionaron divisiones recomendadas en conjuntos de entrenamiento y de prueba. Todo ello, combinado con una extensa anotación, convierte al conjunto de datos en un recurso valioso para el entrenamiento y la evaluación de algoritmos automáticos de interpretación de ECG.

El conjunto de datos se complementa con una gran cantidad de metadatos sobre demografía, características de infarto, probabilidades para las declaraciones diagnósticas de ECG y propiedades de las señales anotadas.

La publicación original describe 21 837 registros de 18 885 pacientes. En este proyecto usamos la versión 1.0.3, distribuida en PhysioNet (Goldberger et al., 2000), que contiene **21 799 registros de 18 869 pacientes**, porque los autores retiraron algunos registros en versiones posteriores. Los registros se tomaron con equipos Schiller AG y están disponibles a 500 Hz y en una versión reducida a 100 Hz. En el Capítulo III se describe en detalle su contenido y cómo lo preparamos.

2.6 Del trazo a los números: señales digitales

Un electrocardiógrafo moderno no dibuja una línea continua, sino que mide el voltaje muchas veces por segundo y guarda cada medición como un número. A cada medición se le llama **muestra** y al número de muestras por segundo, **frecuencia de muestreo**. Si un equipo trabaja a 500 Hz, guarda 500 números por segundo en cada derivación; un estudio de 10 segundos y 12 derivaciones produce así una tabla de 5 000 renglones por 12 columnas.

Es como filmar un partido con una cámara: a más cuadros por segundo, más fluido el movimiento. Para el electrocardiograma, 100 cuadros por segundo bastan para reconocer la forma general de las ondas; 500 permiten ver detalles finos del QRS. En este proyecto convertimos todas las señales a **100 Hz**, porque es la frecuencia con la que se obtuvieron los mejores resultados publicados en PTB-XL y porque reduce cinco veces la cantidad de datos que la red tiene que procesar.

Un detalle que parece menor pero que causa errores graves es que un archivo con solo números no dice a qué frecuencia se grabó. Si un archivo CSV de 5 000 renglones se interpreta como si fuera de 100 Hz en lugar de 500 Hz, el sistema creería que dura 50 segundos y que el corazón late cinco veces más lento. Por eso dedicamos una parte del proyecto a detectar la frecuencia de forma automática.

2.6.1 Ruido y filtrado

La señal que llega al equipo no es solo la del corazón. Se mezclan otras fuentes: la respiración, que mueve los electrodos y hace que la línea base suba y baje lentamente; los músculos del paciente, que generan pequeñas vibraciones rápidas; y la red eléctrica, que induce una interferencia de 50 o 60 Hz. Un **filtro pasa-banda** deja pasar solo las frecuencias

de un rango y atenúa el resto. Usamos un filtro de tipo Butterworth entre 0.5 y 40 Hz: por debajo de 0.5 Hz están los movimientos lentos de la línea base y por encima de 40 Hz, la mayor parte del ruido muscular y eléctrico. La información que distingue un infarto (la forma del QRS, del ST y de la T) queda dentro de ese rango.

Aplicamos el filtro "hacia adelante y hacia atrás", una técnica llamada filtrado de fase cero, para que no desplace las ondas en el tiempo. Si la onda T se corriera unos milisegundos, la relación entre el mapa de explicabilidad y las ondas dejaría de tener sentido.

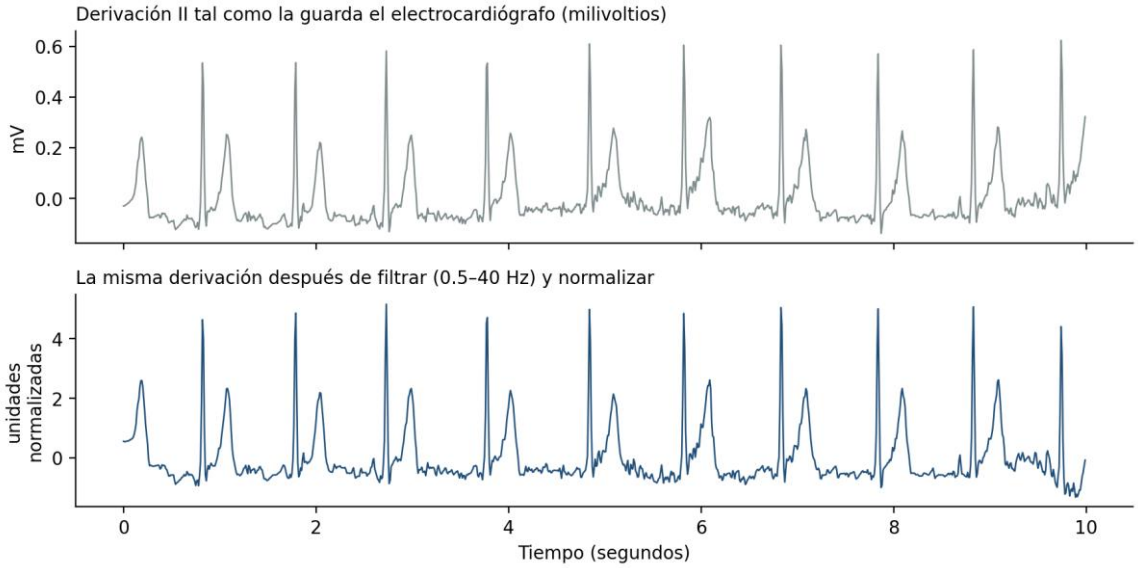


Figura 6. *Derivación II antes y después del filtrado de 0.5 a 40 Hz. La línea base deja de ondular y el trazo conserva la forma de las ondas.*

2.6.2 Normalización

Cada paciente tiene una amplitud distinta: el grosor del tórax, la posición del corazón o la calidad del contacto de los electrodos cambian la altura del trazo. Para que la red no se confunda con esas diferencias, cada derivación se **normaliza**: se le resta su promedio y se divide entre su desviación estándar. El resultado es una señal centrada en cero y con una escala comparable entre pacientes. Después recortamos los valores extremos, que suelen deberse a artefactos, para que no dominen el aprendizaje.

2.7 Explicabilidad: abrir la caja negra con Grad-CAM

Una red neuronal profunda tiene millones de pesos y no es posible leerlos para entender por qué tomó una decisión. Por eso se dice que es una "caja negra". En medicina esto es un problema serio: un médico difícilmente confiará en una herramienta que solo responde "infarto: 64 %" sin decir por qué.

Grad-CAM (Selvaraju et al., 2017) es una de las técnicas más usadas para echar un vistazo dentro de la caja. Funciona en tres pasos. Primero, toma los mapas de activación de la última capa convolucional, que son las "pistas" que encontró la red a lo largo de la señal. Segundo, calcula cuánto cambiaría la puntuación de "infarto" si cada uno de esos mapas aumentara un poco; esa sensibilidad es el gradiente, y sirve como peso de la importancia de cada mapa. Tercero, suma los mapas ponderados por su importancia y se queda solo con la parte positiva. El resultado es una curva a lo largo del tiempo que es alta en los momentos que empujaron la decisión hacia "infarto".

En nuestro caso, la última capa trabaja sobre un trazo de 32 posiciones que cubre los 10 segundos, así que el mapa se estira de nuevo a 1 000 muestras para dibujarlo encima del electrocardiograma. Una consecuencia importante es que el mapa es **temporal y común a las doce derivaciones**: dice "en este momento del trazo", pero no "en esta derivación". Además, su resolución es limitada, de alrededor de un tercio de segundo, por lo que no puede señalar con precisión una onda Q de 40 ms.

Para acercar el mapa al lenguaje clínico, el sistema detecta los picos R de cada latido y define tres ventanas a su alrededor: de 80 a 20 ms antes del pico para la onda Q, de 60 a 160 ms después para el segmento ST y de 160 a 400 ms después para la onda T. Luego compara la activación media en cada ventana. Si una destaca, la interfaz lo indica; si la diferencia es pequeña, informa que la activación es homogénea. Es una ayuda para orientar la mirada, no una medición.

2.8 ¿Cómo se mide si el sistema funciona?

Decir que un modelo "acierta el 85 %" puede ser engañoso. Si en una población solo 1 de cada 100 personas tiene infarto, un sistema que siempre responda "no hay infarto" acertaría el 99 % de las veces y sería completamente inútil. Por eso en salud se usan métricas que separan los dos tipos de error.

2.8.1 La matriz de confusión

Todo comienza por contar cuatro tipos de resultado:

Tabla 3. *Los cuatro resultados posibles de una prueba diagnóstica.*

	El paciente sí tiene infarto	**El paciente no tiene infarto**
El sistema dice "infarto"	Verdadero positivo (VP)	Falso positivo (FP): falsa alarma
El sistema dice "sin infarto"	Falso negativo (FN): infarto no detectado	Verdadero negativo (VN)

Los dos errores no pesan lo mismo. Un falso negativo puede significar que un paciente con infarto se vaya a casa sin tratamiento. Un falso positivo significa una revisión adicional o un análisis de sangre que al final resulta normal. En un sistema de apoyo para infarto, preferimos equivocarnos más por exceso que por defecto, y esa preferencia guía la elección del punto de corte.

2.8.2 Sensibilidad, especificidad y valores predictivos

- **Sensibilidad** = VP / (VP + FN). De cada 100 infartos, cuántos detecta.
- **Especificidad** = VN / (VN + FP). De cada 100 personas sin infarto, cuántas reconoce como tales.
- **Valor predictivo positivo (VPP o precisión)** = VP / (VP + FP). Si el sistema dice "infarto", la probabilidad de que lo sea.
- **Valor predictivo negativo (VPN)** = VN / (VN + FN). Si el sistema dice "sin infarto", la probabilidad de que de verdad no lo haya.
- **F1:** combina la sensibilidad y el VPP en un solo número; es alto solo si ambos lo son.
- **Exactitud:** proporción total de aciertos. La reportamos, pero no la usamos para decidir, por el problema descrito arriba.

La sensibilidad y la especificidad son propiedades del sistema: no cambian si el infarto es más o menos frecuente en la población. Los valores predictivos sí cambian, y mucho. Con una prevalencia de 25 %, como en el grupo de prueba de PTB-XL, nuestro VPP es de 0.64; en una población donde solo el 1 % tiene infarto, el mismo sistema, con la misma sensibilidad y especificidad, tendría un VPP inferior a 0.06. La figura siguiente muestra esta relación. Es un punto que conviene explicar a cualquier usuario: en una población de bajo riesgo, la mayoría de las alarmas serán falsas, aunque el sistema funcione bien.

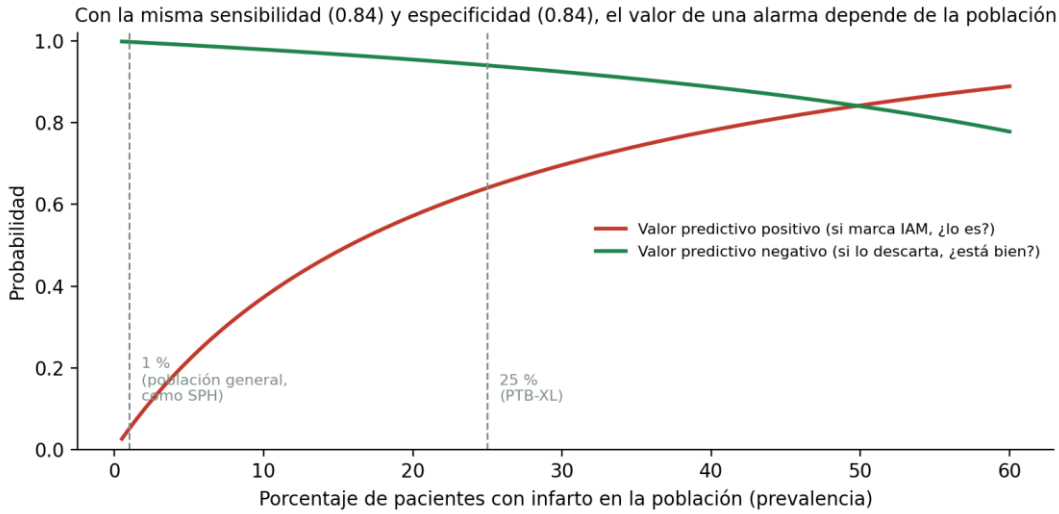


Figura 7. *Valor predictivo positivo y negativo en función de la prevalencia del infarto, con la sensibilidad (0.84) y especificidad (0.843) del modelo digital.*

2.8.3 La curva ROC y el área bajo la curva

La red no responde "sí" o "no", sino una probabilidad entre 0 y 1. Para convertirla en una decisión hay que elegir un **punto de corte**: si la probabilidad lo supera, se dice "infarto". Si bajamos el corte, detectamos más infartos pero damos más falsas alarmas; si lo subimos, ocurre lo contrario.

La **curva ROC** dibuja todos los posibles puntos de corte a la vez: en el eje horizontal la proporción de falsas alarmas (1 − especificidad) y en el vertical la sensibilidad. Un modelo perfecto sube derecho hasta la esquina superior izquierda; un modelo que adivina al azar sigue la diagonal. El **área bajo la curva (AUC)** resume la curva en un número con una interpretación muy intuitiva: es la probabilidad de que, si tomamos al azar un paciente con infarto y otro sin infarto, el modelo le dé mayor probabilidad al que sí lo tiene (Fawcett, 2006). Un AUC de 0.925 significa que esto ocurre en 92.5 de cada 100 parejas.

La **curva de precisión y sensibilidad** es una alternativa útil cuando la clase positiva es minoritaria, porque muestra directamente cuántas de las alarmas son correctas a medida que se detectan más infartos. Su área se conoce como precisión media (AP).

2.8.4 Elegir el punto de corte sin hacer trampa

El corte por defecto de 0.5 no tiene nada de especial. Lo correcto es elegirlo con un criterio claro y usando solo el grupo de validación. Nuestro criterio fue: **entre todos los cortes que detectan al menos 85 de cada 100 infartos en validación, elegir el que da la mayor especificidad**. Si ningún corte alcanzara esa sensibilidad, usaríamos el índice de Youden (Youden, 1950), que busca el punto con la mayor suma de sensibilidad y especificidad. Una

vez elegido, el corte se congela y se aplica al grupo de prueba sin moverlo. Si lo ajustáramos mirando el grupo de prueba, las cifras serían optimistas y no reflejarían lo que pasaría con pacientes nuevos.

2.8.5 Intervalos de confianza por bootstrap

Una sensibilidad de 0.840 medida en 550 infartos no es un valor exacto: con otros 550 infartos podría salir 0.82 o 0.86. El **intervalo de confianza del 95 %** indica el rango razonable del valor real. Lo estimamos con el método **bootstrap** (Efron y Tibshirani, 1993): tomamos al azar, con reemplazo, una muestra del mismo tamaño que el grupo de prueba, calculamos la métrica, repetimos el proceso 1 000 veces y nos quedamos con los percentiles 2.5 y 97.5 de los resultados. Es como repetir el experimento mil veces con pacientes "parecidos" sin tener que conseguir pacientes nuevos.

2.9 Digitalización de electrocardiogramas impresos

Digitalizar un electrocardiograma impreso significa recuperar, a partir de una imagen, la lista de valores de voltaje a lo largo del tiempo. Para una persona la tarea parece trivial: vemos la línea negra sobre la cuadrícula rosa y la seguimos con la vista. Para una computadora implica resolver varios problemas encadenados:

- **Encontrar la hoja** dentro de la foto y corregir la perspectiva si la foto se tomó en ángulo.
- **Enderezarla**, porque un escaneo puede quedar ligeramente girado.
- **Calibrar:** medir cuántos píxeles mide un milímetro de la cuadrícula, para poder convertir distancias en milisegundos y alturas en milivoltios.
- **Separar el trazo del fondo:** distinguir la línea del electrocardiograma de la cuadrícula, del texto y de las sombras.
- **Seguir la línea** columna por columna, incluso cuando se cruza con otra derivación o se interrumpe.
- **Ubicar cada derivación** según la posición que ocupa en el formato de la hoja.

Para estas tareas se usan técnicas de **visión por computadora**, como la detección de bordes y líneas, las transformaciones geométricas y el análisis de colores, junto con algoritmos de optimización como la **programación dinámica**, que permite encontrar el camino más probable de la línea a través de la imagen considerando toda la columna de una vez y no solo el píxel más oscuro.

2.10 Herramientas de software utilizadas

Todo el proyecto se desarrolló con herramientas de código abierto. La tabla siguiente resume cada una y para qué se usó.

Tabla 4. *Herramientas de software del proyecto.*

Herramienta	Para qué la usamos
Python 3.13	Lenguaje principal del modelo, los scripts y el servidor
PyTorch (Paszke et al., 2019)	Definir, entrenar y ejecutar la red ResNet1D; calcular Grad-CAM
NumPy y pandas	Manejo de arreglos numéricos y tablas de metadatos
SciPy	Filtros Butterworth, remuestreo y detección de picos
scikit-learn	Curvas ROC, áreas bajo la curva y particiones estratificadas
wfdb	Lectura de registros en formato WFDB de PhysioNet
OpenCV	Visión por computadora en la digitalización de hojas
PyMuPDF	Convertir páginas PDF en imágenes de 300 ppp
Matplotlib	Gráficas de resultados y generación de hojas sintéticas
FastAPI y Uvicorn	Servidor web y API del sistema
SQLAlchemy y SQLite	Base de datos del historial de análisis
HTML, CSS y JavaScript	Interfaz web, gráficos del trazo y vista tridimensional de la red
Git y GitHub	Control de versiones y publicación de la demostración en GitHub Pages
Visual Studio Code / Cursor	Entorno de desarrollo

El entrenamiento se realizó en una computadora con tarjeta gráfica compatible con CUDA, lo que reduce cada época de varios minutos a unos cuantos segundos. La inferencia, es decir, analizar un electrocardiograma ya con el modelo entrenado, funciona también en una computadora sin tarjeta gráfica en menos de un par de segundos para una señal digital.

2.11 Consideraciones éticas

Trabajar con datos de salud implica responsabilidades. Todas las bases que usamos son públicas, están anonimizadas por sus autores y se distribuyen con licencias que permiten su uso en investigación. El sistema no pide ni guarda el nombre, la edad ni ningún dato que identifique al paciente: el historial almacena solo el nombre del archivo, el resultado, la probabilidad y la fecha.

También existe el riesgo de sesgo. PTB-XL proviene de un solo país y de equipos de una sola marca; las anotaciones fueron hechas por cardiólogos con su propio criterio. Un modelo entrenado con esos datos puede funcionar peor con poblaciones distintas. La validación externa del Capítulo III busca precisamente medir ese riesgo.

Por último, hay un riesgo de mal uso: que alguien tome la respuesta del sistema como un diagnóstico definitivo. Por eso la interfaz repite en varios lugares que se trata de una

herramienta de apoyo, muestra siempre las limitaciones y expresa el resultado como “patrón compatible” y no como “el paciente tiene un infarto”.

Capítulo III. Desarrollo y resultados

Este capítulo cuenta cómo se construyó CardiologIA y qué tan bien funciona. Lo hemos ordenado siguiendo el camino que recorre un electrocardiograma dentro del sistema: primero definimos qué debía hacer el sistema y cómo íbamos a trabajar; después preparamos los datos, diseñamos y entrenamos la red, y resolvimos cómo leer archivos digitales y hojas impresas; luego construimos la explicación visual, el servidor y la interfaz. La segunda mitad del capítulo presenta los resultados, desde el grupo de prueba de PTB-XL hasta bases de datos de otros países, y termina con las limitaciones y los productos entregables.

3.1 Análisis de requerimientos

Antes de escribir una sola línea de código definimos qué debía hacer el sistema. Partimos del objetivo general del anteproyecto y de una pregunta práctica: ¿qué necesita un médico que tiene un electrocardiograma en la mano y quiere una segunda opinión? Las respuestas se tradujeron en requerimientos funcionales, que describen lo que el usuario puede hacer, y no funcionales, que describen las cualidades que debe tener el sistema. Varias de ellas se agregaron a mitad del proyecto, cuando las pruebas mostraron necesidades que no habíamos previsto, como la lectura de hojas impresas o la detección de la frecuencia de muestreo.

3.1.1 Requerimientos funcionales

Tabla 5. *Requerimientos funcionales del sistema.*

Clave	Requerimiento	Criterio de aceptación
RF-01	Cargar un electrocardiograma digital	Acepta registros WFDB (.hea y .dat juntos), .csv, .txt y .npy con 12 derivaciones
RF-02	Cargar un electrocardiograma impreso	Acepta .pdf, .png y .jpg de hojas en formato 3 × 4 a 25 mm/s, con o sin tira de ritmo
RF-03	Detectar la frecuencia de muestreo	Usa la cabecera, una columna de tiempo o una estimación fisiológica; permite forzarla manualmente
RF-04	Clasificar el electrocardiograma	Devuelve “compatible con IAM” o “sin patrón de IAM”, la probabilidad y el punto de corte usado
RF-05	Indicar la certeza de la predicción	Clasifica la certeza en alta, media o baja según la distancia al punto de corte
RF-06	Mostrar el trazo con el mapa Grad-CAM	Dibuja las derivaciones con un fondo cuya intensidad indica la influencia en la decisión
RF-07	Relacionar el mapa con el latido	Reparte la activación entre onda Q, segmento ST y onda T y lista los segmentos más activos
RF-08	Informar sobre la digitalización	Para hojas impresas muestra cobertura, concordancia de la tira de ritmo y correcciones aplicadas
RF-09	Mostrar un caso de ejemplo	Carga un electrocardiograma de PTB-XL con su diagnóstico de referencia sin subir archivos
RF-10	Guardar y mostrar el historial	Registra fecha, archivo, resultado, probabilidad y zona; muestra los análisis recientes

Clave	Requerimiento	Criterio de aceptación
RF-11	Mostrar desempeño y limitaciones	Despliega las métricas del modelo usado y las advertencias de uso
RF-12	Rechazar entradas inválidas	Informa con un mensaje claro si el archivo no tiene 12 derivaciones, es muy corto o no se pudo digitalizar

3.1.2 Requerimientos no funcionales

Tabla 6. *Requerimientos no funcionales del sistema.*

Clave	Requerimiento	Cómo se atiende
RNF-01	Desempeño clínico mínimo	Sensibilidad y especificidad de al menos 0.85 y AUC-ROC alto, medidos en datos no vistos
RNF-02	Tiempo de respuesta	Una señal digital se analiza en uno o dos segundos; una hoja impresa en pocos segundos
RNF-03	Usabilidad	Interfaz de una sola página, arrastrar y soltar, mensajes en lenguaje clínico claro
RNF-04	Transparencia	Cada resultado se acompaña de su explicación visual, su certeza y las limitaciones del modelo
RNF-05	Privacidad	No se solicitan ni se guardan datos personales del paciente
RNF-06	Portabilidad	Funciona en Windows, Linux o macOS con Python; no requiere tarjeta gráfica para analizar
RNF-07	Reproducibilidad	Semillas fijas, scripts para cada etapa y resultados guardados en archivos JSON
RNF-08	Mantenibilidad	Código modular separado en modelo, servidor e interfaz, con nombres en español
RNF-09	Seguridad de uso	Avisos visibles de que el sistema no sustituye al médico ni es un dispositivo certificado

3.1.3 Usuarios del sistema

Identificamos tres perfiles de usuario. El **médico general** quiere una respuesta rápida y una idea de cuánto confiar en ella. El **estudiante de medicina** quiere entender en qué partes del trazo se fijó el sistema para compararlas con su propia lectura. El **cardiólogo** quiere saber cuántos infartos deja pasar el sistema y cuántas falsas alarmas genera antes de considerarlo. La interfaz se diseñó para estos tres perfiles: el resultado principal es breve y visible, y el detalle técnico está disponible en paneles que se despliegan a petición.

3.2 Metodología de desarrollo

Un proyecto que combina un modelo de inteligencia artificial con una aplicación de software no se puede planear completo desde el inicio. No sabíamos qué tan bien funcionaría la primera red, qué problemas aparecerían al leer archivos reales ni cuánto tiempo tomaría el entrenamiento. Por eso trabajamos con una **metodología iterativa e incremental**: en cada

ciclo construíamos una versión que funcionara de punta a punta, la medíamos, identificábamos su principal debilidad y la atacábamos en el siguiente ciclo.

Para la parte del modelo seguimos las fases del proceso CRISP-DM, un estándar de la industria para proyectos de ciencia de datos: entender el problema, entender los datos, prepararlos, modelar, evaluar y desplegar. Para la parte de software aplicamos prácticas de desarrollo ágil: tareas pequeñas, control de versiones con Git, revisiones con los asesores y pruebas después de cada cambio.

3.2.1 Fases del proyecto

Tabla 7. *Fases del proyecto y actividades principales.*

Fase	Actividades	Producto
1. Comprensión del problema	Revisión de literatura, entrevistas con asesores, redacción del anteproyecto	Objetivos y alcance aprobados
2. Comprensión de los datos	Descarga de PTB-XL, exploración de diagnósticos, calidad y demografía	Resumen de caracterización del conjunto
3. Preparación de los datos	Etiquetado binario, filtrado, normalización, partición por pliegues	Arreglos listos para entrenar
4. Modelado	Diseño de la ResNet1D, aumento de datos, entrenamiento y experimentos	Modelo entrenado y su historial
5. Evaluación	Elección del corte, métricas con intervalos, comparación con objetivos	Métricas, curvas y matriz de confusión
6. Explicabilidad	Grad-CAM 1D y asociación con zonas del latido	Mapas y reparto Q/ST/T
7. Despliegue	Servidor FastAPI, base de datos, interfaz web, demostración pública	Aplicación CardiologIA
8. Ampliaciones	Detección de frecuencia, ECG impresos, validación externa	Digitalizador, modelo impreso y resultados externos
9. Documentación	Informe técnico, manual de uso y anexos	Este documento

3.2.2 Cronología del desarrollo

El historial del repositorio permite reconstruir con precisión cuándo se incorporó cada parte. La tabla siguiente resume los hitos principales a partir de los registros de Git.

Tabla 8. *Hitos del desarrollo según el historial del repositorio.*

Fecha	Hito
Agosto de 2026	Inicio de la residencia, anteproyecto, revisión de literatura y exploración de PTB-XL
6 de septiembre	Primera versión del repositorio: preprocesamiento, ResNet1D, entrenamiento y API inicial
11 de septiembre	Publicación de la demostración estática en GitHub Pages
26 de septiembre	Interfaz y evaluación completas; reentrenamiento; resultados en lenguaje claro; terminología médica; detección automática de frecuencia; lectura de ECG impresos

Fecha	Hito
27 de septiembre	Ajuste del modelo de ECG impresos con documentos digitalizados y corrección del digitalizador
29 de septiembre	Limpieza del proyecto, resultados separados por modelo, vista oculta de la red y descarga de bases externas
30 de septiembre	Validación externa en las bases de Georgia, SPH, PTB y Mendeley
25 de octubre	Alineación del ECG impreso con la hoja y experimentos de entrenamiento por épocas completas
25 de octubre (tarde)	Ajuste del modelo de impresos con las 928 fotografías reales de Mendeley; la aplicación pasa a usar ese modelo para fotografías JPG y conserva el anterior para PDF y PNG
Noviembre de 2026	Redacción del informe técnico y preparación de la entrega

3.2.3 Organización del trabajo

El trabajo se repartió entre los dos integrantes del equipo según las fortalezas de cada uno, pero todas las decisiones importantes se tomaron en conjunto y cada parte fue revisada por ambos. Las reuniones con los asesores sirvieron para validar el enfoque, revisar los resultados y, en más de una ocasión, cuestionar cifras que parecían demasiado buenas. Varias de las mejoras del proyecto, como el uso de intervalos de confianza o la validación externa, surgieron de esas conversaciones.

3.3 Arquitectura general del sistema

Antes de entrar al detalle conviene ver el sistema completo. CardiologIA tiene tres grandes piezas que se comunican entre sí:

- **La interfaz web**, que corre en el navegador del usuario. Es la página donde se sube el archivo y se ven los resultados.
- **El servidor**, escrito en Python con FastAPI. Recibe el archivo, decide si es una señal digital o una hoja impresa, lo prepara, ejecuta la red neuronal, calcula la explicación y guarda el análisis en la base de datos.
- **El módulo de inteligencia artificial**, que contiene la red, el preprocesamiento, el digitalizador, la explicabilidad y las herramientas de evaluación. El servidor lo usa como una biblioteca.

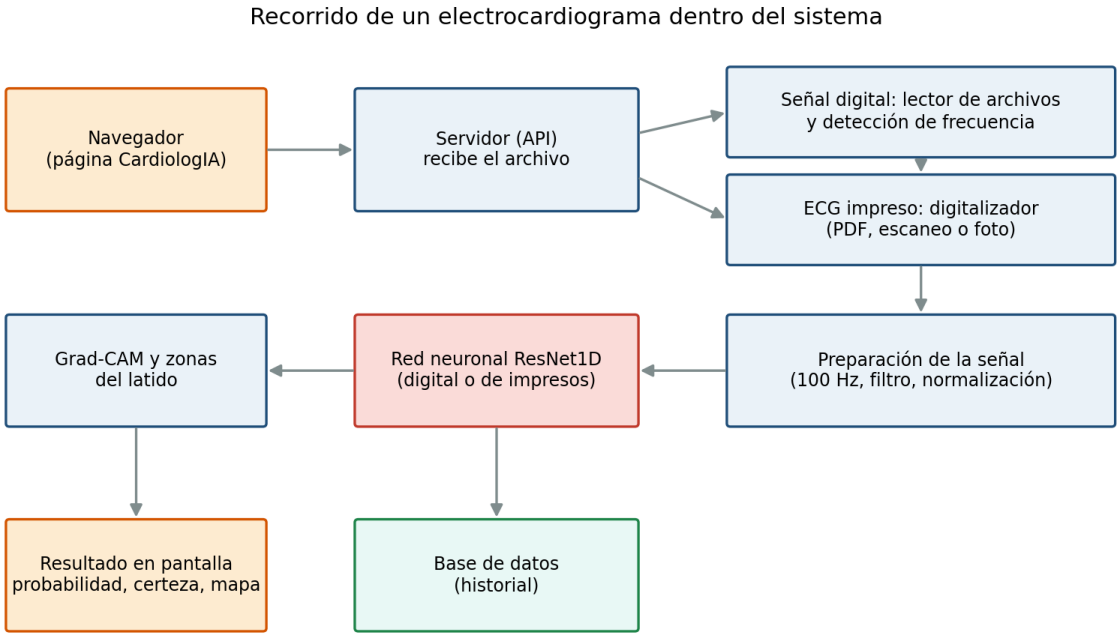


Figura 8. *Recorrido de un electrocardiograma dentro del sistema, desde que se sube en el navegador hasta que se muestra el resultado.*

Esta separación tiene ventajas prácticas. El módulo de inteligencia artificial se puede usar desde scripts sin levantar el servidor, lo que nos permitió entrenar y evaluar con los mismos componentes que usa la aplicación. Y la interfaz se puede publicar como página estática con casos precalculados, como hicimos en GitHub Pages, para que cualquiera la vea sin instalar nada.

3.4 Preparación del conjunto de datos

3.4.1 PTB-XL en números

PTB-XL (Wagner et al., 2020) es, hasta ahora, uno de los conjuntos públicos de electrocardiogramas clínicos más grandes y mejor documentados. Los registros fueron tomados entre 1989 y 1996 con equipos Schiller AG en Alemania y anotados por hasta dos cardiólogos. Usamos la versión 1.0.3, publicada en PhysioNet (Goldberger et al., 2000). Nuestro script de exploración arrojó las siguientes cifras:

Tabla 9. *Características generales de PTB-XL versión 1.0.3.*

Característica	Valor
Registros	21 799 electrocardiogramas de 10 segundos y 12 derivaciones
Pacientes	18 869
Frecuencias disponibles	500 Hz y una versión reducida a 100 Hz
Edad	Media 62.8 años; mediana 62 años

Característica	Valor
Sexo	11 354 hombres y 10 445 mujeres
Etiquetas revisadas por una persona	16 056 registros
Partición recomendada	10 pliegues estratificados; ningún paciente aparece en dos pliegues

Cada registro puede tener varios diagnósticos, codificados con el estándar SCP-ECG. Los autores agruparon esos diagnósticos en cinco superclases: normal (NORM), infarto (MI), cambios del ST-T (STTC), trastornos de la conducción (CD) e hipertrofia (HYP). Un mismo registro puede pertenecer a varias superclases a la vez; por ejemplo, un paciente con un infarto y un bloqueo de rama aparece en MI y en CD.

Tabla 10. *Registros de PTB-XL por superclase diagnóstica (un registro puede tener varias).*

Superclase	Significado	Registros	Porcentaje
NORM	Electrocardiograma normal	9 514	43.6 %
MI	Infarto de miocardio (agudo o antiguo)	5 469	25.1 %
STTC	Cambios del segmento ST y la onda T	5 235	24.0 %
CD	Trastornos de la conducción	4 898	22.5 %
HYP	Hipertrofia	2 649	12.2 %

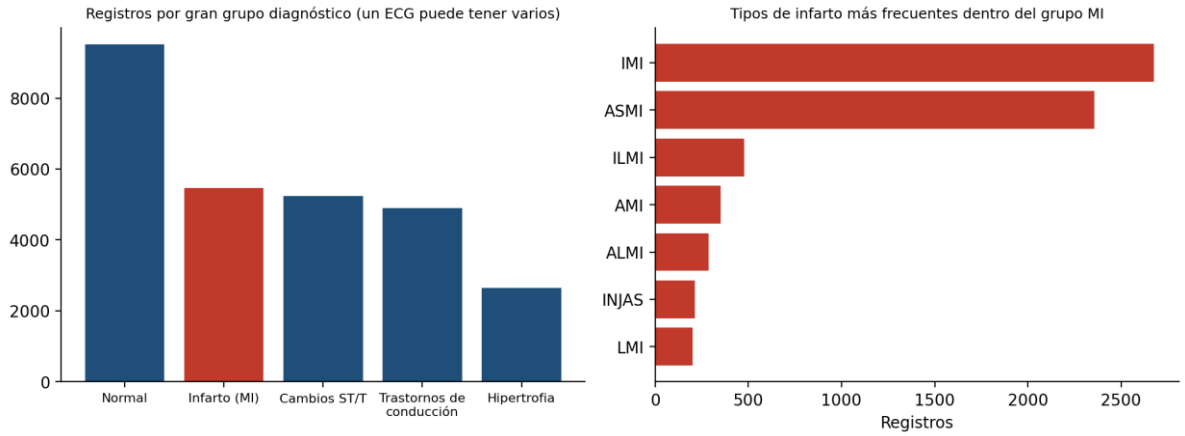


Figura 9. *Distribución de PTB-XL por superclase diagnóstica y por edad y sexo.*

Dentro de la superclase de infarto hay subtipos según la región afectada. Los más frecuentes son el infarto inferior y el anteroseptal, como se ve en la tabla siguiente. El modelo no distingue entre ellos: todos cuentan como positivos.

Tabla 11. *Subtipos de infarto más frecuentes en PTB-XL.*

Código	Región	Registros
IMI	Inferior	2 676
ASMI	Anteroseptal	2 357
ILMI	Inferolateral	478
AMI	Anterior	353
ALMI	Anterolateral	288

Código	Región	Registros
INJAS	Lesión subendocárdica anteroseptal	214
LMI	Lateral	201

3.4.2 Calidad de la señal

PTB-XL incluye anotaciones sobre problemas técnicos de cada registro. Conocerlas nos ayudó a entender qué tan "limpios" son los datos y a decidir si debíamos descartar registros:

Tabla 12. *Problemas de calidad anotados en PTB-XL.*

Problema	Porcentaje de registros
Ruido estático	15.0 %
Latidos extra (extrasístoles)	8.9 %
Deriva de la línea base	7.3 %
Ruido en ráfagas	2.8 %
Marcapasos	1.3 %
Problemas de electrodos	0.14 %

Decidimos **no descartar** registros por estas anotaciones. En un servicio de urgencias los electrocardiogramas también tienen ruido, latidos extra y derivas, y queremos que el modelo aprenda a funcionar con ellos. El filtrado y el aumento de datos se encargan de reducir el efecto del ruido.

3.4.3 Definición de la etiqueta

Convertimos el problema en una pregunta de sí o no: un registro se marca como **positivo (IAM)** si tiene al menos un diagnóstico SCP cuya clase sea MI, y como **negativo** en cualquier otro caso. Esto significa que el grupo negativo no son solo electrocardiogramas normales, sino también registros con bloqueos, hipertrofias o cambios del ST-T por otras causas. Esta decisión hace la tarea más difícil, pero más realista: en la práctica, el sistema debe distinguir un infarto de todo lo demás, no solo de un corazón sano.

Esta definición tiene una consecuencia que conviene repetir: la superclase MI incluye infartos antiguos. Por eso, aunque el proyecto habla de "infarto agudo", lo que el modelo aprende en sentido estricto es a reconocer **patrones electrocardiográficos de infarto**, recientes o antiguos.

3.4.4 Partición por pacientes

Respetamos la partición oficial de PTB-XL, que asegura que todos los registros de un paciente queden en el mismo pliegue. Los pliegues 9 y 10 contienen solo registros cuyas

etiquetas fueron revisadas por una persona, por lo que son los más confiables; los autores recomiendan usarlos para validación y prueba.

Tabla 13. *Partición de PTB-XL utilizada en el proyecto.*

Grupo	Pliegues	Registros	Con IAM	Sin IAM	Uso
Entrenamiento	1 a 8	17 418	4 379	13 039	Aprender los pesos
Validación	9	2 183	540	1 643	Parada temprana y punto de corte
Prueba	10	2 198	550	1 648	Medición final, una sola vez
Total		21 799	5 469	16 330	

La preparación no tuvo que descartar ningún registro: los 21 799 se leyeron correctamente, tenían 12 derivaciones y valores válidos. Esto cumple de sobra el primer objetivo específico, que pedía conservar al menos el 90 % de los registros.

3.4.5 Desbalance de clases

En entrenamiento hay aproximadamente tres registros sin infarto por cada uno con infarto. Si no hacemos nada, la red aprende que responder "sin infarto" es casi siempre buena idea. Para compensarlo, en la función de pérdida le damos más peso a los errores en la clase minoritaria: cada error en un infarto cuenta 1.989 veces y cada error en un registro sin infarto cuenta 0.668 veces. Estos pesos se calculan con la proporción de cada clase en el grupo de entrenamiento.

3.5 Preprocesamiento de la señal

El preprocesamiento convierte cualquier electrocardiograma, venga de donde venga, en exactamente el mismo formato: una tabla de 12 derivaciones por 1 000 muestras, es decir, 10 segundos a 100 Hz, filtrada y normalizada. Los pasos son los mismos durante el entrenamiento y cuando el sistema analiza un archivo nuevo; si no lo fueran, la red recibiría en producción algo distinto de lo que vio al aprender.

1. **Lectura:** se lee el registro y se verifica que tenga 12 derivaciones en el orden estándar (I, II, III, aVR, aVL, aVF, V1–V6) y que sus valores sean números válidos.
2. **Duración mínima:** si dura menos de 5 segundos, se rechaza con un mensaje, porque no habría latidos suficientes para analizar.
3. **Remuestreo:** si la frecuencia no es 100 Hz, se convierte a 100 Hz con un remuestreo polifásico, que evita distorsionar la señal.

4. **Filtrado:** filtro Butterworth de orden 3 entre 0.5 y 40 Hz, aplicado hacia adelante y hacia atrás.
5. **Normalización:** a cada derivación se le resta su media y se divide entre su desviación estándar; después se recortan los valores extremos.
6. **Ajuste a 10 segundos:** si la señal es más larga, se toman los primeros 10 segundos (1 000 muestras); si es más corta, se completa con ceros al final, que tras la normalización equivalen al valor medio de la señal.

En hojas impresas el paso de filtrado cambia un poco. Cada derivación solo tiene un tramo de 2.5 segundos, demasiado corto para que el filtro de 0.5 Hz se estabilice. Para esos tramos se elimina la tendencia lineal y se aplica solo la parte de pasa-bajas; los tramos de 10 segundos, como la tira de ritmo, se filtran igual que una señal digital. Los momentos en que una derivación no está impresa se rellenan con ceros, que tras la normalización equivalen a "sin información".

3.6 Lectura de archivos y detección de la frecuencia de muestreo

Un sistema útil tiene que aceptar los archivos que la gente realmente tiene. Por eso el servidor reconoce varios formatos y, cuando el archivo no dice a qué frecuencia se grabó, la estima.

Tabla 14. *Formatos de entrada aceptados por el sistema.*

Formato	Contenido esperado	¿Cómo se obtiene la frecuencia?
WFDB (.hea + .dat)	Registro de PhysioNet; deben subirse ambos archivos	Siempre de la cabecera (.hea)
CSV / TXT	12 columnas, una por derivación; opcionalmente una columna de tiempo	Columna de tiempo, valor declarado o estimación
NPY	Arreglo de NumPy de 12 × N o N × 12	Valor declarado o estimación
PDF	Hoja exportada por el electrocardiógrafo en formato 3 × 4	No aplica: se mide en el papel (25 mm/s)
PNG / JPG	Escaneo o fotografía de la hoja	No aplica: se mide en el papel (25 mm/s)

3.6.1 ¿Por qué hace falta estimar la frecuencia?

Al probar el sistema con archivos CSV exportados desde distintas fuentes descubrimos que muchos no traen ningún dato sobre su frecuencia. Al principio el sistema suponía que todo archivo duraba 10 segundos, pero esa suposición fallaba con registros más largos o más cortos y, peor aún, fallaba en silencio: el sistema daba un resultado aunque la señal estuviera deformada. Decidimos resolverlo con una idea basada en la fisiología.

3.6.2 La idea: solo una frecuencia da un corazón creíble

El razonamiento es el siguiente. Aunque no sepamos la frecuencia, podemos medir en el archivo cuántas muestras hay entre un latido y el siguiente (el intervalo RR) y cuántas muestras dura el complejo QRS. Esas medidas, en muestras, no dependen de la frecuencia. Después probamos cada frecuencia candidata habitual (100, 250, 500 y 1000 Hz) y convertimos las medidas a unidades fisiológicas. Solo la frecuencia correcta producirá un ritmo cardiaco y un ancho de QRS creíbles.

Por ejemplo, si entre latido y latido hay 415 muestras, a 500 Hz el corazón latiría a 72 latidos por minuto, un valor normal; a 100 Hz serían 14 latidos por minuto, algo incompatible con la vida en reposo, y a 1000 Hz serían 145, una taquicardia. Si además el QRS mide 45 muestras, a 500 Hz duraría 90 ms (normal) y a 100 Hz duraría 450 ms (imposible).

Para que la elección sea objetiva, medimos en los pliegues de entrenamiento de PTB-XL las distribuciones reales de frecuencia cardiaca y de ancho de QRS (medianas de 72 latidos por minuto y 40 ms, según nuestro método de medición). Cada candidata recibe una puntuación según qué tan probable es su ritmo y su QRS bajo esas distribuciones, con una pequeña preferencia por la duración estándar de 10 segundos. Gana la candidata con mayor puntuación. Si la ventaja sobre la segunda es pequeña, el sistema muestra un aviso de **baja certeza** y sugiere indicar la frecuencia manualmente en las opciones avanzadas.

El sistema reporta siempre el **origen** de la frecuencia utilizada, para que el usuario sepa de dónde salió: “cabecera” (archivo WFDB), “declarada” (el usuario la indicó), “columna de tiempo” (calculada a partir de los tiempos del CSV), “estimada” (método fisiológico) o “papel” (hojas impresas, a 25 mm/s).

3.6.3 Evaluación del estimador

Para medir el estimador tomamos los registros del pliegue 10, que no se usó para ajustar las distribuciones, los convertimos a las cuatro frecuencias y los recortamos a 7, 10 y 20 segundos. En total se hicieron 3 600 pruebas. El estimador acertó la frecuencia en el **95.6 %** de ellas. El aviso de baja certeza se activó en alrededor del 9 % de los casos, que concentraban cerca de dos tercios de los errores; es decir, cuando el sistema se equivoca, casi siempre lo advierte.

Tabla 15. *Porcentaje de aciertos del estimador de frecuencia según la frecuencia real y la duración del registro.*

Frecuencia real	7 segundos	10 segundos	20 segundos

Frecuencia real	7 segundos	10 segundos	20 segundos
100 Hz	100 %	99.7 %	99.7 %
250 Hz	98.0 %	98.0 %	92.0 %
500 Hz	93.7 %	95.0 %	86.0 %
1000 Hz	94.0 %	96.0 %	94.7 %

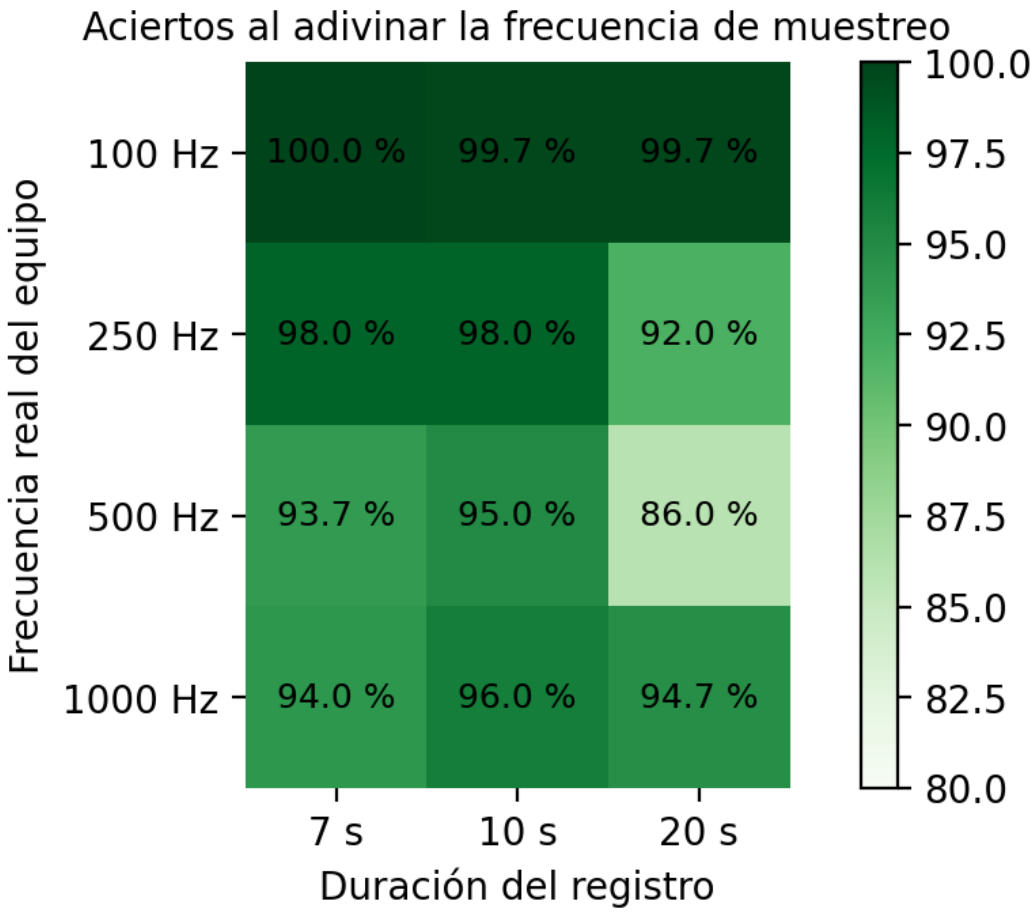


Figura 10. *Aciertos del estimador de frecuencia de muestreo por frecuencia real y duración del registro (3 600 pruebas en el pliegue 10).*

Los errores se concentran en registros con ritmos poco habituales, como frecuencias cardiacas muy altas o muy bajas, o con QRS anchos por bloqueos de rama, donde dos candidatas pueden dar valores fisiológicos aceptables. Para esos casos el aviso y la opción de forzar la frecuencia son la salida adecuada.

3.7 Diseño del modelo ResNet1D

La red que diseñamos sigue la estructura clásica de una ResNet-18 adaptada a señales. Se puede imaginar como una línea de producción en la que el electrocardiograma entra por un lado y, en cada estación, se resume un poco más, hasta que al final queda una sola pregunta: ¿infarto o no?

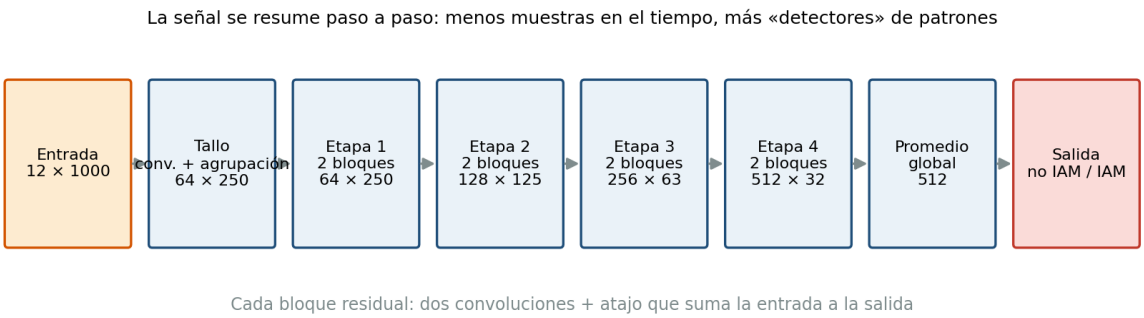


Figura 11. *Estructura de la red ResNet1D: un tallo de entrada, cuatro etapas residuales y una cabeza de clasificación.*

- **Entrada:** 12 derivaciones × 1 000 muestras.
- **Tallo:** una convolución con 64 filtros de 7 muestras y salto 2, normalización, ReLU y un agrupamiento máximo. Reduce el trazo a 250 posiciones y extrae las primeras formas simples.
- **Cuatro etapas residuales**, cada una con dos bloques. La primera mantiene 64 canales; las siguientes duplican los canales (128, 256 y 512) y reducen a la mitad la longitud (125, 63 y 32 posiciones). Así, la red cambia detalle temporal por riqueza de patrones.
- **Agrupamiento global:** promedia cada uno de los 512 canales a lo largo del tiempo. El resultado es un resumen de 512 números que describe el electrocardiograma completo.
- **Clasificador:** un dropout de 0.3 y una capa lineal que convierte esos 512 números en dos puntuaciones, una para "sin infarto" y otra para "infarto". Una función softmax las convierte en probabilidades que suman 1.

Tabla 16. *Configuración de la ResNet1D estándar.*

Componente	Configuración	Salida (canales × posiciones)
Entrada	12 derivaciones, 10 s a 100 Hz	12 × 1 000
Tallo	Conv 7, salto 2, 64 filtros + BN + ReLU + MaxPool 3/2	64 × 250
Etapa 1	2 bloques residuales, filtros de 7	64 × 250
Etapa 2	2 bloques, el primero con salto 2	128 × 125
Etapa 3	2 bloques, el primero con salto 2	256 × 63
Etapa 4	2 bloques, el primero con salto 2	512 × 32
Agrupamiento	Promedio global en el tiempo	512
Clasificador	Dropout 0.3 + capa lineal	2 (sin IAM, IAM)
Total de parámetros	8 732 290	

Dentro de cada bloque se aplica un dropout de 0.2 entre las dos convoluciones. Los pesos de las convoluciones se inicializan con el método de Kaiming, pensado para redes con ReLU, y los de la capa final con valores muy pequeños, de modo que al inicio la red no favorece a ninguna clase.

¿Por qué filtros de 7 muestras? A 100 Hz, 7 muestras equivalen a 70 ms, aproximadamente el ancho de un QRS. Como cada etapa reduce la longitud a la mitad, en la última etapa cada posición "ve" una porción de varios segundos de la señal original, suficiente para comparar varios latidos entre sí. El código también incluye una variante "ligera" (menos canales) y una "profunda" (más bloques); usamos la estándar porque fue la que mejor equilibró desempeño y tiempo de entrenamiento en nuestras primeras pruebas.

3.8 Entrenamiento del modelo

3.8.1 Aumento de datos

Para que la red no memorice los electrocardiogramas de entrenamiento, cada vez que uno se le presenta tiene un 80 % de probabilidad de ser modificado ligeramente. Las modificaciones imitan variaciones reales que ocurren al tomar un electrocardiograma:

- **Cambio de amplitud por derivación** (entre 85 % y 115 %), como si un electrodo hiciera mejor o peor contacto.
- **Ruido aleatorio** de baja intensidad, como el que agrega el amplificador del equipo.
- **Deriva de la línea base** con una onda lenta, como la que produce la respiración.
- **Desplazamiento en el tiempo** de hasta un segundo, como si el registro hubiera empezado un poco antes o después.

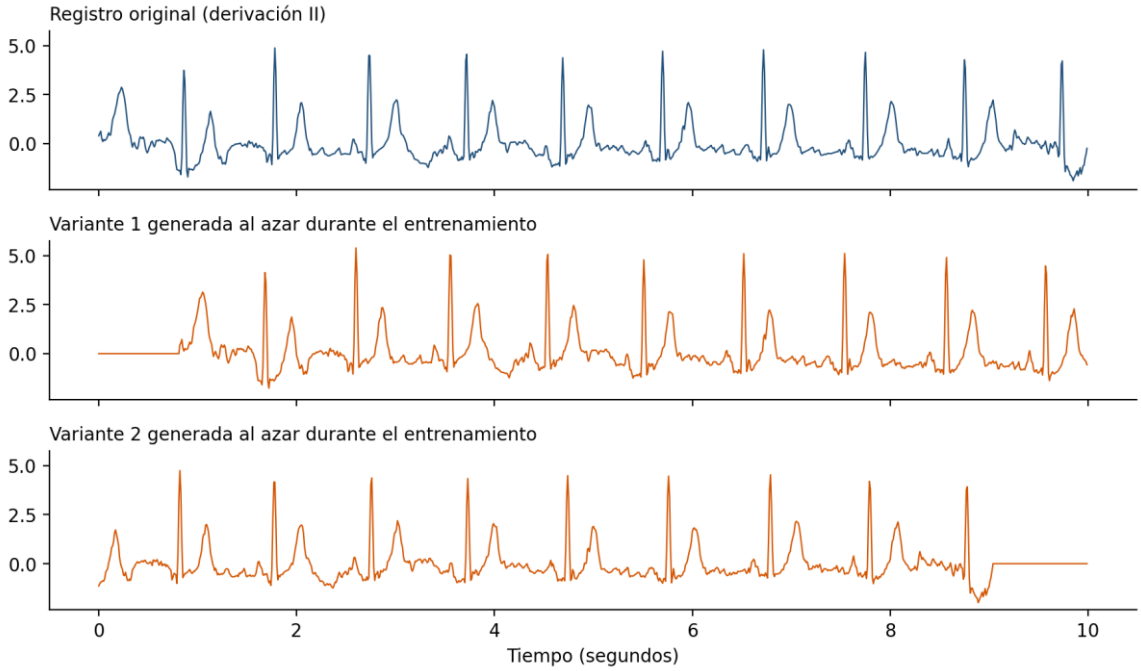


Figura 12. *Ejemplo de aumento de datos sobre la derivación II: la señal original y una versión modificada con cambio de amplitud, ruido, deriva y desplazamiento.*

Gracias a esto, en cada época la red ve versiones distintas de los mismos 17 418 electrocardiogramas. Es como estudiar con ejercicios que cambian un poco cada vez: obliga a entender el concepto y no a recordar la respuesta.

3.8.2 Configuración

Tabla 17. *Configuración del entrenamiento del modelo digital.*

Parámetro	Valor	Explicación
Optimizador	AdamW	Ajusta el paso por cada peso y aplica decaimiento de pesos
Tasa de aprendizaje inicial	0.001	Tamaño de los primeros pasos
Decaimiento de pesos	0.0001	Mantiene los pesos pequeños
Tamaño de lote	32	Electrocardiogramas por paso
Función de pérdida	Entropía cruzada con pesos 0.668 / 1.989	Compensa el desbalance de clases
Programador	Reduce a la mitad la tasa si el AUC de validación no mejora en 2 épocas	Pasos más finos al acercarse al mínimo
Máximo de épocas	30	Límite superior
Paciencia	8 épocas	Se detiene si no mejora en ese número de épocas
Criterio del mejor modelo	AUC-ROC en validación	Métrica que no depende del corte
Semilla	42	Permite repetir el experimento

3.8.3 Desarrollo del entrenamiento

El entrenamiento se detuvo en la época 20, al cumplirse ocho épocas sin mejora. El mejor modelo se obtuvo en la **época 12**, con un AUC-ROC de **0.929** en validación y una tasa de aprendizaje que para entonces se había reducido a 0.0005. En la época 20 el AUC de entrenamiento era de 0.970, ya bastante por encima del de validación: la red empezaba a memorizar y la parada temprana evitó que siguiera por ese camino.

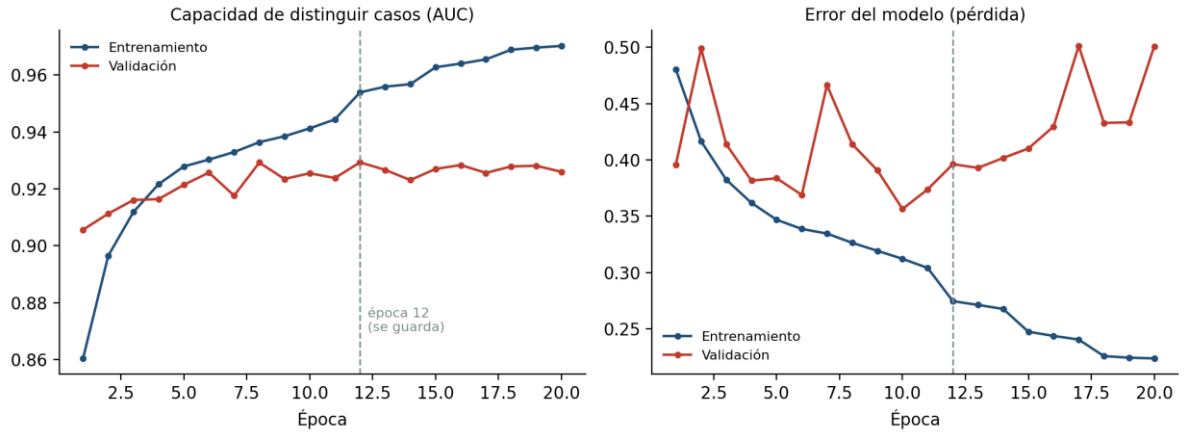


Figura 13. *Evolución de la pérdida y del AUC-ROC en entrenamiento y validación. La línea vertical marca la época 12, cuyo modelo se conservó.*

La figura muestra un patrón típico. Durante las primeras épocas ambas curvas mejoran rápido. Hacia la época 10 la curva de validación se aplana mientras la de entrenamiento sigue subiendo. La pérdida de validación, que mide qué tan seguras y correctas son las respuestas, empieza a subir ligeramente: la red se vuelve más confiada, pero no más acertada, con los casos nuevos.

3.8.4 ¿Y si entrenamos más? Experimentos de continuación

Una pregunta natural es si el modelo mejoraría con más entrenamiento. En la última etapa del proyecto modificamos el entrenador para poder completar todas las épocas pedidas sin detenerse y realizamos dos experimentos partiendo del modelo ya entrenado, con una tasa de aprendizaje diez veces menor (0.0001):

- **Continuación de 16 épocas:** el mejor AUC de validación se alcanzó en la primera época (0.9313), apenas dos milésimas por encima del modelo original, y después bajó hasta 0.9265.
- **Continuación de 100 épocas:** el mejor AUC de validación se alcanzó en la época 3 (0.9306). Al final de las 100 épocas, el AUC de entrenamiento había subido a 0.990,

mientras que el de validación había bajado a 0.910 y la pérdida de validación se había más que duplicado, de 0.42 a 1.05.

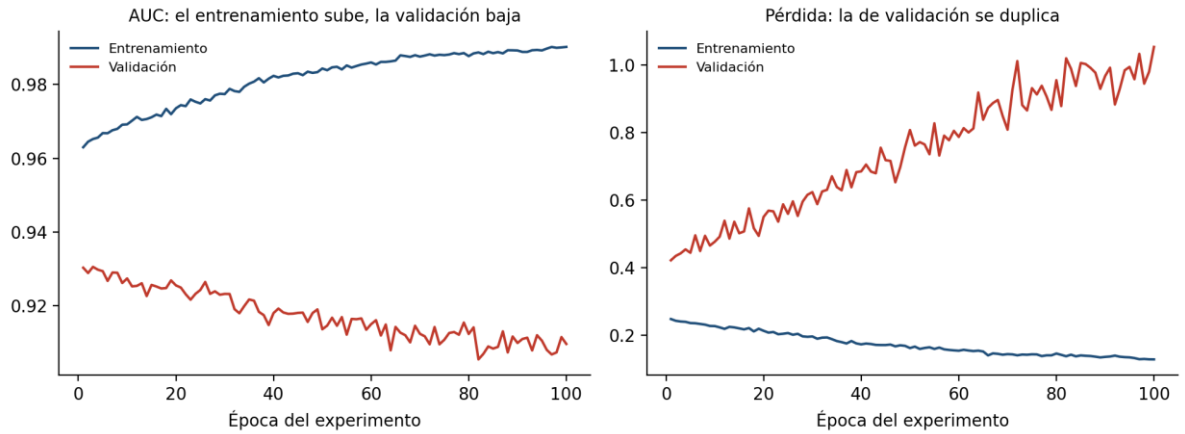


Figura 14. *Experimento de 100 épocas adicionales: el desempeño en entrenamiento sigue subiendo mientras el de validación cae. Es una ilustración clara del sobreajuste.*

Tabla 18. *Comparación del modelo adoptado con los experimentos de continuación.*

Entrenamiento	Mejor época	AUC validación (mejor)	AUC validación (final)	Decisión
Modelo base (30 máx., paciencia 8)	12 de 20	0.929	—	Adoptado
Continuación de 16 épocas	1	0.9313	0.9265	No adoptado
Continuación de 100 épocas	3	0.9306	0.9097	No adoptado

La mejora de dos milésimas de los experimentos está muy por debajo de la incertidumbre de la medición, así que no justificaba cambiar el modelo ya evaluado y documentado. Además, cambiar de modelo después de haber visto los resultados de prueba sería una forma sutil de ajustar al grupo de prueba. Por eso conservamos el modelo de la época 12 y presentamos estos experimentos como evidencia de que el modelo ya estaba cerca de su mejor punto. Los experimentos **no se evaluaron en el grupo de prueba**.

La lección del experimento de 100 épocas es valiosa por sí misma: entrenar más no siempre es mejor. Una red de casi nueve millones de parámetros puede memorizar diecisiete mil electrocardiogramas, y sin la vigilancia del grupo de validación habríamos entregado un modelo que parecía excelente en entrenamiento y que en realidad era peor con pacientes nuevos.

3.9 Elección del punto de corte

Con el modelo de la época 12 calculamos la probabilidad de infarto de cada uno de los 2 183 electrocardiogramas de validación y recorrimos todos los posibles puntos de corte. Aplicamos el criterio descrito en el Capítulo II: entre los cortes que detectan al menos 85 de cada 100

infartos, el de mayor especificidad. El resultado fue un corte de **0.3204**, con el que en validación se obtuvo una sensibilidad de 0.852 y una especificidad de 0.846, con un AUC de 0.929.

A primera vista puede extrañar que el corte esté por debajo de 0.5. La razón es que preferimos no dejar pasar infartos: con un corte de 0.5 la red detectaría menos infartos y daría menos falsas alarmas. Bajar el corte equivale a decirle al sistema "ante la duda, avisa". La interfaz explica esto al usuario junto a la escala de probabilidad.

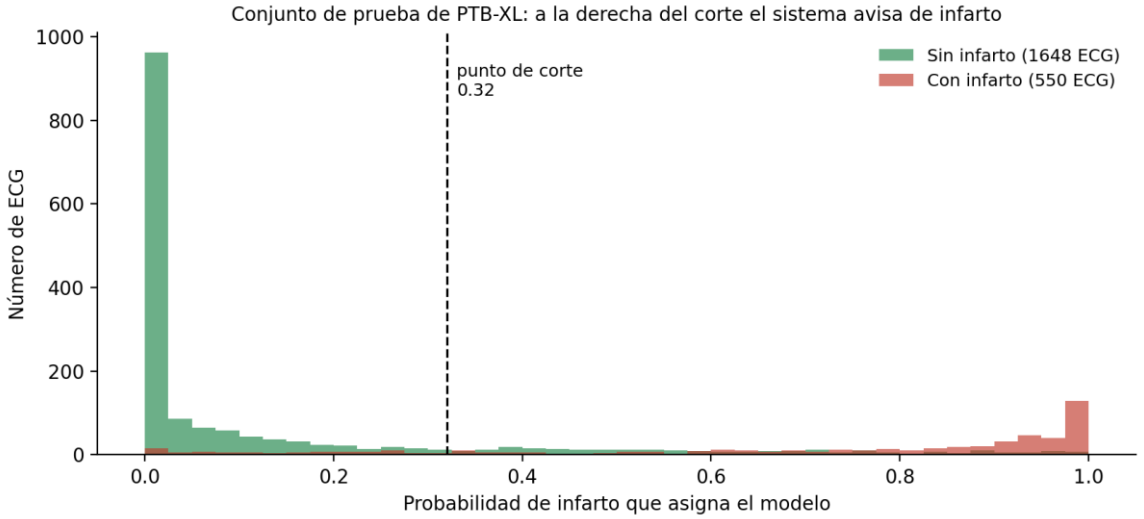


Figura 15. *Distribución de las probabilidades que asigna el modelo en el grupo de prueba, separada por diagnóstico real. La línea marca el punto de corte de 0.3204.*

La figura muestra cómo reparte el modelo sus probabilidades. La mayoría de los registros sin infarto se agrupan cerca de cero y la mayoría de los infartos cerca de uno, pero hay una zona intermedia donde ambas clases se mezclan. Ahí es donde se cometen los errores, y por eso la interfaz califica como de **certeza baja** las probabilidades cercanas al corte.

3.10 Lectura de electrocardiogramas impresos

Cuando mostramos las primeras versiones del sistema, la pregunta más frecuente fue: "¿y si solo tengo la hoja?". En muchos hospitales y consultorios el electrocardiograma se imprime, se anexa al expediente y nunca se guarda como archivo. En el mejor de los casos el equipo genera un PDF. Un sistema que solo acepta archivos de señal deja fuera a la mayoría de los usuarios. Por eso construimos un **digitalizador**: un módulo que recibe un PDF, un escaneo o una foto de la hoja, recupera los trazos y los convierte en la misma señal numérica que usa la red.

3.10.1 Supuestos del formato

Para que el problema fuera abordable, el digitalizador asume el formato más común de los electrocardiógrafos de 12 derivaciones:

- Velocidad de papel de 25 mm/s y ganancia de 10 mm/mV, con cuadrícula de 1 mm y 5 mm.
- Tres renglones en formato 3 × 4: I-aVR-V1-V4, II-aVL-V2-V5 y III-aVF-V3-V6. Cada renglón mide 250 mm, es decir, 10 segundos, y cada derivación ocupa 2.5 segundos.
- Debajo, de cero a tres tiras de ritmo de 10 segundos, normalmente de la derivación II, o de II, V1 y V5.

Estos supuestos cubren la gran mayoría de las hojas que se usan en la práctica. Otros formatos, como el 6 × 2 o el 12 × 1, quedaron fuera del alcance.

3.10.2 Paso a paso

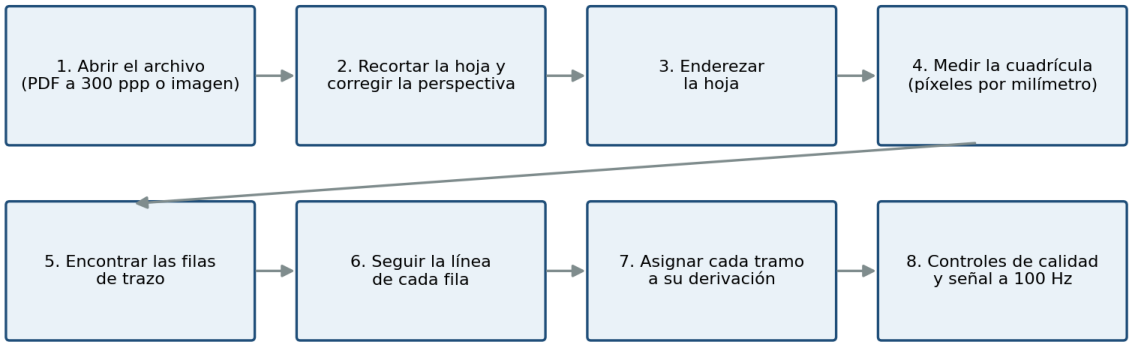


Figura 16. *Etapas del digitalizador de electrocardiogramas impresos.*

1. **Carga del documento.** Un PDF se convierte en imagen a 300 puntos por pulgada. Las imágenes PNG y JPG se cargan directamente, respetando la orientación que guarda el celular en la foto.
2. **Recorte y corrección de perspectiva.** En una foto, la hoja suele aparecer como un trapecio porque la cámara no estaba perfectamente paralela al papel. El sistema busca los bordes de la hoja, localiza sus cuatro esquinas y "aplana" la imagen para que vuelva a ser un rectángulo, como hacen las aplicaciones de escaneo del celular.
3. **Enderezado.** Detecta las líneas de la cuadrícula y mide su inclinación. Si la hoja está girada hasta 6 grados, la endereza. Si está en vertical, prueba ambas rotaciones de 90 grados y se queda con la que produce un resultado válido.

4. **Calibración.** Mide la separación entre las líneas de la cuadrícula para saber cuántos píxeles equivalen a un milímetro. Ese número es la llave para convertir la imagen en tiempo y voltaje: 1 mm horizontal son 40 ms y 1 mm vertical son 0.1 mV. Como comprobación, cada renglón detectado debe medir alrededor de 250 mm.
5. **Separación del trazo.** Distingue la línea del electrocardiograma, que es oscura y continua, del fondo cuadriculado, que suele ser rosa, rojo o gris claro, y elimina manchas pequeñas y texto.
6. **Detección de renglones.** Localiza la línea base de cada uno de los renglones de la hoja, incluidas las tiras de ritmo.
7. **Seguimiento del trazo.** Recorre cada renglón de izquierda a derecha y, en cada columna de píxeles, decide en qué altura está la línea. Usa **programación dinámica**, que en lugar de elegir columna por columna el píxel más oscuro busca el camino completo más coherente, penalizando los saltos bruscos. Así evita "brincar" a la línea de la derivación vecina cuando dos trazos se acercan.
8. **Ensamblado.** Corta cada renglón en cuatro tramos de 2.5 segundos, asigna a cada tramo su derivación según su posición, descarta el pulso de calibración del inicio y arma una tabla de 10 segundos a 100 Hz en la que cada derivación solo tiene datos en su cuarto de tiempo. Las tiras de ritmo aportan los 10 segundos completos de su derivación.
9. **Controles de calidad.** Calcula qué proporción de la señal esperada se pudo recuperar (cobertura) y compara la tira de ritmo con el tramo correspondiente de la derivación II en el renglón superior (concordancia). Si la cobertura es menor al 50 %, rechaza la hoja y pide otra imagen; si es baja o la concordancia es menor a 0.8, analiza pero muestra una advertencia.

La tira de ritmo merece un comentario. No todas las hojas indican qué derivación es, y algunas no usan la derivación II. El digitalizador compara la tira con los tramos impresos de cada derivación y le asigna la que más se parece. Este detalle resultó importante con las 928 hojas reales de Pakistán: la tira de ritmo se identificó como la derivación II en 717 hojas, como III en 182, como aVF en 18, como V6 en 10 y como V3 en una.

3.10.3 Un ejemplo completo

Para ilustrar el proceso tomamos el electrocardiograma 63 de PTB-XL, del grupo de prueba, que tiene un diagnóstico de infarto anteroseptal. Primero lo imprimimos con el mismo formato que usa un electrocardiógrafo comercial; después simulamos una foto tomada con el

celular, con perspectiva, iluminación desigual y compresión JPEG; finalmente le pasamos la foto al digitalizador.

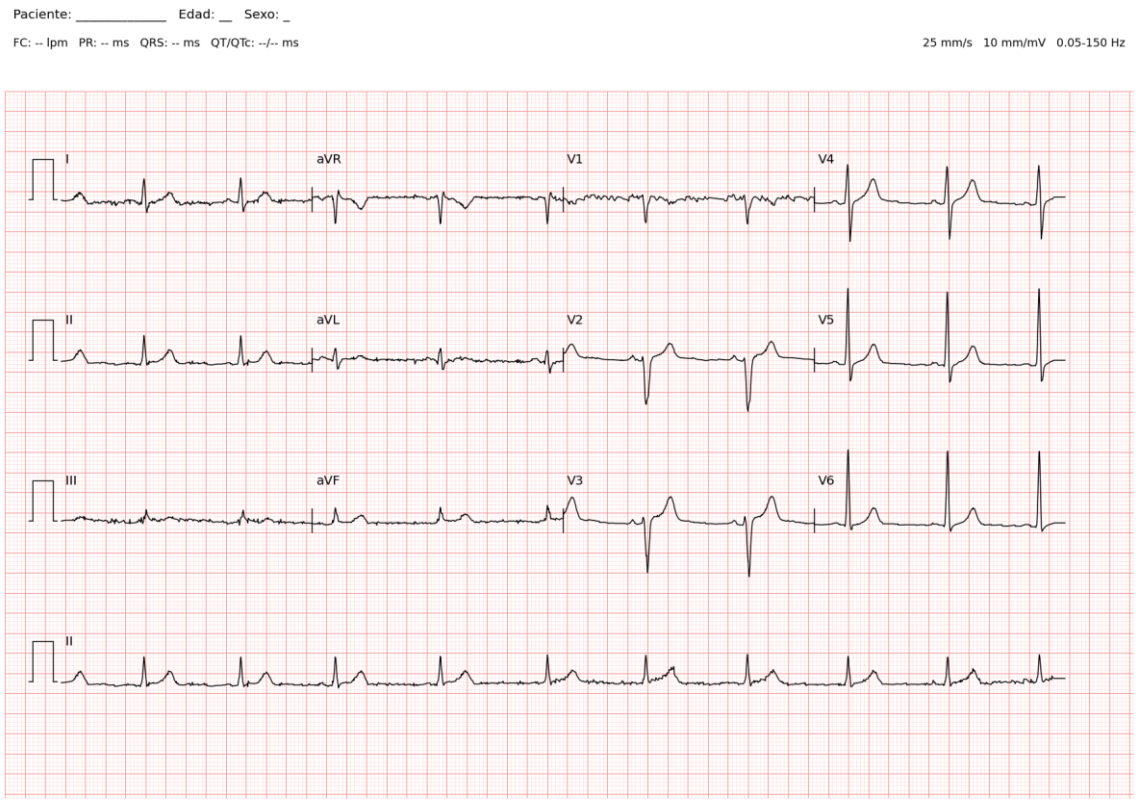


Figura 17. *Hoja impresa en formato 3 × 4 con tira de ritmo, generada a partir del electrocardiograma 63 de PTB-XL.*

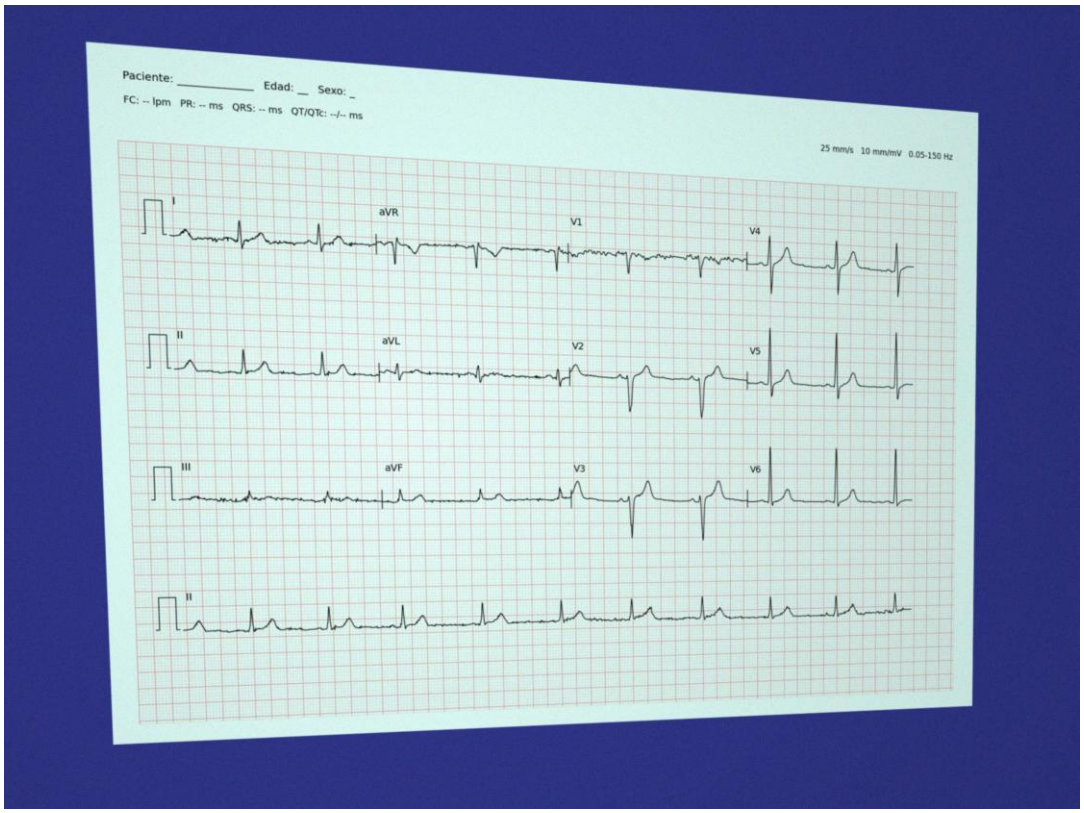


Figura 18. *La misma hoja como si se hubiera fotografiado con un celular: perspectiva, iluminación irregular y fondo.*

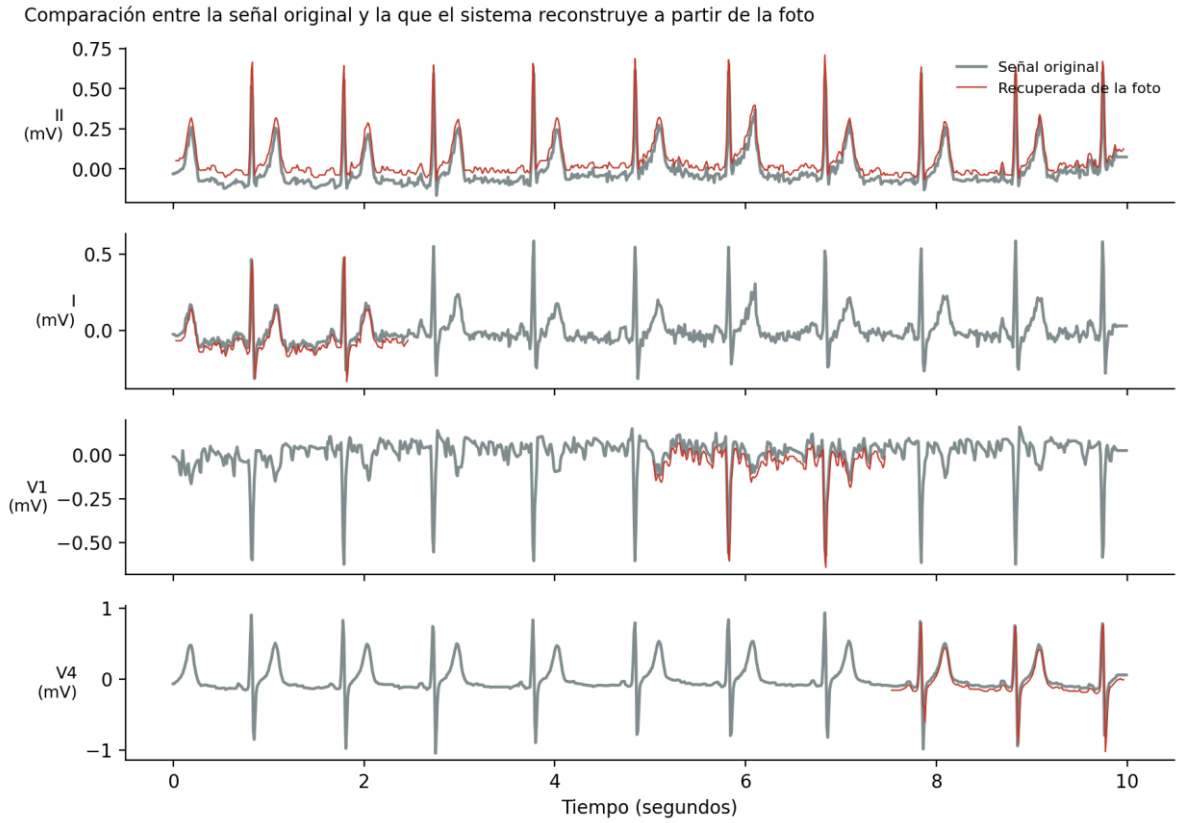


Figura 19. *Comparación entre la señal original (gris) y la recuperada por el digitalizador a partir de la foto (rojo). Cada derivación solo se recupera en su cuarto de tiempo; la derivación II se recupera completa gracias a la tira de ritmo.*

La señal recuperada sigue muy de cerca a la original, aunque con pequeñas diferencias en la altura de los picos y en la línea base. Este mismo caso sirve para mostrar algo que retomaremos en los resultados: la señal digital original obtuvo una probabilidad de infarto de 50 % y la hoja limpia de 55 %, ambas por encima del corte; la foto simulada, en cambio, obtuvo 14 % y habría sido un falso negativo. Pequeñas pérdidas de información en un caso que ya estaba cerca del límite pueden cambiar la decisión, y por eso la interfaz insiste en tomar la foto de frente, completa y sin reflejos.

3.10.4 Hojas sintéticas para entrenar y evaluar

Para entrenar y evaluar el digitalizador necesitábamos miles de hojas impresas cuya señal original conociéramos exactamente. No existe un conjunto así de gran tamaño, de modo que lo fabricamos: tomamos electrocardiogramas de PTB-XL, los "imprimimos" con un generador de hojas que varía al azar el diseño (márgenes, colores de la cuadrícula, grosor de línea, textos, número de tiras de ritmo) y después los degradamos para imitar cuatro situaciones reales:

Tabla 19. *Tipos de documento simulados para entrenar y evaluar la lectura de hojas impresas.*

Tipo	Cómo se genera	Qué imita
PDF del equipo	Hoja vectorial convertida a imagen de 300 ppp	El archivo que exporta el electrocardiógrafo
Imagen limpia	Imagen a 150, 200 o 300 ppp sin defectos	Captura de pantalla o exportación como imagen
Escaneo	Rotación de ±3°, desenfoque, ruido, 30 % en escala de grises, JPEG de calidad 60–95	Hoja pasada por un escáner o multifuncional
Foto con celular	Perspectiva, iluminación desigual, sombra, fondo y compresión JPEG	Foto tomada sobre un escritorio

3.10.5 Un modelo ajustado al papel

La red original se entrenó con señales completas: 10 segundos de las 12 derivaciones. Una hoja 3 × 4, en cambio, solo contiene 2.5 segundos de cada derivación. Al darle a la red original una señal con tres cuartas partes vacías, su desempeño bajaba, así que entrenamos una versión especializada en dos etapas:

- **Etapa 1, formato impreso.** Partimos del modelo digital y lo seguimos entrenando con las mismas señales de PTB-XL, pero ocultando en cada una lo que no aparecería en una hoja 3 × 4. Durante el entrenamiento se varió al azar el número de tiras de ritmo (sin tira en 15 % de los casos, tres tiras en 10 %), se recortaron unas muestras en los bordes de cada

tramo y se agregó un pequeño error de trazo. Con una tasa de aprendizaje de 0.0003, el mejor modelo se obtuvo en la época 5 de 11, con un AUC de validación de 0.929.

- **Etapa 2, documentos digitalizados.** Generamos 6 000 hojas de entrenamiento y 1 000 de validación con los tipos de documento de la tabla anterior, las pasamos por el digitalizador y continuamos el entrenamiento combinando esas señales digitalizadas (70 % de los ejemplos) con las simuladas de la etapa 1. Así la red aprendió los defectos reales que introduce el digitalizador. Con una tasa de 0.0001, el mejor modelo se obtuvo en la época 3 de 9, con un AUC de validación de 0.927.

El punto de corte del modelo de la etapa 2 se eligió en las hojas de validación con el mismo criterio que el modelo digital y resultó de **0.3623**, con una sensibilidad de 0.852 y una especificidad de 0.806 en validación.

3.10.6 Ajuste con hojas reales

Las hojas sintéticas tienen una limitación evidente: por variadas que sean, las fabricamos nosotros. Cuando probamos el modelo de la etapa 2 con fotografías reales de hojas de Pakistán (sección 3.18), detectó la gran mayoría de los infartos, pero marcó como sospechosas a demasiadas hojas normales. Por eso, al final del proyecto, hicimos una tercera etapa de ajuste usando esas mismas fotografías reales.

La colección de Mendeley (Khan y Hussain, 2021) tiene 928 fotografías de hojas impresas, tomadas en hospitales de Pakistán y clasificadas por sus autores en cuatro grupos: infarto (239), normal (284), antecedente de infarto (172) y latido anormal (233). Como son pocas hojas, la forma de medir tenía que ser muy cuidadosa para no evaluar al modelo con hojas que ya había visto. Usamos **validación cruzada de cinco pliegues**:

1. Las hojas de infarto y normales se repartieron en cinco grupos con la misma proporción de cada clase.
2. En cada turno, cuatro grupos sirvieron para ajustar el modelo y el quinto se guardó para medirlo. De los cuatro de ajuste, un 20 % se apartó para decidir cuándo detenerse y elegir el corte (sensibilidad mínima de 0.85 y, entre esos cortes, la mayor especificidad).
3. Las hojas de antecedente de infarto se sumaron al ajuste como positivos, pero nunca se usaron para medir. Las de latido anormal no se usaron en ningún momento, de modo que sirven como prueba independiente de falsas alarmas.
4. Cada hoja de infarto o normal recibió así una probabilidad de un modelo que no la había visto. Con esas probabilidades se calcularon las métricas.

El ajuste partió del modelo de la etapa 2, con AdamW, tasa de aprendizaje de 0.0001, lotes de 16, aumento de datos y un máximo de 25 épocas con paciencia de 6. Como hay pocas hojas, se mantuvieron fijas las estadísticas de normalización por lotes del modelo original y se limitó el tamaño de los pasos. Las mejores épocas de los cinco pliegues fueron 9, 20, 12, 24 y 7. El modelo final se entrenó con todas las hojas durante 12 épocas (la mediana) y su corte es la mediana de los cortes de los pliegues: **0.9494**.

Tabla 20. *Resultado del ajuste con hojas reales en cada pliegue de la validación cruzada.*

Pliegue	Mejor época	Corte elegido en el 20 % apartado
1	9	0.9494
2	20	0.9942
3	12	0.9459
4	24	0.9803
5	7	0.9042
Modelo final	12 (mediana)	0.9494 (mediana)

La variación entre pliegues es informativa. La mejor época va de 7 a 24, lo que indica que con tan pocas hojas el momento exacto en que conviene detenerse depende mucho de qué hojas tocaron en cada grupo. Usar la mediana, en lugar del valor de un solo pliegue, protege contra un pliegue con suerte. Los cortes, en cambio, son todos altos (de 0.90 a 0.99), lo que confirma que el modelo ajustado separa las clases con mucha seguridad y que el corte exacto cambia pocas decisiones.

Un corte de 0.95 parece muy exigente, pero en estas hojas no lo es en el sentido habitual: el modelo ajustado empuja las probabilidades hacia los extremos, de modo que casi todas las hojas quedan muy cerca de 0 o de 1. Con las hojas que el modelo no vio en cada pliegue, se escaparon 16 de 239 infartos.

3.10.7 Qué modelo usa la aplicación para cada documento

El ajuste a hojas reales mejoró mucho el desempeño en las fotografías de Pakistán, pero tuvo un costo: al medir el modelo ajustado con la vista impresa de los 2 198 electrocardiogramas de prueba de PTB-XL, su sensibilidad cayó a 0.518 y su AUC a 0.862, frente a 0.844 y 0.928 del modelo de la etapa 2. El modelo se especializó en el estilo de esas hojas y olvidó parte de lo que sabía de hojas de otro estilo. Ningún modelo era el mejor para todo, así que la aplicación usa cada uno donde mejor funciona:

Tabla 21. *Modelos utilizados por la aplicación según el tipo de entrada.*

Entrada	Modelo	Entrenamiento	Punto de corte

Entrada	Modelo	Entrenamiento	Punto de corte
Señal digital (WFDB, CSV, TXT, NPY)	ResNet1D estándar a 100 Hz	Desde cero con PTB-XL, mejor época 12	0.3204
PDF o PNG (señal digitalizada)	ResNet1D impreso digitalizado (etapa 2)	Formato 3 × 4 simulado y 6 000 hojas sintéticas digitalizadas	0.3623
Fotografía JPG de una hoja real	ResNet1D de hojas reales (etapa 3)	Etapa 2 ajustada con las 928 hojas de Mendeley	0.9494
— (solo referencia)	ResNet1D impreso, etapa 1	Formato 3 × 4 simulado, mejor época 5	—

La regla es sencilla y depende de la extensión del archivo: los JPG, que es el formato en que un celular guarda las fotografías, se analizan con el modelo de hojas reales; los PDF que exporta el equipo y las imágenes PNG se analizan con el modelo de la etapa 2. Es una regla práctica, no perfecta: una fotografía guardada como PNG usará el modelo de la etapa 2, y un JPG exportado por un equipo de otra marca usará el de hojas reales, que solo conoce el estilo de las hojas de Pakistán. Una mejora futura sería que el sistema reconociera el tipo de hoja por su contenido y no por su extensión, o entrenar un solo modelo con hojas reales de varias fuentes.

3.11 Explicabilidad

3.11.1 Implementación de Grad-CAM unidimensional

Para calcular Grad-CAM elegimos como capa objetivo la salida del último bloque residual de la cuarta etapa, justo antes del agrupamiento global. Esa capa tiene 512 canales y 32 posiciones en el tiempo. Durante el análisis se registra su salida y, al calcular la puntuación de la clase “infarto”, se registran también los gradientes que llegan a ella. Con ambos se construye el mapa:

1. Se promedian los gradientes de cada canal a lo largo del tiempo; ese promedio es el peso de importancia del canal.
2. Se multiplica cada uno de los 512 mapas por su peso y se suman.
3. Se conservan solo los valores positivos, que son los que empujan hacia “infarto”.
4. Se estira el resultado de 32 a 1 000 posiciones con interpolación lineal y se escala entre 0 y 1.

Inicialmente usábamos como capa objetivo la última convolución del bloque, antes de la suma residual. En la revisión del código detectamos que así el mapa ignoraba la información que

llega por el atajo, y lo cambiamos a la salida completa del bloque, que es lo que realmente ve el clasificador.

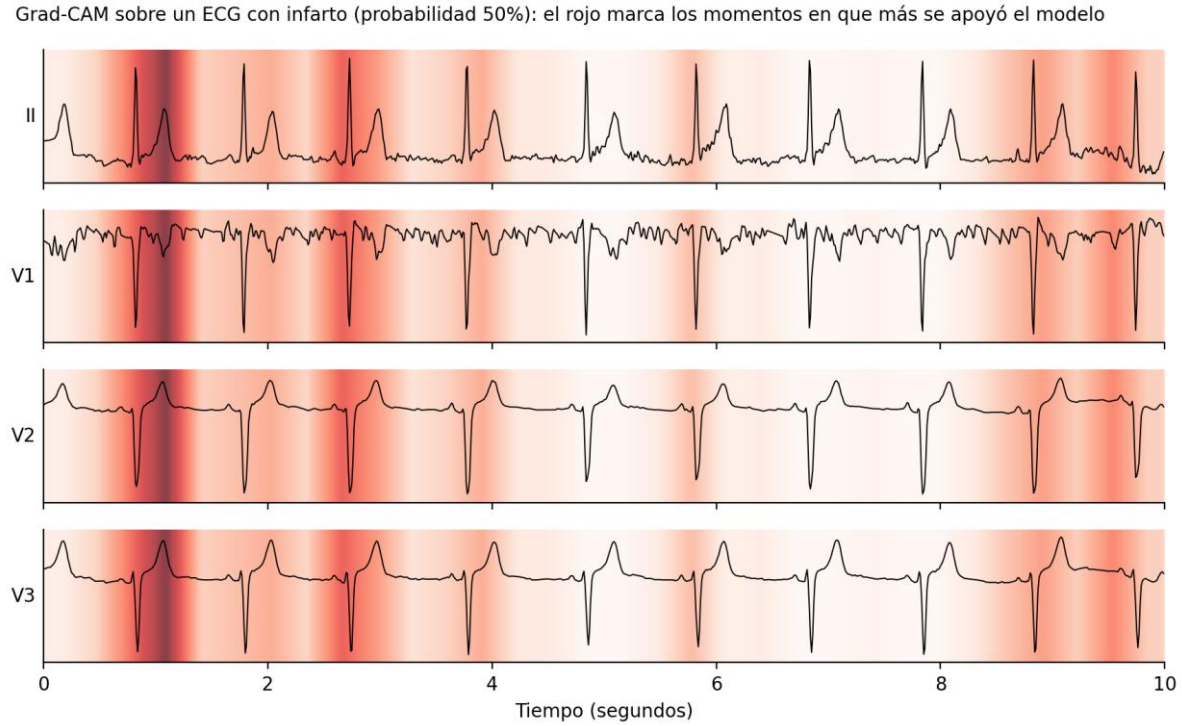


Figura 20. *Mapa Grad-CAM sobre cuatro derivaciones del electrocardiograma 63 de PTB-XL (infarto anteroseptal). El rojo más intenso señala los momentos que más pesaron en la decisión.*

3.11.2 Relación con la onda Q, el segmento ST y la onda T

Sobre el mapa se aplica el análisis por zonas descrito en el Capítulo II. El sistema detecta los picos R en la derivación II; en una hoja impresa sin tira de ritmo, donde II solo cubre 2.5 segundos, usa en cada cuarto de tiempo la derivación visible de mayor amplitud. Después marca en cada latido las ventanas de onda Q, segmento ST y onda T, y calcula la activación media de cada ventana. Los tres valores se presentan como porcentajes que suman 100 %. Si la diferencia entre la zona más activa y la menos activa es menor a 5 puntos, la interfaz dice que la activación es homogénea y no destaca ninguna.

Además, el sistema agrupa los tramos de tiempo en que el mapa supera el 60 % de su máximo, con una duración mínima de 80 ms, y los presenta como **segmentos con mayor activación**, indicando su inicio, su fin, la zona del latido que predomina en ellos y su activación media.

3.11.3 Cómo interpretar el mapa

Queremos ser claros sobre lo que el mapa dice y lo que no dice. Dice en qué momentos de los 10 segundos se apoyó la red para inclinarse hacia “infarto”. No dice en qué derivación está el

problema, porque el mapa es común a las doce. Tampoco demuestra que en ese momento exista una onda Q patológica o un ST elevado: puede que la red se haya fijado en otra cosa que coincide en el tiempo. Su utilidad es orientar la mirada del médico y permitirle detectar respuestas sospechosas, por ejemplo, si el mapa se concentra en un artefacto o en el pulso de calibración de una hoja.

3.12 Casos de uso

Los casos de uso describen, paso a paso, cómo interactúa cada usuario con el sistema. Distinguimos dos actores: el **profesional de la salud**, que usa la aplicación web, y el **desarrollador**, que prepara los datos, entrena y evalúa los modelos con los scripts del proyecto.

Tabla 22. *Resumen de los casos de uso del sistema.*

Clave	Caso de uso	Actor
CU-01	Analizar un electrocardiograma digital	Profesional de la salud
CU-02	Analizar un electrocardiograma impreso	Profesional de la salud
CU-03	Forzar la frecuencia de muestreo	Profesional de la salud
CU-04	Ver un caso de ejemplo	Profesional de la salud
CU-05	Interpretar la explicación visual	Profesional de la salud
CU-06	Consultar el desempeño y las limitaciones	Profesional de la salud
CU-07	Consultar el historial de análisis	Profesional de la salud
CU-08	Explorar la vista de la red neuronal	Profesional de la salud o estudiante
CU-09	Preparar los datos y entrenar el modelo	Desarrollador
CU-10	Evaluar el modelo y validar en bases externas	Desarrollador

Tabla 23. *Caso de uso CU-01: analizar un electrocardiograma digital.*

Elemento	Descripción
Clave	CU-01
Nombre	Analizar un electrocardiograma digital
Actor	Profesional de la salud
Descripción	El usuario sube un archivo con la señal de un electrocardiograma y obtiene la estimación del sistema.
Precondiciones	El servidor está en ejecución y el usuario tiene un archivo WFDB, CSV, TXT o NPY de 12 derivaciones.
Flujo principal	1. Arrastra el archivo al recuadro o lo selecciona con el explorador. 2. Pulsa “Analizar”. 3. El sistema lee el archivo, determina la frecuencia y prepara la señal. 4. La red calcula la probabilidad de infarto y la compara con el corte de 0.3204. 5. El sistema calcula el mapa Grad-CAM y el reparto entre onda Q, ST y T. 6. La interfaz muestra el veredicto, la probabilidad, la certeza, la frecuencia y su origen, la duración, la frecuencia cardiaca y el trazo con el mapa. 7. El análisis se guarda en el historial.
Flujos alternos	Si el archivo WFDB llega sin su pareja (.hea o .dat), si no tiene 12 derivaciones o si dura menos de 5 segundos, el sistema muestra un mensaje de error y no realiza el análisis. Si la frecuencia se estimó con baja certeza, se

Elemento	Descripción
	muestra una advertencia.
Postcondición	El usuario ve el resultado y el análisis queda registrado.

Tabla 24. *Caso de uso CU-02: analizar un electrocardiograma impreso.*

Elemento	Descripción
Clave	CU-02
Nombre	Analizar un electrocardiograma impreso
Actor	Profesional de la salud
Descripción	El usuario sube un PDF, un escaneo o una foto de la hoja y el sistema la digitaliza antes de analizarla.
Precondiciones	La hoja está en formato 3 × 4 a 25 mm/s y 10 mm/mV y se ve completa en la imagen.
Flujo principal	1. Sube el archivo .pdf, .png o .jpg y pulsa “Analizar”. 2. El sistema recorta la hoja, corrige la perspectiva, la endereza y la calibra con la cuadrícula. 3. Sigue los trazos, arma la señal de 12 derivaciones y evalúa la cobertura y la concordancia de la tira de ritmo. 4. Si el archivo es JPG, el modelo de hojas reales calcula la probabilidad y la compara con el corte de 0.9494; si es PDF o PNG, lo hace el modelo de la etapa 2 con el corte de 0.3623. 5. La interfaz muestra el resultado junto con los datos de la digitalización: cobertura, concordancia, tiras de ritmo detectadas, corrección de perspectiva, ángulo de enderezado y escala en píxeles por milímetro.
Flujos alternos	Si no se reconoce la cuadrícula o la cobertura es menor al 50 %, el sistema pide otra imagen. Si la cobertura o la concordancia son bajas, analiza pero advierte que el resultado puede no ser confiable.
Postcondición	El usuario ve el resultado con la información de calidad de la lectura.

Tabla 25. *Caso de uso CU-03: forzar la frecuencia de muestreo.*

Elemento	Descripción
Clave	CU-03
Nombre	Forzar la frecuencia de muestreo
Actor	Profesional de la salud
Descripción	El usuario indica la frecuencia de un archivo CSV, TXT o NPY cuando la conoce o cuando el sistema avisó de baja certeza.
Precondiciones	El usuario tiene un archivo de señal sin cabecera.
Flujo principal	1. Abre “Opciones avanzadas”. 2. Elige 100, 250, 500 o 1000 Hz en la lista. 3. Sube el archivo y pulsa “Analizar”. 4. El sistema usa la frecuencia indicada y reporta su origen como “declarada”.
Flujos alternos	En registros WFDB la opción se ignora, porque la frecuencia de la cabecera es la fuente más confiable.
Postcondición	El análisis se realiza con la frecuencia indicada.

Tabla 26. *Caso de uso CU-04: ver un caso de ejemplo.*

Elemento	Descripción
Clave	CU-04
Nombre	Ver un caso de ejemplo
Actor	Profesional de la salud
Descripción	El usuario explora el sistema sin tener un archivo propio.
Precondiciones	Ninguna.
Flujo principal	1. Pulsa “Ver caso de ejemplo”. 2. El sistema carga un electrocardiograma de

Elemento	Descripción
	PTB-XL con su resultado precalculado. 3. La interfaz muestra el resultado y, además, el diagnóstico de referencia de los cardiólogos y si la predicción fue un acierto o un error. 4. Si pulsa de nuevo, se muestra otro caso.
Flujos alternos	Si el servidor no está disponible, la versión publicada en GitHub Pages usa casos guardados como archivos JSON.
Postcondición	El usuario ve un caso real con su diagnóstico de referencia.

Tabla 27. *Caso de uso CU-05: interpretar la explicación visual.*

Elemento	Descripción
Clave	CU-05
Nombre	Interpretar la explicación visual
Actor	Profesional de la salud
Descripción	El usuario revisa en qué momentos del trazo se apoyó la red.
Precondiciones	Se completó un análisis (CU-01, CU-02 o CU-04).
Flujo principal	1. Revisa el trazo de las derivaciones del plano frontal con el fondo coloreado según la activación. 2. Observa la curva de influencia debajo del trazo. 3. Consulta el reparto porcentual entre onda Q, segmento ST y onda T. 4. Revisa la lista de segmentos con mayor activación y su zona predominante.
Flujos alternos	Si no se detectan latidos suficientes, el reparto por zonas no se muestra y se informa al usuario.
Postcondición	El usuario cuenta con elementos para contrastar el resultado con su propia lectura.

Tabla 28. *Caso de uso CU-06: consultar el desempeño y las limitaciones.*

Elemento	Descripción
Clave	CU-06
Nombre	Consultar el desempeño y las limitaciones
Actor	Profesional de la salud
Descripción	El usuario revisa cuánto puede confiar en el modelo que analizó su archivo.
Precondiciones	Se completó un análisis.
Flujo principal	1. Despliega el panel “Desempeño y limitaciones del modelo”. 2. El sistema muestra las métricas del modelo correspondiente (digital o impreso) con sus intervalos de confianza. 3. El sistema muestra las limitaciones de uso.
Flujos alternos	Ninguno.
Postcondición	El usuario conoce las tasas de error esperadas del modelo.

Tabla 29. *Caso de uso CU-07: consultar el historial de análisis.*

Elemento	Descripción
Clave	CU-07
Nombre	Consultar el historial de análisis
Actor	Profesional de la salud
Descripción	El usuario revisa los análisis realizados recientemente.
Precondiciones	El servidor tiene acceso a la base de datos.
Flujo principal	1. Se desplaza a la sección “Análisis recientes”. 2. El sistema consulta los últimos registros y los muestra en una tabla con fecha, archivo, resultado, probabilidad y zona que más pesó.
Flujos alternos	Si no hay análisis previos, la tabla aparece vacía con un mensaje.
Postcondición	El usuario visualiza su historial reciente.

Tabla 30. *Caso de uso CU-08: explorar la vista de la red neuronal.*

Elemento	Descripción
Clave	CU-08
Nombre	Explorar la vista de la red neuronal
Actor	Profesional de la salud o estudiante
Descripción	El usuario abre una vista tridimensional que muestra cómo se activa la red ante distintos electrocardiogramas.
Precondiciones	El archivo de la red exportada está disponible.
Flujo principal	1. Abre la vista escribiendo “cerebro” en la página, entrando a la dirección con #cerebro o haciendo triple clic sobre el nombre de la aplicación. 2. Elige un electrocardiograma de prueba (acierto con alta confianza, caso cerca del umbral, falso negativo, negativo seguro o falso positivo). 3. Gira y acerca la vista para observar qué capas y neuronas se iluminan. 4. Cierra la vista con la tecla Esc o con el botón de cerrar.
Flujos alternos	Ninguno.
Postcondición	El usuario obtiene una intuición visual de cómo procesa la red un electrocardiograma.

Tabla 31. *Caso de uso CU-09: preparar los datos y entrenar el modelo.*

Elemento	Descripción
Clave	CU-09
Nombre	Preparar los datos y entrenar el modelo
Actor	Desarrollador
Descripción	El desarrollador reproduce el preprocesamiento y el entrenamiento.
Precondiciones	PTB-XL descargado en dataset/crudo y entorno de Python instalado.
Flujo principal	1. Ejecuta el script de exploración para obtener el resumen de PTB-XL. 2. Ejecuta el preprocesamiento, que genera los arreglos de entrenamiento, validación y prueba. 3. Ejecuta el entrenamiento con la configuración deseada. 4. El script guarda el mejor modelo, el último y el historial por época.
Flujos alternos	Si no hay tarjeta gráfica, el entrenamiento se ejecuta en el procesador, de forma mucho más lenta.
Postcondición	Existe un modelo entrenado en modelo_ia/puntos_control.

Tabla 32. *Caso de uso CU-10: evaluar el modelo y validar en bases externas.*

Elemento	Descripción
Clave	CU-10
Nombre	Evaluar el modelo y validar en bases externas
Actor	Desarrollador
Descripción	El desarrollador mide el desempeño del modelo y su generalización.
Precondiciones	Existe un modelo entrenado; para la validación externa, las bases descargadas.
Flujo principal	1. Ejecuta la evaluación, que elige el corte en validación y mide el grupo de prueba con intervalos de confianza. 2. Ejecuta la evaluación de la digitalización de extremo a extremo. 3. Ejecuta la descarga y la validación en bases externas. 4. Revisa las métricas, curvas y matrices guardadas en documentos/resultados.
Flujos alternos	Si una base externa no está descargada, el script la omite e informa.
Postcondición	Los resultados quedan guardados en archivos JSON, CSV y PNG.

3.13 Servidor y API

El servidor está escrito con FastAPI y organizado en capas, de modo que cada parte tiene una sola responsabilidad: las **rutas** reciben las peticiones, los **servicios** contienen la lógica del análisis, los **repositorios** hablan con la base de datos, los **esquemas** describen la forma de los datos que entran y salen, y las **utilidades** leen los distintos formatos de archivo. Los modelos se cargan una sola vez al iniciar y se reutilizan en cada análisis.

Tabla 33. *Rutas de la API.*

Método	Ruta	Función
GET	/salud	Comprueba que el servidor está activo
POST	/api/analisis	Recibe uno o dos archivos (y opcionalmente la frecuencia) y devuelve el resultado completo
GET	/api/visualizacion/demo	Devuelve un caso de ejemplo de PTB-XL con su diagnóstico de referencia
GET	/api/historial	Devuelve los análisis más recientes
GET	/	Entrega la interfaz web

La ruta principal es **POST /api/analisis**. Recibe los archivos en un formulario y, opcionalmente, la frecuencia de muestreo. El servicio de análisis decide qué hacer según la extensión: si es un PDF o una imagen, llama al digitalizador y elige el modelo de impresos que corresponde (hojas reales para JPG, etapa 2 para PDF y PNG); si es un archivo de señal, usa el lector correspondiente, determina la frecuencia y usa el modelo digital. Después prepara la señal, ejecuta la red, calcula Grad-CAM, arma la visualización, guarda el registro y devuelve una respuesta en formato JSON.

Tabla 34. *Campos principales de la respuesta del análisis.*

Campo	Contenido
tipo_entrada	“senal” o “documento_impreso”
etiqueta	“iam_detectado” o “sin_iam”
probabilidad_iam	Probabilidad estimada por la red, entre 0 y 1
confianza	Probabilidad de la clase elegida
umbral_decision	Punto de corte aplicado (0.3204, 0.3623 o 0.9494)
mensaje	Texto breve para el usuario
frecuencia_original	Frecuencia de muestreo del archivo, en Hz
origen_frecuencia	cabecera, declarada, columna_tiempo, estimada o papel
duracion_original_segundos	Duración del registro recibido
frecuencia_cardiaca_lpm	Frecuencia cardiaca medida en latidos por minuto
advertencias	Lista de avisos (baja certeza de frecuencia, cobertura baja, etc.)
digitalizacion	Para hojas: cobertura, concordancia, tiras de ritmo, perspectiva, ángulo y escala
visualizacion	Señal, mapa Grad-CAM, reparto por zonas y segmentos para dibujar

El Anexo D muestra una respuesta real del sistema al analizar la foto simulada de la sección 3.10.

3.14 Base de datos

El historial se guarda en una base de datos SQLite, que consiste en un solo archivo y no requiere instalar un servidor de base de datos. Para el volumen de un prototipo es más que suficiente y facilita copiar o respaldar el historial. El acceso se hace mediante SQLAlchemy, de modo que cambiar a otro motor, como PostgreSQL, solo requeriría cambiar la cadena de conexión.

Tabla 35. *Estructura de la tabla registros_analisis.*

Columna	Tipo	Descripción
id	Entero, llave primaria	Identificador autoincremental
nombre_archivo	Texto (255)	Nombre del archivo analizado
etiqueta	Texto (50), indexado	Resultado: iam_detectado o sin_iam
probabilidad_iam	Real	Probabilidad de infarto
confianza	Real	Probabilidad de la clase elegida
umbral_decision	Real, opcional	Punto de corte aplicado
frecuencia_original	Real, opcional	Frecuencia de muestreo del archivo
zona_predominante	Texto (50), opcional	Zona del latido con más activación
mensaje	Texto	Mensaje mostrado al usuario
creado_en	Fecha y hora	Momento del análisis

Como se ve, la tabla no tiene columnas para datos del paciente. Es una decisión deliberada de privacidad: el sistema no necesita saber de quién es el electrocardiograma para analizarlo.

3.15 Interfaz de usuario

La interfaz se diseñó como una sola página con un estilo oscuro y sobrio, pensada para profesionales de la salud. En la parte superior aparece el nombre de la aplicación, **CardiologIA**, con dos etiquetas que dejan claro su carácter: “Beta” y “Uso médico”. Debajo, una breve descripción explica qué hace la herramienta y a quién va dirigida.

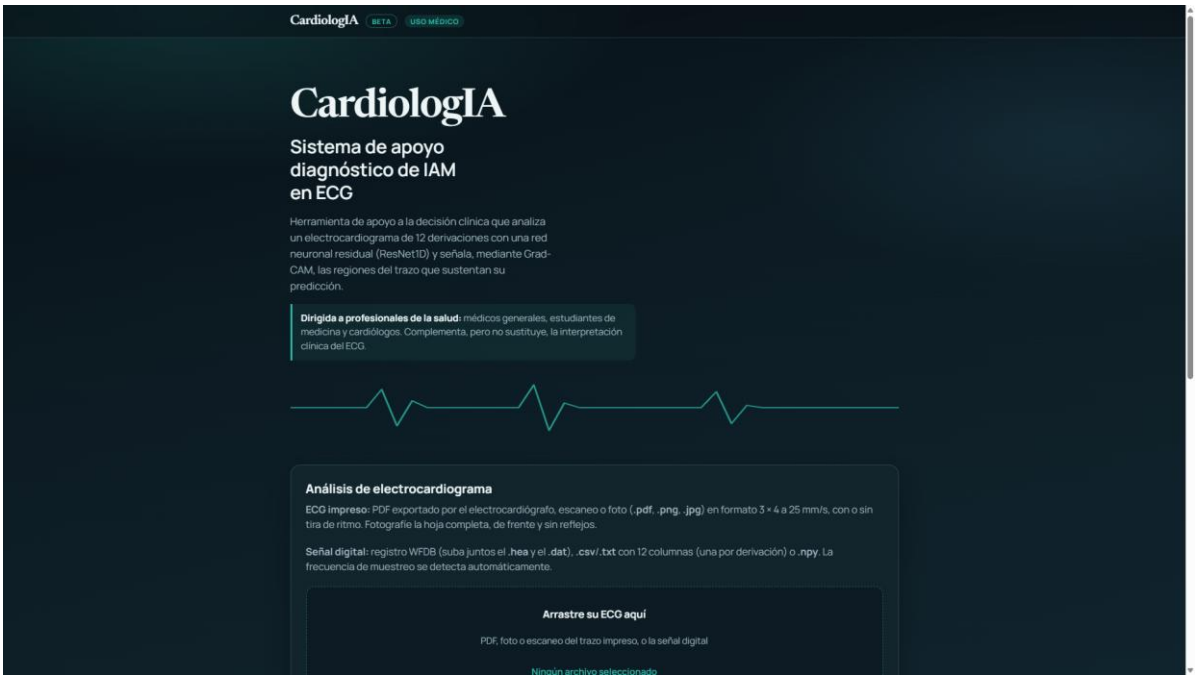


Figura 21. *Pantalla de inicio de CardiologIA con la descripción de la herramienta y el área de carga de archivos.*

3.15.1 Carga del archivo

El área de análisis explica en dos líneas qué archivos se aceptan: electrocardiogramas impresos (PDF, escaneo o foto en formato 3 × 4) y señales digitales (WFDB, CSV, TXT o NPY). El usuario puede arrastrar el archivo o seleccionarlo. Un menú de **opciones avanzadas** permite forzar la frecuencia de muestreo, con una explicación de cuándo conviene usarlo. Tres botones completan el área: “Analizar”, “Ver caso de ejemplo” y “Limpiar”.

3.15.2 Resultado

El resultado se presenta en un recuadro destacado con un veredicto en lenguaje clínico: “Patrón electrocardiográfico compatible con IAM” o “Sin patrón electrocardiográfico de IAM”. Debajo aparece la probabilidad en una escala de color de 0 a 100 % con una marca en el punto de corte, de modo que se ve de un vistazo qué tan lejos o cerca quedó el caso. Un texto aclara por qué el corte está por debajo de 50 %.

La **certeza** se calcula con la distancia entre la probabilidad y el corte, medida en proporción al espacio disponible de ese lado de la escala. Es **alta** si esa distancia relativa es de al menos 0.6, **media** si está entre 0.25 y 0.6 y **baja** si es menor. Junto a la certeza se muestran la frecuencia de muestreo y su origen, la duración y la frecuencia cardiaca y, para hojas impresas, los datos de la digitalización. En los casos de ejemplo se agrega el diagnóstico de referencia y si la predicción fue un verdadero o falso positivo o negativo.

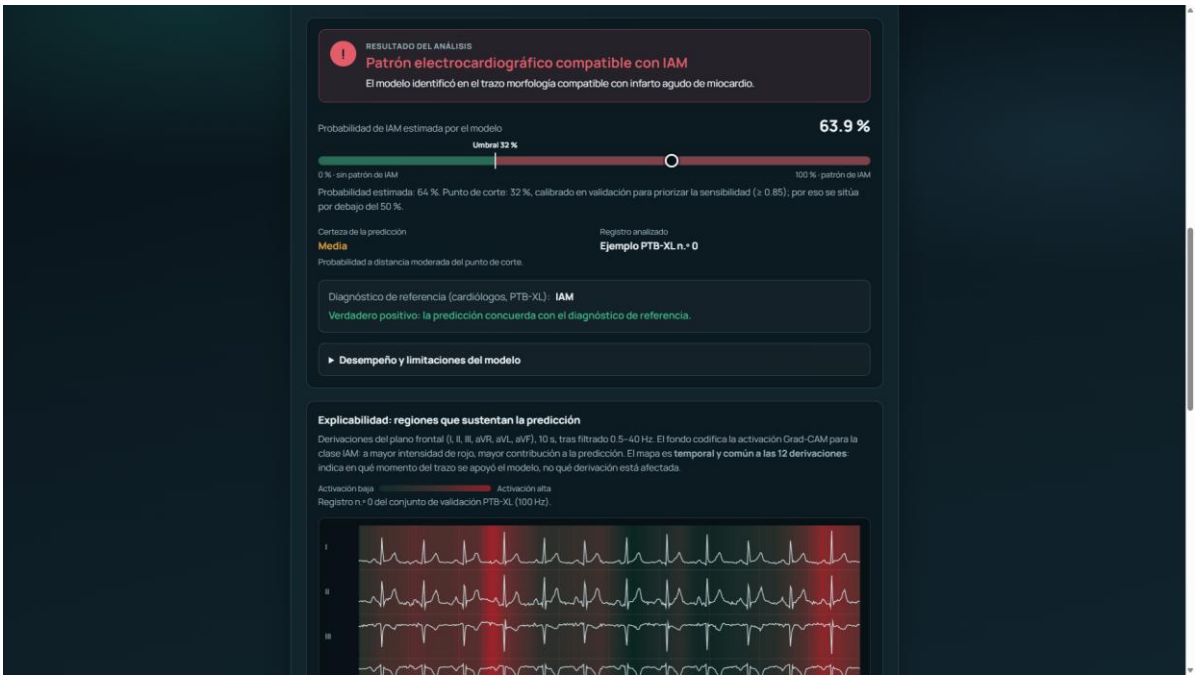


Figura 22. *Resultado de un caso de ejemplo: veredicto, escala de probabilidad con el punto de corte, certeza y comparación con el diagnóstico de referencia.*

3.15.3 Desempeño y limitaciones

Un panel desplegable muestra las métricas del modelo que se usó, con sus intervalos de confianza, y las limitaciones en lenguaje directo, por ejemplo: “Un resultado negativo no excluye IAM: alrededor de 16 de cada 100 registros con IAM no son detectados”. Para hojas impresas el panel muestra las métricas por tipo de documento del modelo de la etapa 2; todavía no incluye las del modelo de fotografías JPG, una mejora pendiente que se menciona en el Capítulo IV. Decidimos que esta información estuviera a un clic del resultado, porque un médico necesita conocer las tasas de error para poder ponderar la respuesta.

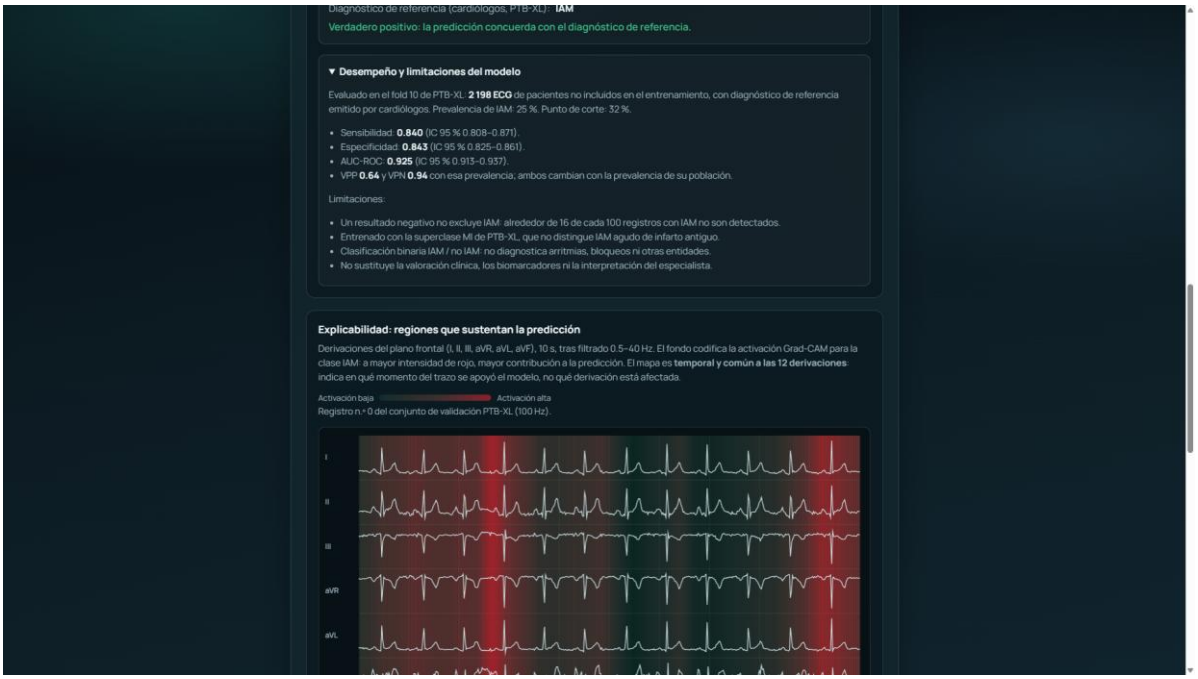


Figura 23. *Panel de desempeño y limitaciones del modelo, desplegado debajo del resultado.*

3.15.4 Explicación visual

La sección de explicabilidad dibuja las seis derivaciones del plano frontal durante los 10 segundos, ya filtradas, con un fondo que va de oscuro a rojo según la activación de Grad-CAM. Debajo, una curva de "influencia" resume el mapa en el tiempo. Un texto aclara que el mapa es temporal y común a las doce derivaciones.



Figura 24. *Sección de explicabilidad: derivaciones del plano frontal con el mapa Grad-CAM de fondo y la curva de influencia.*

Más abajo se muestra el reparto de la activación entre onda Q (necrosis), segmento ST (lesión) y onda T (isquemia), cada uno con una breve explicación clínica, y la lista de segmentos con mayor activación. Al final, una nota recuerda que Grad-CAM es orientativo. La sección termina con la tabla de **análisis recientes**.

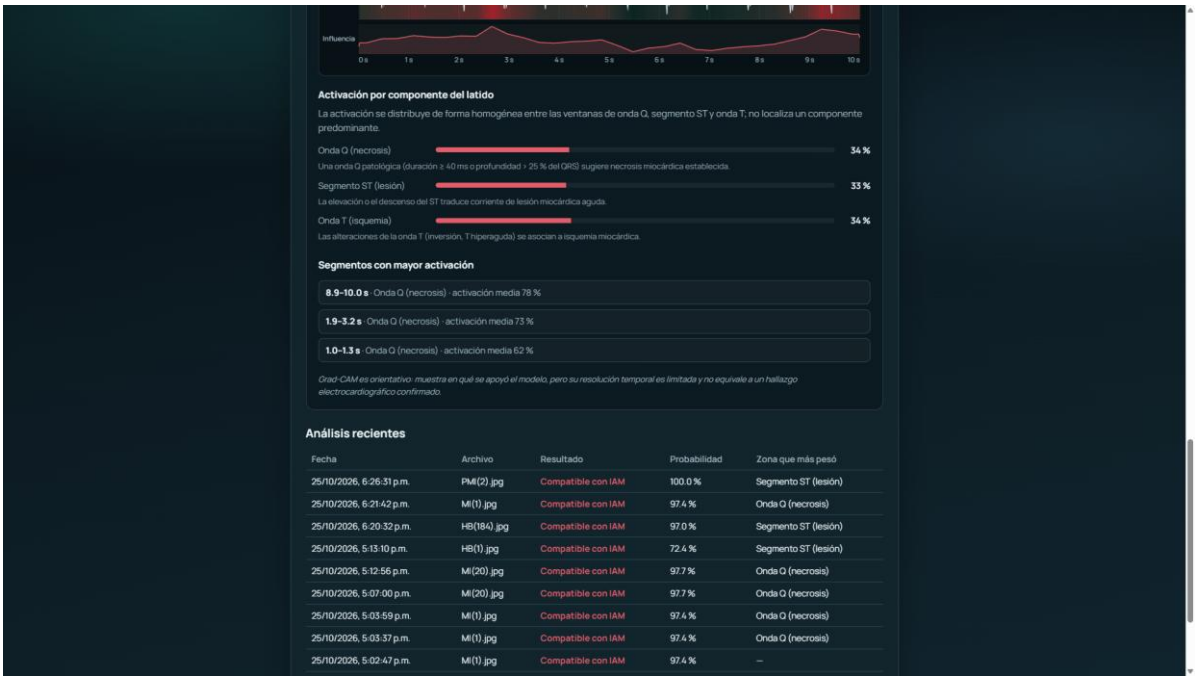


Figura 25. *Reparto de la activación por componente del latido, segmentos con mayor activación y tabla de análisis recientes.*

3.15.5 La vista de la red neuronal

Como complemento didáctico construimos una vista oculta que dibuja la red en tres dimensiones. Cada punto representa una neurona, agrupadas por capas con colores distintos, y las líneas representan las conexiones con pesos más fuertes. Al elegir uno de los cinco electrocardiogramas de prueba, el brillo de cada neurona refleja su activación real ante ese trazo, y en la salida se ve cómo se reparte la probabilidad entre “IAM” y “no IAM”. La vista muestra 1 998 neuronas representativas y 4 016 conexiones de las 8 732 290 que tiene el modelo; los datos se exportan con un script del proyecto. Se abre escribiendo “cerebro” en la página, entrando con la dirección terminada en #cerebro o con un triple clic sobre el nombre de la aplicación.

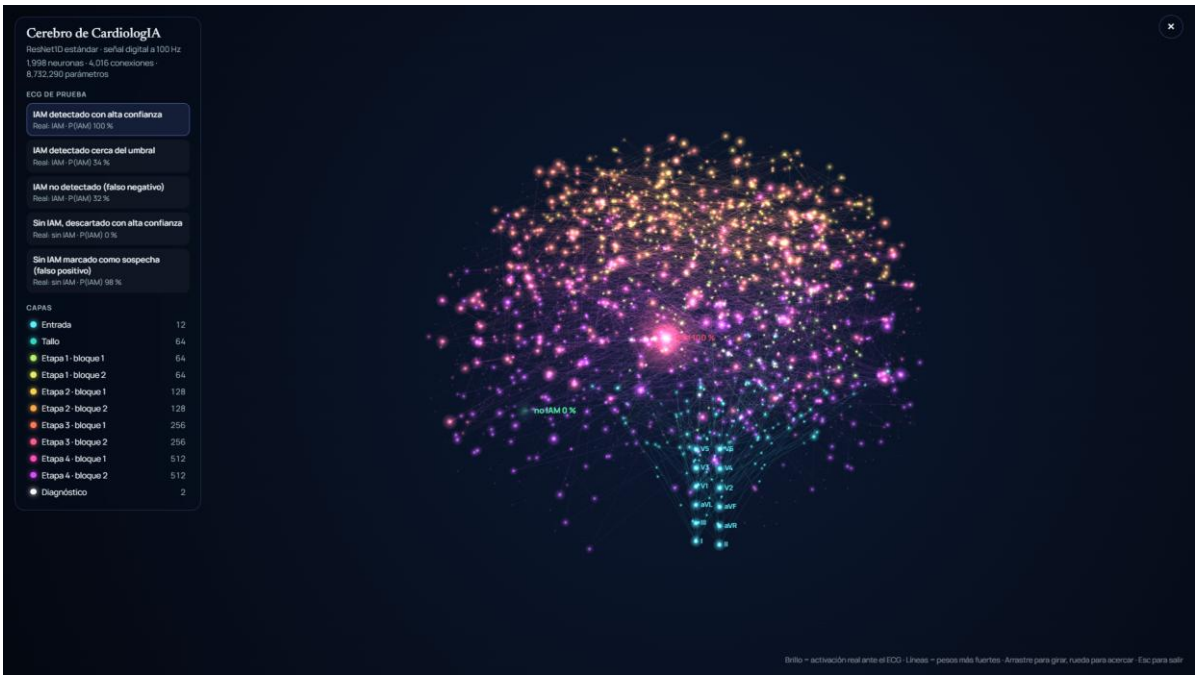


Figura 26. *Vista tridimensional de la red neuronal con los cinco casos de prueba disponibles y la leyenda de capas.*

3.15.6 Demostración pública

Además de la versión con servidor, publicamos una versión estática en GitHub Pages, disponible en https://alejandroonm.github.io/Residencia2026/. Esa versión no analiza archivos nuevos, porque no tiene servidor, pero muestra cinco casos reales de PTB-XL con sus resultados precalculados, el mapa de explicabilidad y la vista de la red. Sirve para que cualquier persona conozca la herramienta sin instalar nada.

3.16 Pruebas del sistema

Además de la evaluación del modelo, que se presenta en la siguiente sección, probamos el funcionamiento del sistema de punta a punta. La tabla siguiente resume las pruebas funcionales más representativas, realizadas con el servidor en ejecución local.

Tabla 36. *Pruebas funcionales del sistema.*

Prueba	Entrada	Resultado esperado	Resultado obtenido
Salud del servidor	GET /salud	Estado activo	Correcto
Señal CSV sin frecuencia	ejemplo_con_iam.csv	Frecuencia estimada, compatible con IAM	Correcto: 100 Hz estimada, 61 lpm, probabilidad 50.2 %
Registro WFDB completo	.hea y .dat del mismo registro	Frecuencia tomada de la cabecera	Correcto: origen “cabecera”, 100 Hz, misma probabilidad que el CSV
Registro WFDB incompleto	Solo el .hea	Mensaje de error claro	Correcto: “El formato WFDB requiere subir

Prueba	Entrada	Resultado esperado	Resultado obtenido
			juntos un archivo .hea y un .dat”
Señal demasiado corta	CSV de 3 segundos	Rechazo por duración menor a 5 s	Correcto: “La señal dura 3.0 s; se requieren al menos 5 s”
Hoja limpia	Imagen de la hoja del ECG 63	Digitalización y resultado	Correcto: probabilidad 54.9 %, compatible
Foto simulada	Foto del ECG 63	Digitalización con corrección de perspectiva	Digitalizada (cobertura 100 %, concordancia 0.978); probabilidad 13.9 %, falso negativo
Caso de ejemplo	Botón “Ver caso de ejemplo”	Caso con diagnóstico de referencia	Correcto: verdadero positivo, 63.9 %
Historial	Varios análisis seguidos	Aparecen en “Análisis recientes”	Correcto
Vista de la red	Escribir “cerebro”	Se abre la vista 3D	Correcto

La prueba con la foto simulada es especialmente ilustrativa. El digitalizador hizo bien su trabajo, con una cobertura completa y una concordancia de la tira de ritmo de 0.978, pero el resultado cambió respecto a la señal original. Esto muestra que el error no siempre viene de una mala lectura de la hoja: en casos que ya estaban cerca del corte, diferencias pequeñas en la señal pueden cambiar la decisión. Es una de las razones por las que el sistema reporta la certeza y por las que un resultado negativo nunca debe tomarse como definitivo.

3.17 Resultados con señales digitales

Esta sección presenta la medición más importante del proyecto: cómo se comporta el modelo digital con los 2 198 electrocardiogramas del pliegue 10 de PTB-XL, que no se usaron en ningún momento del entrenamiento ni para elegir el punto de corte. El grupo de prueba se evaluó **una sola vez**, al final, con el modelo de la época 12 y el corte de 0.3204 ya congelados. Todo lo que aparece aquí es, por lo tanto, una estimación honesta de lo que pasaría con pacientes nuevos parecidos a los de PTB-XL.

3.17.1 Métricas principales

De los 2 198 electrocardiogramas de prueba, 550 tienen infarto según PTB-XL (25 %) y 1 648 no. El modelo marcó como compatibles con infarto 721 trazos, de los cuales 462 eran infartos reales y 259 falsas alarmas. De los 1 477 trazos que dejó como negativos, 1 389 eran efectivamente sin infarto y 88 eran infartos que no detectó.

Tabla 37. *Resultados del modelo digital en el grupo de prueba (pliegue 10, 2 198 electrocardiogramas).*

Métrica	Corte 0.3204 (elegido)	IC 95 %	Corte 0.5 (referencia)
Sensibilidad	0.840	0.808 – 0.871	0.769
Especificidad	0.843	0.825 – 0.861	0.900
AUC-ROC	0.925	0.913 – 0.937	0.925
F1	0.727	—	0.743
Exactitud	0.842	—	0.867
Valor predictivo positivo	0.641	—	0.719
Valor predictivo negativo	0.940	—	0.921
Precisión media (área bajo la curva PR)	0.825	—	0.825
Verdaderos positivos / falsos negativos	462 / 88	—	423 / 127
Verdaderos negativos / falsos positivos	1 389 / 259	—	1 483 / 165

La lectura de la tabla es la siguiente. De cada 100 infartos, el modelo detecta 84; de cada 100 trazos sin infarto, descarta correctamente 84. Si se toma al azar un trazo con infarto y otro sin infarto, en 92.5 de cada 100 parejas el modelo le da una probabilidad más alta al que sí tiene infarto. Cuando el modelo dice "negativo", acierta 94 de cada 100 veces; cuando dice "compatible con infarto", acierta 64 de cada 100 veces, lo que significa que un resultado positivo debe verse como una llamada de atención y no como un diagnóstico.

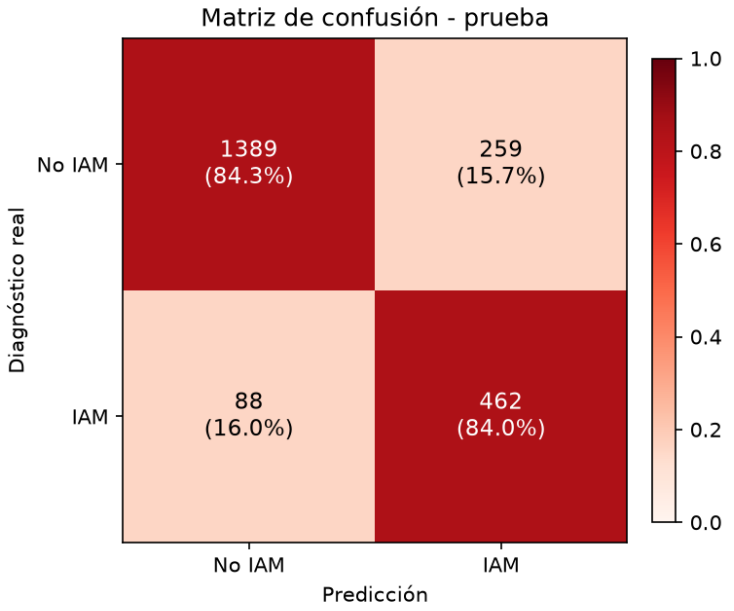


Figura 27. *Matriz de confusión del modelo digital en el grupo de prueba con el corte de 0.3204.*

La matriz de confusión muestra los mismos números de forma visual. Las casillas de la diagonal, en rojo oscuro, son los aciertos; las otras dos son los errores. Los errores están

repartidos casi por igual en proporción: 16 % de los infartos se escapan y 15.7 % de los trazos sin infarto generan una falsa alarma. Ese equilibrio es justamente lo que buscaba el criterio de elección del corte.

3.17.2 Curvas ROC y de precisión

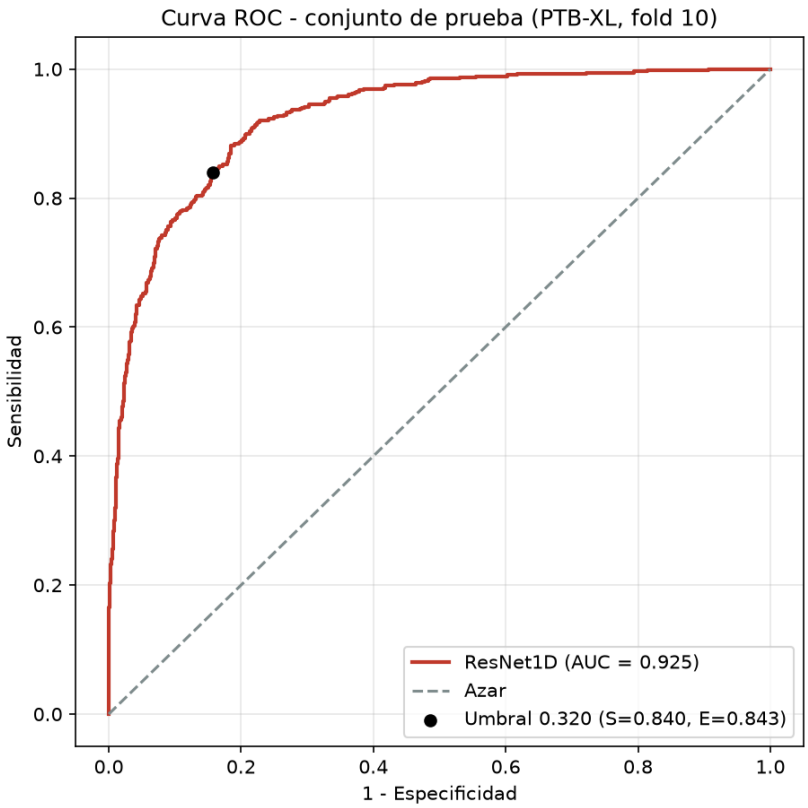


Figura 28. *Curva ROC del modelo digital en el grupo de prueba. El punto marca el corte de 0.3204.*

La curva ROC sube con rapidez y se separa claramente de la diagonal, que representaría adivinar al azar. El punto marcado es el corte elegido. Moverse a lo largo de la curva hacia arriba significa detectar más infartos a cambio de más falsas alarmas, y hacia abajo lo contrario. La forma de la curva indica que no hay un corte "mágico": cualquier ganancia en sensibilidad se paga con especificidad.

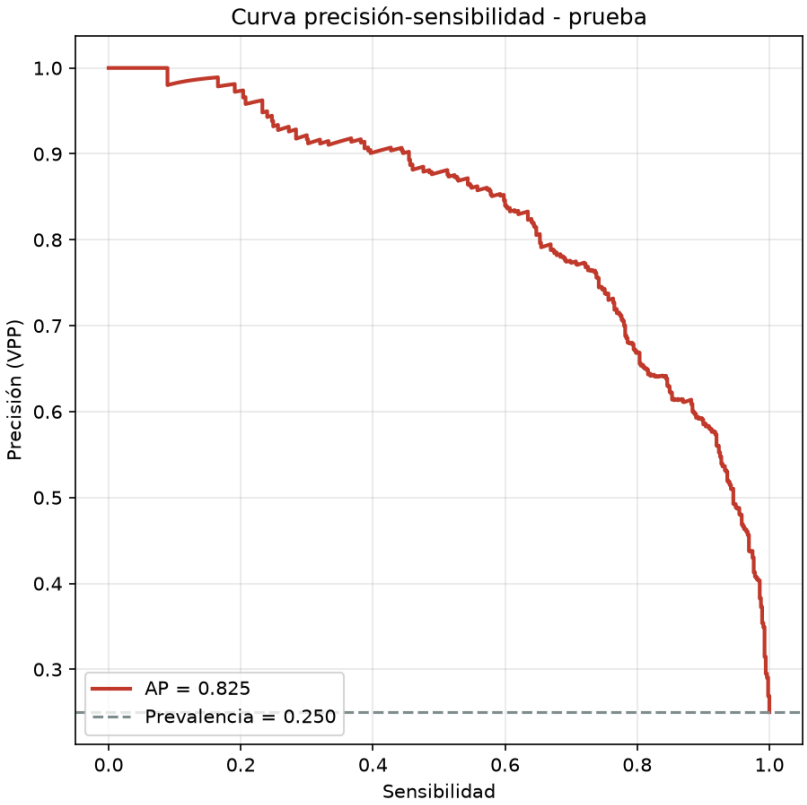


Figura 29. *Curva de precisión contra sensibilidad del modelo digital en el grupo de prueba.*

La curva de precisión contra sensibilidad es más exigente que la ROC cuando la clase de interés es minoritaria, porque se fija en qué fracción de los positivos marcados son reales. Su área, la precisión media, es de 0.825. Para comparación, un modelo que adivina al azar tendría una precisión media igual a la prevalencia, es decir, 0.25.

3.17.3 ¿Por qué no usar el corte de 0.5?

Con el corte de 0.5 el modelo tendría una especificidad de 0.900 y una exactitud ligeramente mayor, pero dejaría pasar 127 infartos en lugar de 88: 39 pacientes más con un infarto no detectado en un grupo de 550. Para una herramienta cuyo objetivo es avisar, ese costo nos pareció inaceptable. El corte de 0.3204 no se eligió mirando estos resultados, sino en el grupo de validación, y el hecho de que en prueba la sensibilidad y la especificidad hayan quedado tan cerca de las de validación (0.852 y 0.846) indica que el corte se comporta de forma estable con datos nuevos.

3.17.4 ¿Dónde se equivoca el modelo?

Un porcentaje global esconde diferencias importantes. Para entenderlas, desglosamos los errores del grupo de prueba por tipo de infarto, por el diagnóstico de los trazos sin infarto, por

sexo y por edad. El análisis se realizó con un script del proyecto que lee las probabilidades del grupo de prueba y las cruza con las etiquetas de PTB-XL.

Tabla 38. *Sensibilidad del modelo digital por tipo de infarto (un trazo puede tener más de un tipo).*

Tipo de infarto	Localización	Casos en prueba	Sensibilidad
IMI	Inferior	267	0.843
ASMI	Anteroseptal	234	0.923
ILMI	Inferolateral	48	0.938
AMI	Anterior	35	0.771
ALMI	Anterolateral	27	0.593
INJAS	Lesión anteroseptal	22	0.955
LMI	Lateral	20	0.550
INJAL	Lesión anterolateral	14	1.000

Los infartos anteroseptales e inferolaterales, que son de los más frecuentes y producen cambios visibles en varias derivaciones a la vez, se detectan en más de 92 de cada 100 casos. Los **infartos laterales** son la gran debilidad: el modelo solo detecta 55 de cada 100 infartos laterales puros y 59 de cada 100 anterolaterales. Tiene sentido desde el punto de vista clínico, porque la cara lateral del corazón se observa en pocas derivaciones (I, aVL, V5 y V6) y sus cambios suelen ser más discretos. Además, son los tipos con menos ejemplos en el entrenamiento. Hay que tomar estas cifras con cautela, porque con 20 o 27 casos el margen de error es amplio, pero la tendencia es consistente.

Tabla 39. *Especificidad del modelo digital según el diagnóstico de los trazos sin infarto.*

Grupo sin infarto	Trazos	Especificidad	Falsas alarmas
Solo normal (NORM)	912	0.932	≈ 7 de cada 100
Con cambios del ST-T (STTC)	382	0.730	≈ 27 de cada 100
Con trastornos de conducción (CD)	321	0.667	≈ 33 de cada 100
Con hipertrofia (HYP)	183	0.683	≈ 32 de cada 100

Esta tabla explica casi todas las falsas alarmas. Con trazos normales, el modelo se equivoca en solo 7 de cada 100. Con trazos que tienen otras alteraciones cardiacas, las falsas alarmas se multiplican por cuatro o cinco. No es un fallo extraño: los bloqueos de rama, la hipertrofia del ventrículo y los cambios del ST-T por otras causas producen alteraciones que se parecen a las de un infarto, y también confunden a médicos en formación. Para el usuario la conclusión práctica es clara: **un resultado positivo en un paciente con una enfermedad cardiaca conocida tiene menos valor que en un paciente con un corazón previamente sano.** (Un mismo trazo puede pertenecer a varios grupos, por eso las cifras no suman los 1 648 trazos sin infarto.)

Tabla 40. *Desempeño del modelo digital por sexo y por grupo de edad.*

Grupo	Trazos (con infarto)	Sensibilidad	Especificidad
Hombres	—	0.862	0.844
Mujeres	—	0.814	0.841
Menores de 50 años	521 (38)	0.763	0.959
De 50 a 69 años	885 (195)	0.821	0.835
70 años o más	758 (302)	0.858	0.750

Por sexo, la especificidad es prácticamente igual y la sensibilidad es unos cinco puntos menor en mujeres. La diferencia cae dentro del margen de error de la medición, pero coincide con lo que reporta la literatura médica: los infartos en mujeres se presentan con más frecuencia de forma atípica. Por edad aparecen dos patrones claros. En menores de 50 años el modelo casi no da falsas alarmas (especificidad de 0.959), pero solo hay 38 infartos y detecta 76 de cada 100. En mayores de 70 años detecta más infartos, pero da una falsa alarma en uno de cada cuatro trazos sin infarto, porque a esa edad son mucho más frecuentes las otras alteraciones cardiacas que, como vimos, confunden al modelo. Los grupos de edad no suman los 2 198 trazos porque algunos registros de PTB-XL no tienen la edad anotada.

3.18 Resultados con electrocardiogramas impresos

Los electrocardiogramas impresos se evaluaron en tres niveles, de lo más controlado a lo más real: primero la vista 3 × 4 de las señales de PTB-XL, sin papel de por medio; después hojas sintéticas impresas y digitalizadas de punta a punta; y por último fotografías reales de hojas tomadas en hospitales de Pakistán, que se presentan en la sección de validación externa.

3.18.1 Vista 3 × 4 de las señales de prueba

En este primer nivel se toman las 2 198 señales de prueba y se oculta lo que no aparecería en una hoja 3 × 4: cada derivación queda visible solo durante su cuarto de tiempo y la derivación II completa como tira de ritmo. No hay digitalización, así que esta medición separa el efecto de "ver menos señal" del efecto de "leerla de una imagen".

Tabla 41. *Desempeño en la vista 3 × 4 de los 2 198 electrocardiogramas de prueba.*

Modelo	Corte	Sensibilidad	Especificidad	AUC-ROC
Digital, con la señal completa (referencia)	0.3204	0.840	0.843	0.925
Impreso, etapa 2 (PDF y PNG)	0.3623	0.844 (0.810 – 0.873)	0.852 (0.835 – 0.869)	0.928 (0.916 – 0.940)
Impreso, etapa 2, corte propio de la vista 3 × 4	0.3347	0.858 (0.828 – 0.885)	0.843 (0.825 – 0.860)	0.928
Hojas reales (fotografías JPG)	0.9494	0.518 (0.477 – 0.561)	0.945 (0.934 – 0.955)	0.862 (0.843 – 0.879)

El resultado más interesante es que el modelo de la etapa 2, que solo ve una cuarta parte de cada derivación, iguala e incluso supera ligeramente al modelo digital que ve la señal completa. Esto no significa que la información extra no sirva, sino que el modelo especializado aprendió a sacar el máximo provecho de la tira de ritmo y de los tramos visibles. Con el corte de la aplicación (0.3623), elegido con hojas digitalizadas, obtiene una sensibilidad de 0.844 y una especificidad de 0.852.

La última fila muestra el costo del ajuste a hojas reales que describimos en la sección 3.10.6. Con las señales de PTB-XL, el modelo de hojas reales solo detecta 52 de cada 100 infartos con su corte de 0.95. Aunque bajáramos el corte a 0.5, solo llegaría a 64 de cada 100 con una especificidad de 0.891, y para alcanzar 85 de cada 100 habría que bajarlo casi a cero, con lo que la especificidad caería a 0.675. Su AUC también baja de 0.928 a 0.862, lo que confirma que el problema no es solo el corte: el modelo cambió su forma de ver las señales. Esta medición es la razón por la que la aplicación conserva el modelo de la etapa 2 para PDF y PNG.

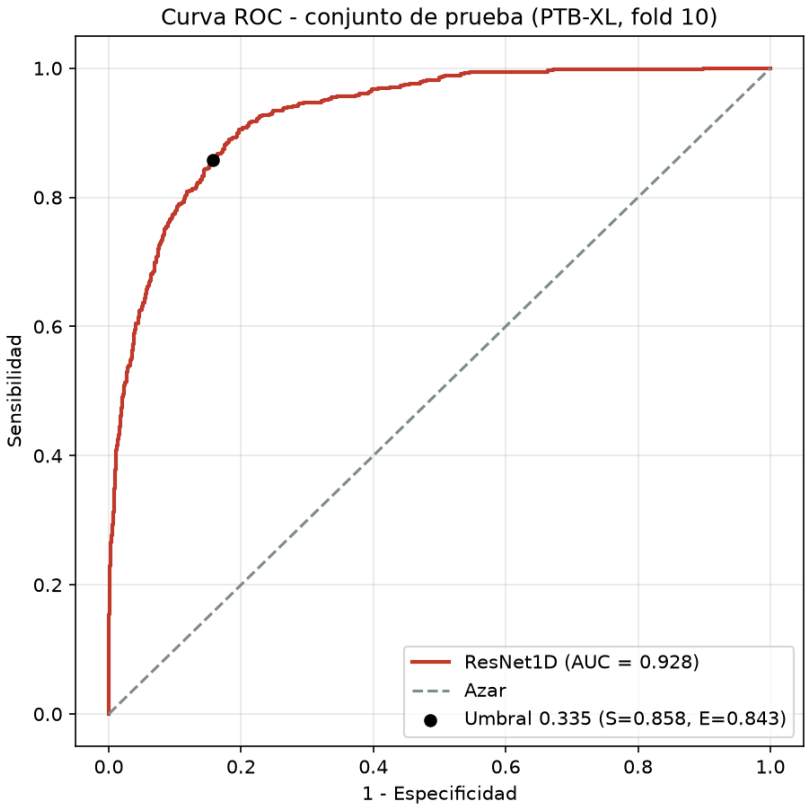


Figura 30. *Curva ROC del modelo de impresos (etapa 2) sobre la vista 3 × 4 de los electrocardiogramas de prueba. El punto marca el corte propio de esa vista (0.3347).*

3.18.2 Digitalización de punta a punta

En el segundo nivel se imprimieron 500 electrocardiogramas de prueba en cada uno de los cuatro tipos de documento (PDF del equipo, imagen limpia, escaneo y foto con celular), se pasaron por el digitalizador y se analizaron con el modelo de la etapa 2 y el corte de 0.3623. Así se mide el sistema completo, tal como lo usaría alguien que sube una hoja: si el digitalizador comete un error, ese error llega al modelo. De los 500 registros, 114 tienen infarto (22.8 %).

Tabla 42. *Calidad de la digitalización por tipo de documento (500 hojas de cada tipo).*

Tipo de documento	Digitalizadas con éxito	Correlación mediana con la señal original	Derivaciones con correlación ≥ 0.9
PDF del equipo	99.8 %	0.989	98.4 %
Imagen limpia	99.8 %	0.984	96.5 %
Escaneo	99.8 %	0.977	91.9 %
Foto con celular	97.8 %	0.958	76.5 %

La **correlación** mide qué tan parecida es la señal recuperada a la original: 1 sería idéntica. En los PDF y las imágenes limpias la digitalización es casi perfecta, con correlaciones medianas de 0.98 a 0.99. Los escaneos pierden un poco por la rotación, el desenfoque y la compresión. Las fotos son el caso más difícil: 11 de las 500 no se pudieron digitalizar, sobre todo porque la perspectiva deformaba tanto la hoja que las filas no medían los 10 segundos esperados, y una de cada cuatro derivaciones quedó con una correlación menor a 0.9. Aun así, la mediana de 0.958 indica que la mayoría de las fotos se leen bien. En todos los tipos, la tira de ritmo se identificó correctamente en al menos 99.8 % de las hojas.

Tabla 43. *Desempeño de punta a punta del modelo de la etapa 2 (corte 0.3623) por tipo de documento.*

Tipo de documento	Sensibilidad (IC 95 %)	Especificidad (IC 95 %)	AUC-ROC	AUC con la señal original	Acuerdo con la señal original
PDF del equipo	0.921 (0.871 – 0.966)	0.805 (0.764 – 0.843)	0.941	0.944	96.4 %
Imagen limpia	0.930 (0.882 – 0.974)	0.803 (0.762 – 0.841)	0.948	0.944	96.4 %
Escaneo	0.912 (0.860 – 0.960)	0.808 (0.766 – 0.845)	0.937	0.943	94.4 %
Foto con celular	0.927 (0.877 – 0.973)	0.778 (0.736 – 0.817)	0.925	0.942	92.8 %
Todos juntos	0.923	0.799	0.937	—	—

En los cuatro tipos de documento la sensibilidad supera 0.91 y la especificidad ronda 0.80. La columna “AUC con la señal original” muestra el desempeño que se habría obtenido con la

misma vista 3 × 4 sin pasar por papel; la diferencia con la columna anterior es lo que cuesta digitalizar. Para PDF, imágenes y escaneos ese costo es mínimo, de menos de una centésima. Para las fotos baja de 0.942 a 0.925, una pérdida pequeña pero real. La última columna indica en cuántas hojas la decisión final (positivo o negativo) fue la misma que con la señal original: entre 93 y 96 de cada 100.

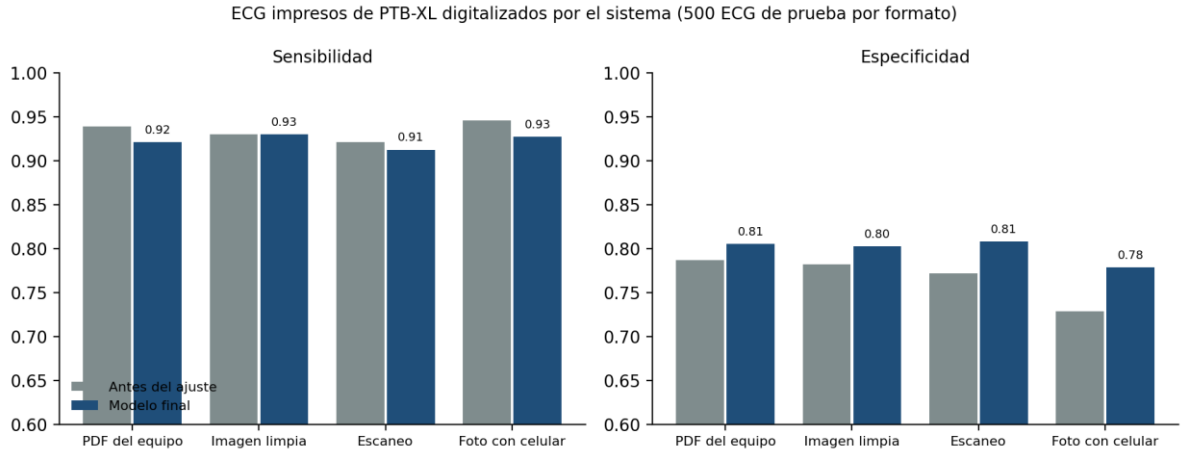


Figura 31. *Sensibilidad y especificidad por tipo de documento, antes y después del ajuste del modelo con hojas digitalizadas.*

3.18.3 ¿Sirvió el ajuste con hojas digitalizadas?

Para responder, evaluamos con los mismos 2 000 documentos el modelo de la etapa 1, que nunca vio una señal digitalizada, con su propio corte elegido en validación (0.4303). La figura anterior compara ambos. El modelo sin ajuste tenía una sensibilidad un poco más alta (0.934 en conjunto), pero su especificidad era claramente menor: 0.787 en PDF, 0.782 en imágenes, 0.771 en escaneos y 0.728 en fotos. Con el ajuste, la especificidad sube a 0.80 en promedio y la mejora es mayor justamente en las fotos, de 0.728 a 0.778. Dicho de forma sencilla, el modelo sin ajuste confundía los defectos del digitalizador, como picos suavizados o pequeños saltos del trazo, con signos de infarto; después del ajuste aprendió a ignorarlos.

3.18.4 Un caso que cambia de decisión

El electrocardiograma 63 de PTB-XL, un infarto anteroseptal que usamos como ejemplo a lo largo del informe, ilustra los límites de la digitalización. Con la señal digital, el modelo le asignó 50.2 % de probabilidad; con la hoja limpia en PNG, 54.9 %; con la foto simulada, 13.9 %. El digitalizador leyó bien la foto, con una cobertura completa y una concordancia de 0.978 entre la tira de ritmo y el tramo de II, pero las pequeñas diferencias en la señal bastaron para mover un caso que ya estaba cerca del límite al otro lado del corte. Este ejemplo resume por

qué la interfaz muestra la señal digitalizada junto al resultado, por qué califica la certeza y por qué insiste en que un negativo no descarta un infarto.

3.19 Validación externa

Un modelo que funciona bien con datos de un hospital alemán de los años noventa no necesariamente funciona igual con pacientes de otro país, otros equipos u otra época. Por eso probamos los modelos, **sin ningún reentrenamiento ni cambio de corte**, en cuatro bases de datos públicas que nunca vieron durante su entrenamiento. Es la prueba más dura del proyecto y, a nuestro juicio, la más informativa.

Tabla 44. *Bases de datos usadas en la validación externa.*

Base	Origen	Electrocardiogramas evaluados	Con infarto	Modelo evaluado
SPH, Shandong Provincial Hospital (Liu et al., 2022)	China	25 770	260 (1.0 %)	Digital
PTB Diagnostic (Bousseljot et al., 1995)	Alemania	268	148 (55.2 %)	Digital
Georgia 12-Lead ECG Challenge (Perez Alday et al., 2020)	Estados Unidos	10 338	7 (0.07 %)	Digital
ECG Images of Cardiac Patients (Khan y Hussain, 2021)	Pakistán	928 fotografías	239 + 172 con antecedente	Impresos

3.19.1 Señales digitales de otros países

Tabla 45. *Desempeño del modelo digital (corte 0.3204) en bases externas.*

Base	Sensibilidad (IC 95 %)	Especificidad (IC 95 %)	AUC-ROC (IC 95 %)	Especificidad solo en normales
PTB-XL, prueba (referencia)	0.840 (0.808 – 0.871)	0.843 (0.825 – 0.861)	0.925 (0.913 – 0.937)	0.932
SPH (China)	0.965 (0.942 – 0.988)	0.896 (0.893 – 0.900)	0.984 (0.980 – 0.988)	0.958
PTB Diagnostic (Alemania)	0.858 (0.802 – 0.913)	0.700 (0.616 – 0.782)	0.868 (0.818 – 0.910)	0.981
Georgia (EE. UU.)	6 de 7 infartos	0.586	No interpretable	0.840

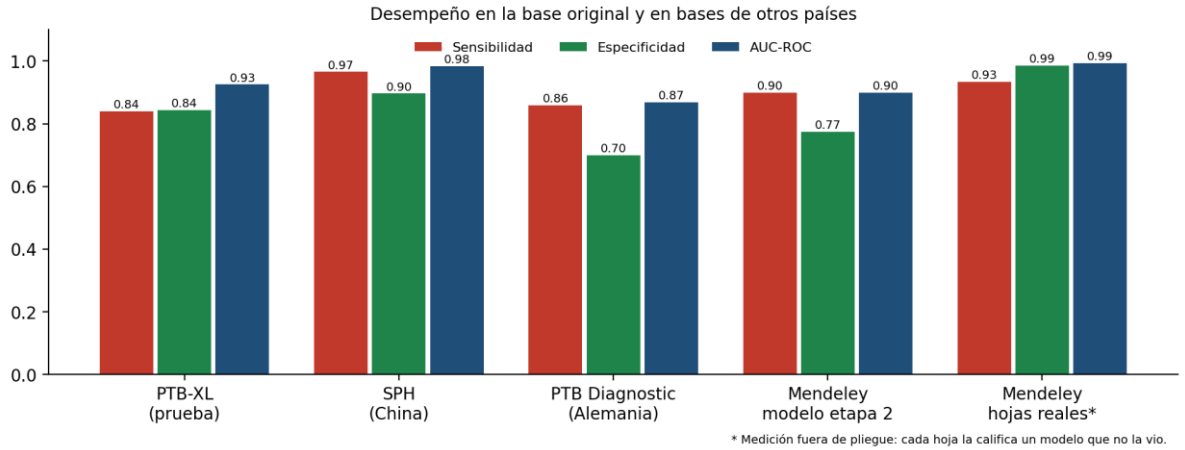


Figura 32. *Sensibilidad, especificidad y AUC-ROC en PTB-XL y en las bases externas. En Mendeley se muestran el modelo de la etapa 2 y el modelo ajustado con hojas reales, medido fuera de pliegue.*

SPH (China). Es la prueba externa más grande y el resultado fue mejor de lo esperado: detectó 251 de los 260 infartos y descartó correctamente 96 de cada 100 trazos normales. El AUC de 0.984 es incluso mayor que en PTB-XL. Una explicación probable es que en SPH los infartos anotados suelen ser casos claros y que los trazos se tomaron con equipos modernos y con menos ruido. Sin embargo, este resultado también enseña algo sobre la prevalencia: como solo 1 de cada 100 trazos tiene infarto, el valor predictivo positivo fue de apenas 0.087. De cada 100 alarmas, solo 9 fueron infartos reales, aunque el modelo casi nunca dejó pasar uno (valor predictivo negativo de 0.9996).

PTB Diagnostic (Alemania). Es una base antigua de la misma institución que PTB-XL, con muchos infartos y pocos controles. La sensibilidad fue de 0.858, muy parecida a la de PTB-XL, y la especificidad en trazos normales fue excelente, de 0.981. La especificidad global bajó a 0.700 porque buena parte de los trazos sin infarto son de pacientes con miocardiopatía, bloqueos de rama, hipertrofia o enfermedad valvular, justamente los grupos que más confunden al modelo: por ejemplo, marcó como infarto 12 de los 15 trazos con miocardiopatía.

Georgia (Estados Unidos). Solo tiene 7 infartos anotados, así que la sensibilidad y el AUC no se pueden interpretar (detectó 6 de 7). Lo valioso de esta base es la especificidad: 0.840 en trazos normales, pero 0.586 en conjunto, porque la mayoría de sus trazos tienen otras alteraciones. En particular, marcó como infarto 67 de cada 100 trazos con isquemia y 62 de cada 100 con onda Q anormal. Clínicamente, estos dos hallazgos están muy relacionados con el infarto, de modo que muchas de esas "falsas alarmas" corresponden a trazos que un médico también querría revisar con atención.

3.19.2 Fotografías reales de hojas impresas

La colección de Mendeley es la única de las cuatro con hojas reales: fotografías tomadas con celular de electrocardiogramas impresos en hospitales de Pakistán. Fue la prueba de fuego del digitalizador. Con la versión final, las 928 hojas se digitalizaron con una cobertura mediana del 100 % y una concordancia mediana de 0.996 entre la tira de ritmo y el tramo correspondiente. Un hallazgo inesperado fue que muchas de estas hojas no usan la derivación II como tira de ritmo; el digitalizador la identificó como II en 717 hojas, como III en 182, como aVF en 18, como V6 en 10 y como V3 en una. Sin esa identificación automática, la señal de casi una de cada cuatro hojas se habría colocado en la derivación equivocada.

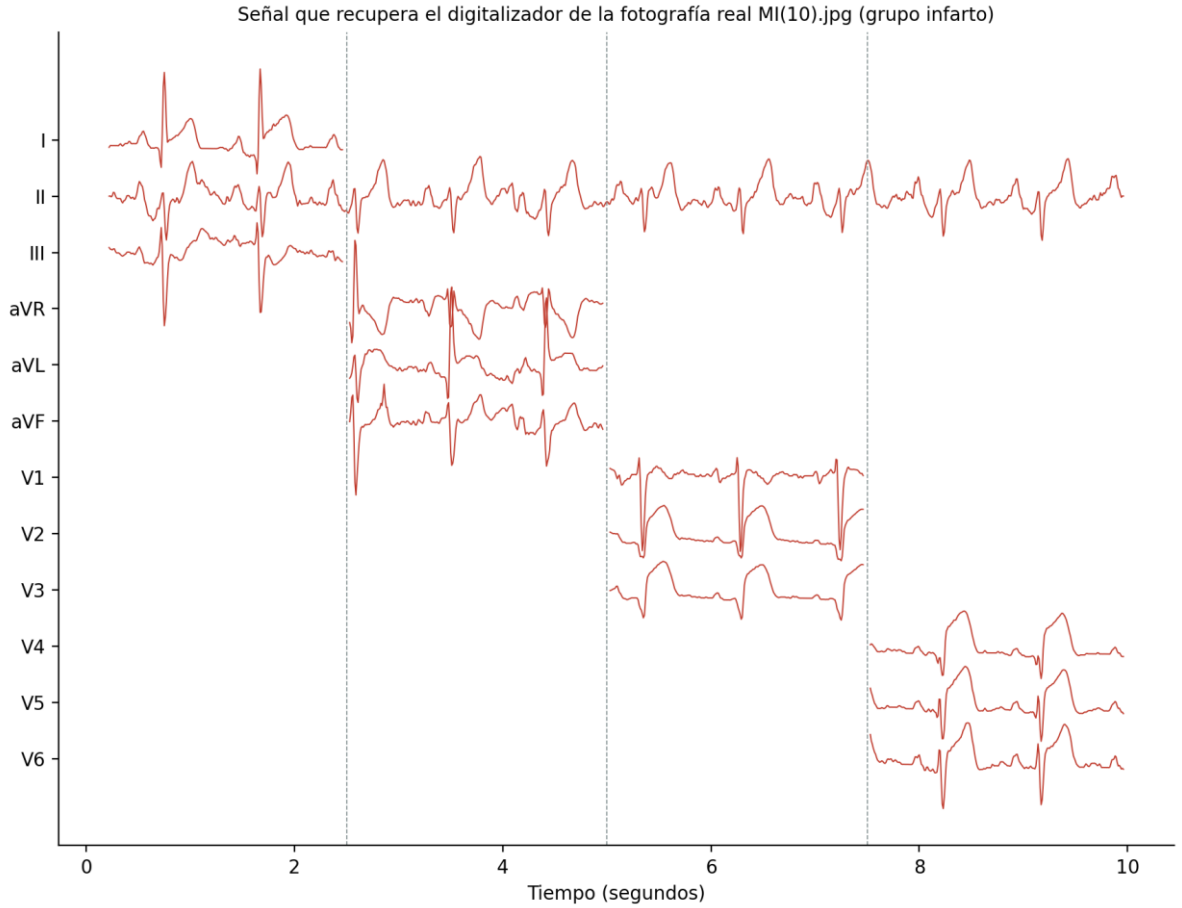


Figura 33. *Entrada que recibe el modelo después de digitalizar una fotografía real del grupo de infarto de Mendeley. Cada derivación ocupa su cuarto de tiempo y la tira de ritmo (II) aparece completa. Los valores están normalizados.*

La figura muestra lo que "ve" el modelo a partir de una de esas fotografías. Los complejos de cada derivación se reconocen con claridad, la línea base es estable y la tira de ritmo de la derivación II recorre los 10 segundos. En V1 a V3 se aprecia una forma del QRS y del segmento ST muy distinta de la de V4 a V6, el tipo de diferencia entre derivaciones vecinas que la red aprende a relacionar con un infarto.

Tabla 46. *Desempeño en las hojas reales de Mendeley: infarto (239) frente a normal (284).*

Modelo	Corte	Sensibilidad (IC 95 %)	Especificidad (IC 95 %)	AUC-ROC (IC 95 %)	VP / FN / FP / VN
Etapa 2, sin ajuste a hojas reales	0.3623	0.900 (0.861 – 0.936)	0.775 (0.728 – 0.824)	0.899 (0.872 – 0.928)	215 / 24 / 64 / 220
Ajustado con hojas reales, fuera de pliegue	0.9494	0.933 (0.901 – 0.963)	0.986 (0.970 – 0.997)	0.993 (0.984 – 0.999)	223 / 16 / 4 / 280

Sin haber visto nunca una hoja real, el modelo de la etapa 2 detectó 90 de cada 100 infartos y descartó 77 de cada 100 trazos normales, con un AUC de 0.899. Es un resultado razonable para un modelo entrenado solo con hojas sintéticas, y confirma que la cadena completa (foto, digitalización y modelo) funciona con documentos reales. El ajuste con validación cruzada mejoró mucho estas cifras: 93 de cada 100 infartos detectados y solo 4 falsas alarmas entre 284 normales. Como se explicó en la sección 3.10.6, cada hoja de esta medición fue calificada por un modelo que no la había visto, de modo que no se trata de cifras infladas por memorización.

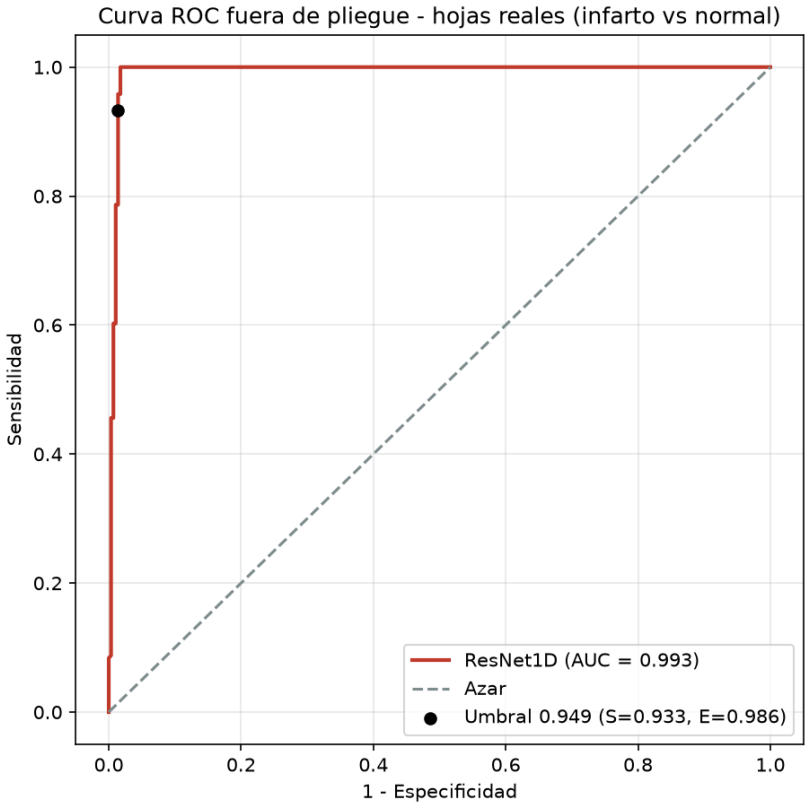


Figura 34. *Curva ROC fuera de pliegue del modelo ajustado con hojas reales (infarto frente a normal, 523 hojas). El punto marca el corte de 0.9494.*

Hay, sin embargo, dos advertencias importantes. La primera es que todas las hojas vienen del mismo origen, con el mismo tipo de equipo, el mismo estilo de impresión y probablemente las mismas condiciones de fotografía. Un modelo puede aprender a reconocer detalles de ese

estilo que no tienen nada que ver con el corazón. La caída del modelo ajustado en las señales de PTB-XL (sensibilidad de 0.518, sección 3.18.1) sugiere que algo de eso ocurrió. La segunda es que las 233 hojas de **latido anormal**, que no se usaron en el ajuste, sirven como prueba independiente de falsas alarmas: el modelo ajustado marcó como infarto 30.5 % de ellas, frente a 48.5 % del modelo de la etapa 2. Mejoró, pero sigue confundiendo uno de cada tres trazos con otra alteración, igual que en las bases digitales.

Tabla 47. *Porcentaje de hojas de Mendeley marcadas como infarto, por grupo.*

Grupo	Hojas	Etapa 2 (corte 0.3623)	Hojas reales (corte 0.9494)
Infarto	239	90.0 %	100 %*
Antecedente de infarto	172	93.0 %	94.2 %*
Latido anormal	233	48.5 %	30.5 %
Normal	284	22.5 %	1.4 %*

Los valores marcados con asterisco corresponden a hojas que el modelo final sí vio durante su ajuste, por lo que no miden su desempeño con hojas nuevas; se incluyen solo para mostrar que el modelo aprendió bien su conjunto de entrenamiento. Las cifras confiables del modelo ajustado son las de la medición fuera de pliegue (tabla anterior) y la de latido anormal. Llama la atención que las hojas con **antecedente de infarto** se marquen en más de 93 de cada 100 casos con ambos modelos. Esto es coherente con lo que se dijo de PTB-XL: el modelo reconoce las huellas eléctricas del infarto, sean recientes o antiguas, y no puede saber cuándo ocurrió.

3.19.3 Qué tanto marca el sistema según el tipo de trazo

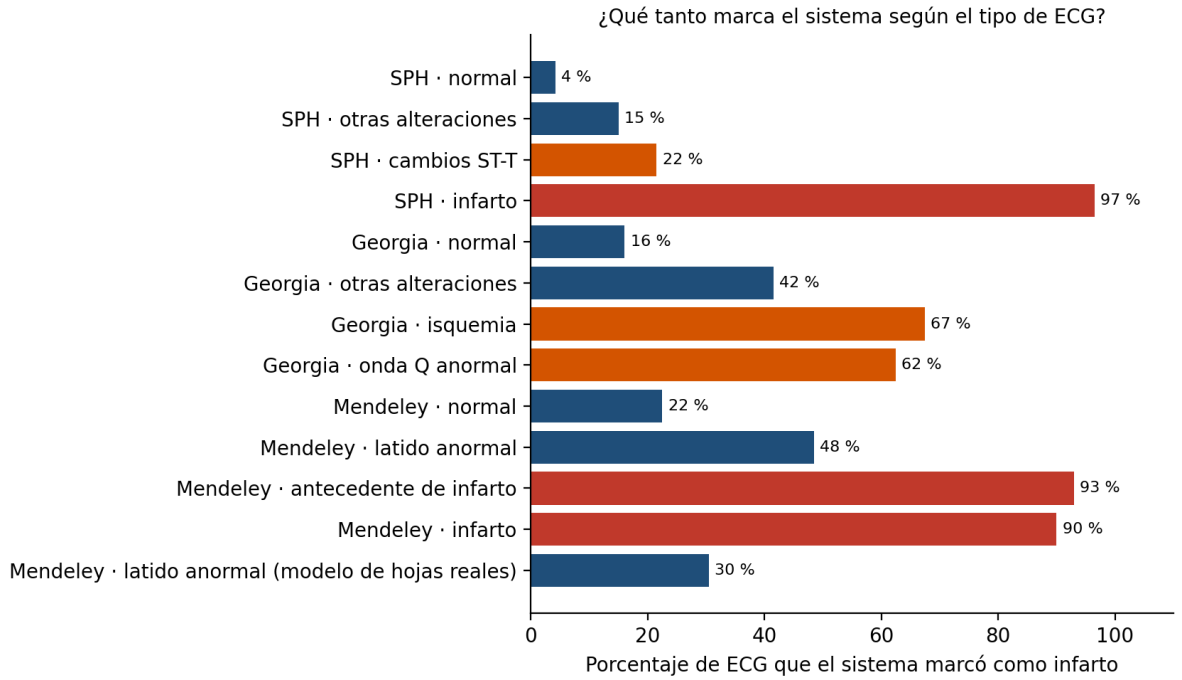


Figura 35. *Porcentaje de electrocardiogramas marcados como infarto en cada grupo de las bases externas. En rojo, los grupos con infarto; en naranja, los grupos con hallazgos isquémicos; en azul, el resto.*

Esta figura resume la validación externa en una sola imagen y muestra un patrón muy consistente. En las cuatro bases, los trazos con infarto se marcan con mucha frecuencia (entre 86 y 97 de cada 100), los normales se marcan poco y los trazos con otras alteraciones quedan en medio. Los hallazgos isquémicos, como la isquemia y la onda Q anormal de Georgia, se marcan con frecuencia alta, lo cual es clínicamente comprensible. La lección general es que el sistema distingue muy bien un infarto de un corazón sano, pero le cuesta más distinguir un infarto de otras enfermedades del corazón. Ese es el escenario más común en un servicio real, y por eso el sistema debe usarse como apoyo y no como sustituto del médico.

3.20 Cumplimiento de los objetivos

En la tabla siguiente revisamos cada objetivo del anteproyecto y lo comparamos con lo que se logró. Somos estrictos en la evaluación: un objetivo se marca como cumplido solo si la evidencia lo respalda sin interpretaciones generosas.

Tabla 48. *Cumplimiento de los objetivos específicos del anteproyecto.*

Objetivo	Meta	Resultado	Estado
Preparar PTB-XL (filtrado, normalización, segmentación)	≥ 90 % de registros utilizables	100 % (21 799 de 21 799); filtrado de 0.5 a 40 Hz y normalización por derivación	Cumplido
Entrenar una ResNet1D en	Sensibilidad y	Digital: 0.840 y 0.843 en prueba (IC	Parcial: muy cerca

Objetivo	Meta	Resultado	Estado
PyTorch	especificidad ≥ 85 %	de la sensibilidad 0.808 – 0.871). Impresos, vista 3 × 4: 0.844 y 0.852	de la meta; 0.85 dentro del intervalo de confianza
Evaluar con sensibilidad, especificidad, F1 y AUC-ROC, comparando con Ribeiro et al. (2020)	AUC > 0.90	AUC 0.925 (0.913 – 0.937), F1 0.727, intervalos de confianza y validación externa en cuatro bases	Cumplido (con la comparación matizada en 3.21)
Grad-CAM 1D para relacionar la decisión con la onda Q, el ST y la onda T	Mapa interpretable	Mapa por derivación y reparto de la activación por ventanas de onda Q, ST y onda T, latido a latido	Cumplido (orientativo)
Interfaz web para cargar un ECG y ver diagnóstico, señal resaltada y confianza	Interfaz funcional	Interfaz con carga de archivos digitales e impresos, resultado, certeza, Grad-CAM, historial y demostración pública	Cumplido

El único objetivo que no se cumplió por completo es el de sensibilidad del modelo digital, que quedó en 0.840 frente a la meta de 0.85. Queremos ser claros con este punto: la diferencia es de un punto porcentual, equivale a unos cinco infartos de 550 y está dentro del margen de error de la medición, pero la estimación puntual no alcanza la meta. Habría sido fácil "cumplirla" bajando el corte después de ver los resultados de prueba, pero eso habría invalidado la medición. Preferimos reportar el número real. Vale la pena notar que el corte se eligió para cumplir la meta en validación (0.852) y que el modelo de impresos sí la alcanza en la vista 3 × 4 y en los cuatro tipos de documento digitalizados.

Además de los objetivos originales, se cumplieron las tres metas agregadas durante el desarrollo: la lectura de hojas impresas en PDF, escaneo y foto; la detección automática de la frecuencia de muestreo, que acierta en 95.6 % de 3 600 pruebas; y la validación externa en bases de cuatro países.

3.21 Comparación con la literatura

Comparar resultados entre trabajos es delicado, porque cada uno usa datos, tareas y formas de medir diferentes. Por eso dividimos la comparación en dos: los trabajos que usan los mismos datos y la misma partición, con los que la comparación es razonable, y los que usan otros datos, con los que solo es orientativa.

Tabla 49. *Comparación con trabajos de referencia.*

Trabajo	Datos y tarea	Métrica	Valor	¿Comparable?
Este trabajo, modelo digital	PTB-XL, pliegue 10; infarto frente al resto	AUC del infarto	0.925	—
Strodthoff et al. (2021), resnet1d_wang	PTB-XL, pliegue 10; cinco superclases	AUC promedio de las cinco clases	0.930	Parcialmente: misma partición, otra tarea

Trabajo	Datos y tarea	Métrica	Valor	¿Comparable?
Strodthoff et al. (2021), xresnet1d101	PTB-XL, pliegue 10; cinco superclases	AUC promedio de las cinco clases	0.928	Parcialmente
Ribeiro et al. (2020)	Más de 2 millones de ECG de Brasil; seis anomalías de ritmo y conducción	F1 por clase	0.870 – 1.000	No: otra base, otras clases, sin infarto

Con el banco de pruebas de Strodthoff et al. (2021) compartimos la base y la partición de prueba. Su tarea es más amplia, porque clasifica cinco superclases a la vez, y reportan el promedio de las cinco. Nuestro AUC de 0.925 para el infarto cae en el mismo rango que sus mejores redes convolucionales, que obtienen alrededor de 0.93. Esto nos da confianza en que el modelo está en el nivel esperable para esta base y que no hay un error grave en el entrenamiento ni en la evaluación.

El anteproyecto proponía a Ribeiro et al. (2020) como línea base. Al estudiar el trabajo con detalle encontramos que no evalúa infarto y que usa otra base de datos, de modo que sus cifras de F1 (entre 0.87 y 1.00) no se pueden comparar con las nuestras sin hacer trampa. Lo que sí tomamos de ese trabajo fue la arquitectura: una red residual unidimensional que recibe las doce derivaciones como canales y aprende directamente de la señal cruda. En ese sentido, el proyecto confirma que su enfoque se puede trasladar con éxito a la detección de infarto con datos públicos.

Respecto a la lectura de hojas impresas, la iniciativa más cercana es el PhysioNet Challenge 2024, que propuso digitalizar y clasificar electrocardiogramas a partir de imágenes. No comparamos cifras directamente porque las condiciones de evaluación son distintas, pero el enfoque de nuestro digitalizador, que calibra con la cuadrícula y sigue el trazo fila por fila, es coherente con las soluciones de ese tipo y obtuvo correlaciones medianas de 0.96 a 0.99 con las señales originales.

3.22 Discusión y limitaciones

Los resultados permiten responder con bastante claridad las preguntas que guiaron el trabajo, pero también dejan ver los límites del sistema. Los agrupamos en cinco temas.

Lo que el modelo aprende

PTB-XL no distingue entre un infarto agudo y uno antiguo, así que el modelo aprende a reconocer patrones eléctricos de infarto, recientes o no. La validación con Mendeley lo confirma: las hojas con antecedente de infarto se marcan tanto como las de infarto actual. En

urgencias esto importa, porque un paciente con un infarto antiguo y dolor en el pecho por otra causa podría recibir un resultado positivo. El sistema no sustituye la historia clínica, la exploración ni la troponina.

Las falsas alarmas

La mayoría de las falsas alarmas aparecen en trazos con otras alteraciones del corazón: cambios del ST-T, bloqueos de rama, hipertrofia, miocardiopatías. Este patrón se repitió en PTB-XL, en las tres bases digitales externas y en las hojas de Mendeley, así que es una característica del modelo y no una casualidad. Reducirlo requeriría entrenar con más ejemplos de esos grupos o pasar a un modelo que reconozca varias enfermedades a la vez, en lugar de responder solo "infarto sí o no".

Los infartos que se escapan

Los infartos laterales y anterolaterales son los más difíciles de detectar, y también se escapan más infartos en personas jóvenes y en mujeres. Son grupos con pocos ejemplos, así que las cifras tienen un margen de error amplio, pero en todos los casos la dirección coincide con lo que se sabe de la clínica. Un resultado negativo nunca debe usarse para descartar un infarto.

Las hojas impresas y la elección del modelo

El digitalizador funcionó muy bien con hojas sintéticas y con las hojas reales de Pakistán, pero exige el formato 3 × 4 a 25 mm/s y 10 mm/mV y la hoja completa en la imagen. Las fotos tomadas en ángulo extremo, con sombras fuertes o cortadas siguen siendo el punto débil: cerca del 2 % no se pueden digitalizar y alrededor del 1 % se digitaliza mal sin que el control de calidad lo detecte. Por eso la interfaz muestra la señal recuperada para que el usuario la compare con su hoja.

La elección del modelo por extensión de archivo es una solución práctica a un problema real: ningún modelo era el mejor para todos los tipos de hoja. El modelo de hojas reales es excelente con hojas como las de Mendeley, pero pierde mucho con hojas de otro estilo, y no hay forma de saber por la extensión de qué estilo es una foto. Un usuario con un electrocardiógrafo distinto que suba una foto en JPG obtendría el resultado de un modelo que nunca vio hojas como la suya. Además, el panel de desempeño de la interfaz todavía muestra las cifras del modelo de la etapa 2, que son las correctas para PDF y PNG, pero no para fotografías JPG. Ambas situaciones están documentadas como trabajo pendiente.

La explicación visual

Grad-CAM indica en qué momentos del trazo se apoyó la red, pero no prueba que ahí exista una lesión. La capa de la que se obtiene el mapa tiene una resolución temporal baja, por lo que cada zona resaltada abarca varios latidos y el reparto entre onda Q, ST y onda T tiende a ser parejo. Es una herramienta útil para detectar decisiones sospechosas, por ejemplo cuando la red se fija en ruido o en un borde de la hoja, pero no para localizar el infarto con precisión.

Validez de las mediciones

Todas las cifras de este capítulo se obtuvieron con datos retrospectivos de bases públicas. No hubo una prueba prospectiva con pacientes de Tijuana ni una comparación directa con médicos leyendo los mismos trazos. Las bases externas tienen sus propios sesgos: SPH parece contener infartos especialmente claros, Georgia casi no tiene infartos y las hojas de Mendeley vienen de un solo origen. Antes de cualquier uso clínico, el sistema tendría que pasar por una validación prospectiva y por los procesos regulatorios correspondientes.

3.23 Productos entregables

Al cierre de la residencia el proyecto entrega los siguientes productos, todos disponibles en el repositorio del equipo:

Tabla 50. *Productos entregables del proyecto.*

Producto	Descripción	Ubicación
Código del modelo	Arquitectura ResNet1D, preprocesamiento, entrenamiento, evaluación, explicabilidad y digitalización	modelo_ia/
Modelos entrenados	Digital (corte 0.3204), impresos etapa 2 (0.3623) y hojas reales (0.9494)	modelo_ia/puntos_control/ (se entregan aparte por su tamaño)
Servidor y API	FastAPI con análisis, historial, salud y caso de ejemplo	backend/
Interfaz web	Carga, resultado, certeza, Grad-CAM, historial y vista de la red	frontend/
Base de datos	Esquema SQL del historial de análisis	base_de_datos/
Scripts	Exploración, preprocesamiento, entrenamiento, evaluación, validación externa, ajuste con hojas reales y exportaciones	scripts/
Resultados	Métricas en JSON, curvas ROC y PR, matrices de confusión y probabilidades por registro	documentos/resultados/
Ejemplos	Electrocardiogramas de prueba con y sin infarto en WFDB, CSV y NPY	dataset/ejemplos/
Demostración pública	Versión estática con cinco casos de PTB-XL	https://alejandroonm.github.io/Residencia2026/
Documentación	README, comparación con la literatura	README.md y documentos/

Producto	Descripción	Ubicación
	y este informe técnico	

Capítulo IV. Conclusiones

4.1 Conclusiones generales

Al inicio de la residencia nos propusimos construir un sistema que, a partir de un electrocardiograma de 12 derivaciones, estimara la probabilidad de un infarto y mostrara en qué parte del trazo se apoyó para decidir. Al cierre, el sistema existe, funciona de punta a punta y está medido con cuidado. Una persona puede subir un archivo digital, un PDF, un escaneo o una foto de una hoja impresa, y en unos segundos recibe la probabilidad, una indicación de qué tan seguro está el modelo, la señal que se analizó y un mapa de las zonas que más pesaron en la decisión.

El modelo central, una red residual unidimensional entrenada con PTB-XL, alcanzó en el grupo de prueba una sensibilidad de 0.840, una especificidad de 0.843 y un AUC de 0.925. Dos de las tres metas numéricas se cumplieron con holgura y la tercera, la sensibilidad, quedó un punto por debajo de 0.85, dentro del margen de error de la medición. Preferimos reportar ese número tal como salió antes que ajustar el corte después de ver los resultados, porque una cifra maquillada no le serviría a nadie que tuviera que confiar en la herramienta.

La validación con bases de otros países fue, probablemente, la parte más valiosa del proyecto. Mostró que el modelo detecta con mucha consistencia los infartos de China, Alemania, Estados Unidos y Pakistán, entre 86 y 97 de cada 100, y que su punto débil no es una población en particular, sino un tipo de paciente: el que tiene otras enfermedades del corazón. Ese hallazgo, que se repitió en todas las bases, define con claridad cómo se debe usar el sistema: como una segunda lectura que llama la atención sobre un trazo, no como un juez que decide.

El digitalizador de hojas impresas surgió como una necesidad práctica y terminó siendo uno de los aportes más originales. Recupera la señal de un PDF o una imagen limpia casi sin pérdida y la de una foto con una pérdida pequeña. Con fotografías reales de hojas de Pakistán digitalizó las 928 hojas, identificó automáticamente qué derivación aparecía en la tira de ritmo y, con el modelo ajustado a esas hojas, detectó 93 de cada 100 infartos con muy pocas falsas alarmas. Ese ajuste también enseñó una lección: un modelo que se especializa demasiado en un estilo de hoja pierde capacidad con otros. Por eso el sistema usa hoy dos modelos de impresos y elige uno según el tipo de archivo.

Por último, el proyecto dejó un producto documentado y reproducible: el código, los scripts para repetir cada experimento, los resultados en archivos abiertos, una interfaz pensada para profesionales de la salud y una demostración pública. Cualquier estudiante del instituto puede tomar este trabajo, repetir las mediciones y continuar a partir de él.

4.2 Respuesta a las preguntas de investigación

En el Capítulo I planteamos cinco preguntas. Con los resultados en la mano, las respuestas son las siguientes.

1. **¿Puede una red neuronal entrenada con datos públicos alcanzar una sensibilidad y una especificidad de al menos 85 %?** Casi. La especificidad (0.843) y el AUC (0.925) cumplen las metas y la sensibilidad queda en 0.840, con un intervalo de confianza que incluye el 0.85. El modelo de impresos sí supera ambas metas en la vista 3 × 4 y en los documentos digitalizados.
2. **¿Se puede mostrar en qué parte del trazo se apoyó la red?** Sí, con Grad-CAM. El mapa permite ver si la red se fijó en los complejos del corazón o en algo sospechoso, como ruido o un borde de la hoja. Su resolución, sin embargo, no alcanza para atribuir la decisión con precisión a la onda Q, al segmento ST o a la onda T por separado.
3. **¿Se puede recuperar la señal de una hoja impresa, un escaneo o una foto?** Sí. Con PDF e imágenes la correlación mediana con la señal original es de 0.98 a 0.99, con escaneos de 0.977 y con fotos de 0.958. El sistema completo mantiene una sensibilidad mayor a 0.91 en los cuatro tipos de documento.
4. **¿Qué tan bien funciona con electrocardiogramas de otros países?** Detecta bien los infartos en las cuatro bases externas. La especificidad depende de qué tan frecuentes sean las otras alteraciones cardiacas en cada base: es muy alta con trazos normales y baja con trazos de pacientes con otras enfermedades del corazón.
5. **¿Cómo presentar el resultado para que se entienda su alcance?** Con un veredicto en lenguaje claro, la probabilidad junto al punto de corte, una calificación de certeza, la señal analizada, el mapa de explicabilidad y un panel que explica el desempeño y las limitaciones del modelo, siempre con el aviso de que el resultado debe confirmarlo un médico.

4.3 Competencias desarrolladas

La residencia nos permitió poner en práctica conocimientos de la carrera y adquirir otros que no forman parte del plan de estudios. Las competencias más importantes fueron las siguientes:

- **Aprendizaje profundo aplicado:** diseño de una arquitectura residual, manejo del desbalance de clases, aumento de datos, parada temprana, ajuste fino por etapas y validación cruzada con pocos datos.
- **Evaluación rigurosa de modelos:** separación estricta entre entrenamiento, validación y prueba; elección del punto de corte con un criterio fijado de antemano; intervalos de confianza por bootstrap; análisis de errores por subgrupo y validación externa.
- **Procesamiento de señales:** filtrado, remuestreo, normalización y detección de latidos en señales fisiológicas reales, con ruido y defectos.
- **Visión por computadora:** corrección de perspectiva, calibración con la cuadrícula del papel y seguimiento de trazos para convertir una imagen en una señal.
- **Desarrollo de software completo:** una API con FastAPI, una base de datos con SQLAlchemy, una interfaz web y la publicación de una demostración estática.
- **Conocimiento del dominio médico:** lectura básica del electrocardiograma, signos del infarto, uso de guías clínicas y comunicación de resultados a profesionales de la salud.
- **Trabajo en equipo y control de versiones:** organización del trabajo en un repositorio compartido con Git, revisión de cambios y documentación continua.
- **Comunicación escrita y ética profesional:** reportar resultados que no cumplen la meta con la misma claridad que los que sí, y explicar las limitaciones de una herramienta de salud sin exagerar sus capacidades.

4.4 Trabajo futuro

El sistema es un prototipo sólido, pero hay varias líneas claras para mejorarlo. Las ordenamos según el beneficio que esperamos de cada una.

1. **Un solo modelo de impresos para todo tipo de hoja.** Volver a ajustar el modelo de hojas reales mezclando las fotografías de Mendeley con hojas sintéticas de PTB-XL, para que aprenda el estilo real sin olvidar el resto. Con eso se podría eliminar la elección por extensión de archivo.

2. **Más hojas reales de distintos orígenes.** Conseguir, con los permisos correspondientes, electrocardiogramas impresos de equipos usados en México, idealmente de una unidad médica de Tijuana, para medir el sistema en el contexto donde se usaría.
3. **Reducir las falsas alarmas en pacientes con otras enfermedades.** Entrenar un modelo que reconozca varias clases a la vez (infarto, cambios del ST-T, bloqueos, hipertrofia) para que aprenda a distinguirlas en lugar de agruparlas como "no infarto".
4. **Distinguir infarto agudo de antiguo.** Usar bases con anotaciones de la fecha del evento o combinar el electrocardiograma con datos clínicos como la troponina.
5. **Mejorar la explicabilidad.** Obtener el mapa de una capa con más resolución temporal o probar otras técnicas de atribución que permitan señalar latidos y ondas concretas.
6. **Actualizar el panel de desempeño** para que muestre las cifras del modelo que realmente analizó cada archivo, incluidas las del modelo de fotografías.
7. **Validación prospectiva y con especialistas.** Comparar el sistema con cardiólogos y médicos generales leyendo los mismos trazos y, si los resultados lo justifican, iniciar el camino regulatorio que exigiría un uso clínico.

4.5 Lo que aprendimos en el camino

Más allá de las cifras, la residencia nos dejó varias lecciones que no aparecen en ningún libro de texto y que creemos útiles para quien haga un proyecto parecido.

Desconfiar de los números demasiado buenos. Más de una vez obtuvimos un resultado que parecía excelente y que, al revisarlo, escondía un problema: una medición que reutilizaba datos de entrenamiento, un corte elegido con los mismos datos con los que se evaluaba o un modelo que funcionaba de maravilla en un tipo de hoja y mal en otro. El ajuste con hojas reales es el mejor ejemplo: el AUC de 0.993 era verdadero para esas hojas, pero la medición con PTB-XL mostró que no era toda la historia. Aprendimos a preguntarnos siempre "¿con qué datos se midió esto y qué no se midió?".

Medir antes de cambiar. Cada cambio importante, como un nuevo modelo, un ajuste al digitalizador o un nuevo punto de corte, se acompañó de una medición con los mismos datos y el mismo procedimiento que la versión anterior. Esa disciplina nos permitió decidir con evidencia qué conservar y qué descartar, como ocurrió con los experimentos de 16 y 100 épocas adicionales, que no se adoptaron.

El problema real es más amplio que el del artículo. Al empezar pensábamos que el reto era entrenar una buena red. Resultó que la red era solo una parte: leer archivos con frecuencias desconocidas, digitalizar hojas impresas, presentar la incertidumbre y explicar las limitaciones nos llevó tanto o más tiempo que el modelo. Un sistema útil se construye pensando en quién lo va a usar y con qué archivos.

Escribir para quien no estuvo ahí. Documentar cada decisión mientras se tomaba, en el repositorio y en los archivos de resultados, hizo posible escribir este informe con cifras exactas y no de memoria. También nos obligó a explicar las cosas con palabras sencillas, lo cual muchas veces reveló que no las entendíamos tan bien como creíamos.

4.6 Recomendaciones

Para quien quiera usar o continuar el sistema recomendamos: no usarlo como única base para una decisión clínica; revisar siempre la señal digitalizada cuando se suba una hoja impresa; dar más peso a un resultado positivo en pacientes sin enfermedad cardiaca conocida y menos en pacientes con bloqueos, hipertrofia o cambios del ST-T previos; nunca descartar un infarto por un resultado negativo; y, si se modifica el modelo, repetir todas las mediciones de este informe con los scripts del proyecto antes de cambiar el que usa la aplicación.

Referencias

Attia, Z. I., Kapa, S., Lopez-Jimenez, F., McKie, P. M., Ladewig, D. J., Satam, G., … Friedman, P. A. (2019). Screening for cardiac contractile dysfunction using an artificial intelligence–enabled electrocardiogram. Nature Medicine, 25(1), 70–74. https://doi.org/10.1038/s41591-018-0240-2

Bousseljot, R., Kreiseler, D., & Schnabel, A. (1995). Nutzung der EKG-Signaldatenbank CARDIODAT der PTB über das Internet. Biomedizinische Technik, 40(S1), 317–318.

Byrne, R. A., Rossello, X., Coughlan, J. J., Barbato, E., Berry, C., Chieffo, A., … ESC Scientific Document Group. (2023). 2023 ESC Guidelines for the management of acute coronary syndromes. European Heart Journal, 44(38), 3720–3826. https://doi.org/10.1093/eurheartj/ehad191

Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman & Hall.

Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., … Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. Circulation, 101(23), e215–e220. https://doi.org/10.1161/01.CIR.101.23.e215

Hannun, A. Y., Rajpurkar, P., Haghpanahi, M., Tison, G. H., Bourn, C., Turakhia, M. P., & Ng, A. Y. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. Nature Medicine, 25(1), 65–69. https://doi.org/10.1038/s41591-018-0268-3

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. En Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770–778). https://doi.org/10.1109/CVPR.2016.90

Ibanez, B., James, S., Agewall, S., Antunes, M. J., Bucciarelli-Ducci, C., Bueno, H., … ESC Scientific Document Group. (2018). 2017 ESC Guidelines for the management of acute myocardial infarction in patients presenting with ST-segment elevation. European Heart Journal, 39(2), 119–177. https://doi.org/10.1093/eurheartj/ehx393

Instituto Nacional de Estadística y Geografía. (2024). Estadísticas de defunciones registradas 2023. INEGI.

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. En Proceedings of the 32nd International Conference on Machine Learning (pp. 448–456). PMLR.

Khan, A. H., & Hussain, M. (2021). ECG images dataset of cardiac patients (Versión 2) [Conjunto de datos]. Mendeley Data. https://doi.org/10.17632/gwbz3fsgp8.2

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. En International Conference on Learning Representations. https://arxiv.org/abs/1412.6980

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. En Advances in Neural Information Processing Systems 25 (pp. 1097–1105).

LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4), 541–551. https://doi.org/10.1162/neco.1989.1.4.541

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324. https://doi.org/10.1109/5.726791

Liu, H., Chen, D., Chen, D., Zhang, X., Li, H., Bian, L., Shu, M., & Wang, Y. (2022). A large-scale multi-label 12-lead electrocardiogram database with standardized diagnostic statements. Scientific Data, 9, 272. https://doi.org/10.1038/s41597-022-01403-5

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. En International Conference on Learning Representations. https://arxiv.org/abs/1711.05101

Organización Mundial de la Salud. (2021). Enfermedades cardiovasculares [Nota descriptiva]. https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., … Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. En Advances in Neural Information Processing Systems 32 (pp. 8024–8035).

Perez Alday, E. A., Gu, A., Shah, A. J., Robichaux, C., Wong, A.-K. I., Liu, C., … Reyna, M. A. (2020). Classification of 12-lead ECGs: The PhysioNet/Computing in Cardiology Challenge 2020. Physiological Measurement, 41(12), 124003. https://doi.org/10.1088/1361-6579/abc960

Reyna, M. A., Deepanshi, Weigle, J., Koscova, Z., Campbell, K., Shivashankara, K. K., … Sameni, R. (2024). Digitization and classification of ECG images: The George B. Moody PhysioNet Challenge 2024. Computing in Cardiology, 51.

Ribeiro, A. H., Ribeiro, M. H., Paixão, G. M. M., Oliveira, D. M., Gomes, P. R., Canazart, J. A., … Ribeiro, A. L. P. (2020). Automatic diagnosis of the 12-lead ECG using a deep neural network. Nature Communications, 11, 1760. https://doi.org/10.1038/s41467-020-15432-4

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En Proceedings of the IEEE International Conference on Computer Vision (pp. 618–626). https://doi.org/10.1109/ICCV.2017.74

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15(56), 1929–1958.

Strodthoff, N., Wagner, P., Schaeffter, T., & Samek, W. (2021). Deep learning for ECG analysis: Benchmarks and insights from PTB-XL. IEEE Journal of Biomedical and Health Informatics, 25(5), 1519–1528. https://doi.org/10.1109/JBHI.2020.3022989

Thygesen, K., Alpert, J. S., Jaffe, A. S., Chaitman, B. R., Bax, J. J., Morrow, D. A., & White, H. D. (2018). Fourth universal definition of myocardial infarction (2018). Circulation, 138(20), e618–e651. https://doi.org/10.1161/CIR.0000000000000617

Wagner, P., Strodthoff, N., Bousseljot, R.-D., Kreiseler, D., Lunze, F. I., Samek, W., & Schaeffter, T. (2020). PTB-XL, a large publicly available electrocardiography dataset. Scientific Data, 7, 154. https://doi.org/10.1038/s41597-020-0495-6

Youden, W. J. (1950). Index for rating diagnostic tests. Cancer, 3(1), 32–35.

Anexos

Los anexos reúnen información práctica para usar, instalar y continuar el sistema. No es necesario leerlos para entender el informe, pero son la referencia para quien quiera repetir el trabajo.

Anexo A. Manual de uso

Este manual está pensado para un profesional de la salud o un estudiante que usa la aplicación por primera vez. Se supone que el servidor ya está en marcha (ver Anexo B).

A.1 Abrir la aplicación

Abra un navegador web (Chrome, Edge o Firefox) y entre a la dirección http://127.0.0.1:8000. Aparecerá la pantalla de inicio de CardiologIA con una breve descripción de la herramienta y el área para subir archivos. Si solo quiere conocer la herramienta sin instalar nada, puede usar la demostración pública en https://alejandroonm.github.io/Residencia2026/, que muestra casos de ejemplo ya analizados.

A.2 Preparar el archivo

El sistema acepta dos tipos de entrada:

- **Señal digital:** el par de archivos .hea y .dat de un registro WFDB (hay que seleccionar los dos a la vez), un archivo .csv o .txt con 12 columnas en el orden I, II, III, aVR, aVL, aVF, V1 a V6, o un archivo .npy con la misma forma. La señal debe durar al menos 5 segundos; lo ideal son 10.
- **Hoja impresa:** un PDF, una imagen PNG o una fotografía JPG de la hoja completa en formato 3 × 4, impresa a 25 mm/s y 10 mm/mV. Los PDF y PNG se analizan con el modelo de la etapa 2 y las fotografías JPG con el modelo ajustado a hojas reales.

Para una fotografía, coloque la hoja sobre una superficie plana y de color uniforme, tómela de frente, con buena luz y sin sombras ni reflejos, y asegúrese de que se vean los cuatro bordes de la cuadrícula. Una foto torcida o cortada puede digitalizarse mal.

A.3 Analizar

1. Arrastre el archivo al área de carga o haga clic en ella para elegirlo.

2. Si subió un CSV, TXT o NPY y conoce con certeza la frecuencia de muestreo del equipo, puede elegirla en la lista “Forzar frecuencia de muestreo”; si no, déjela vacía y el sistema la detectará.
3. Pulse el botón “Analizar” y espere unos segundos. Las hojas impresas tardan un poco más porque primero deben digitalizarse.

A.4 Leer el resultado

- **Veredicto:** “Compatible con IAM” o “Sin patrón de IAM”.
- **Probabilidad y punto de corte:** una barra muestra la probabilidad que calculó el modelo y la línea del punto de corte. Si la probabilidad está a la derecha de la línea, el resultado es positivo.
- **Certeza:** alta, media o baja según qué tan lejos esté la probabilidad del corte. Un resultado con certeza baja debe tomarse con especial cautela.
- **Señal analizada:** las derivaciones que vio el modelo. En hojas impresas, compárelas con su hoja: si el trazo recuperado no se parece al de la hoja, el resultado no es confiable.
- **Explicación visual:** las zonas en rojo son los momentos del trazo que más pesaron en la decisión, y una gráfica reparte esa importancia entre onda Q, segmento ST y onda T.
- **Advertencias:** mensajes sobre la frecuencia estimada, la duración de la señal o la calidad de la digitalización.
- **Historial:** los análisis recientes aparecen en una tabla al final de la página.

El resultado es un apoyo y no un diagnóstico. Un resultado negativo no descarta un infarto, y un resultado positivo debe confirmarse con la valoración médica, la evolución de los síntomas y los estudios de laboratorio.

A.5 Mensajes de error frecuentes

Tabla 51. *Mensajes de error frecuentes y qué hacer.*

Mensaje	Causa	Qué hacer
El formato WFDB requiere subir juntos un archivo .hea y un .dat	Se subió solo uno de los dos archivos	Seleccione ambos archivos a la vez
La señal dura X s; se requieren al menos 5 s	El registro es demasiado corto	Use un registro de al menos 5 s, idealmente 10 s
Se detectaron 0 filas de trazo	La imagen no muestra una hoja 3 × 4 reconocible	Tome de nuevo la foto, completa, de frente y con buena luz
La longitud de las filas no corresponde a 10 s a 25 mm/s	La hoja está cortada, deformada o impresa a otra velocidad	Verifique que la hoja esté completa y a 25 mm/s
El archivo excede el tamaño máximo	El archivo pesa más de 20 MB	Reduzca la resolución de la imagen

Anexo B. Guía de instalación

El sistema funciona en Windows, Linux o macOS con Python 3.11 o superior. Para usarlo no se necesita una tarjeta gráfica; solo para entrenar los modelos.

1. Clonar el repositorio y crear un entorno virtual:

```
git clone https://github.com/AlejandrooNM/Residencia2026.git
cd Residencia2026
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
pip install -r requisitos.txt
copy .env.ejemplo .env
```

2. Copiar los modelos entrenados, que se entregan aparte por su tamaño (unos 33 MB cada uno), a la carpeta modelo_ia/puntos_control/, en las subcarpetas resnet1d_estandar_100hz, resnet1d_estandar_impreso_digitalizado_100hz y resnet1d_estandar_impreso_hojas_reales_100hz.

3. Iniciar el servidor:

```
python scripts/iniciar_api.py
```

4. Abrir http://127.0.0.1:8000 en el navegador. La documentación interactiva de la API está en http://127.0.0.1:8000/docs.

Las rutas de los modelos y los puntos de corte se pueden cambiar en el archivo .env:

Tabla 52. *Variables de configuración principales.*

Variable	Valor por defecto	Uso
RUTA_CHECKPOINT	…/resnet1d_estandar_100hz/mejor.pt	Modelo de señales digitales
UMBRAL_CLASIFICACION	0.3204	Corte del modelo digital
RUTA_CHECKPOINT_DIGITALIZADO	…/resnet1d_estandar_impreso_digitalizado_100hz/mejor.pt	Modelo para PDF y PNG
UMBRAL_CLASIFICACION_DIGITALIZADO	0.3623	Corte para PDF y PNG
RUTA_CHECKPOINT_IMPRESO	…/resnet1d_estandar_impreso_hojas_reales_100hz/mejor.pt	Modelo para fotografías JPG
UMBRAL_CLASIFICACION_IMPRESO	0.9494	Corte para fotografías JPG
URL_BASE_DE_DATOS	sqlite:///./base_de_datos/sistema_iam.db	Base de datos del historial
TAMANO_MAXIMO_CARGA_MB	20	Tamaño máximo de

Variable	Valor por defecto	Uso
		archivo
MODO_COMPARTIR	false	Escuchar en la red local para demostraciones

Anexo C. Reproducir los experimentos

Todos los resultados del informe se pueden repetir con los scripts del proyecto. El entrenamiento requiere una tarjeta gráfica con CUDA; el resto funciona en un procesador común, aunque algunas evaluaciones tardan varias horas.

Tabla 53. *Scripts para reproducir los experimentos.*

Paso	Comando	Resultado
Explorar PTB-XL	python scripts/explorar_dataset_ptbxl.py	Estadísticas de la base
Preprocesar	python scripts/preprocesar_dataset_ptbxl.py --frecuencia 100	Señales listas para entrenar
Entrenar el modelo digital	python scripts/entrenar_resnet1d.py --variante estandar --epocas 30 --paciencia 8 --aumento-datos	Modelo de la época 12
Evaluar en prueba	python scripts/evaluar_modelo.py	Métricas, curvas e intervalos
Entrenar impresos, etapa 1	entrenar_resnet1d.py --formato-impreso --pesos-iniciales <modelo digital> --lr 3e-4	Modelo para la vista 3 × 4
Generar hojas digitalizadas	python scripts/generar_digitalizados.py --conjunto entrenamiento --registros 6000	Señales digitalizadas de entrenamiento
Entrenar impresos, etapa 2	entrenar_resnet1d.py --formato-impreso --digitalizados 0.7 --lr 1e-4	Modelo para PDF y PNG
Evaluar la digitalización	python scripts/evaluar_digitalizacion.py --conjunto prueba	Resultados por tipo de documento
Ajustar con hojas reales	python scripts/ajustar_hojas_reales.py	Modelo para JPG y métricas fuera de pliegue
Validación externa	python scripts/validar_bases_externas.py	Métricas en SPH, PTB y Georgia
Estimación de frecuencia	python scripts/evaluar_estimacion_frecuencia.py	Aciertos del estimador
Demostraciones y vista de la red	exportar_demos_estaticas.py y exportar_red_neuronal.py	Archivos para la demostración pública

Anexo D. Estructura del proyecto

```
Residencia2026/
├── backend/aplicacion/     API: rutas, servicios, esquemas y lectura de archivos
├── frontend/               Interfaz web y casos de demostración
├── modelo_ia/
│   ├── arquitectura/       Red ResNet1D y bloque residual
│   ├── preprocesamiento/   Filtrado, normalización y estimación de frecuencia
│   ├── entrenamiento/      Conjunto de datos, aumento y ciclo de entrenamiento
│   ├── evaluacion/         Punto de corte, intervalos de confianza y gráficas
│   ├── explicabilidad/     Grad-CAM y zonas Q, ST y T
│   ├── digitalizacion/     De PDF o foto a señal de 12 derivaciones
│   └── puntos_control/     Modelos entrenados (no se suben al repositorio)
├── dataset/                Datos crudos y procesados, metadatos y ejemplos
├── base_de_datos/          Esquema SQL del historial
├── documentos/             Resultados, figuras e informe
└── scripts/                Preparar, entrenar, evaluar y levantar la web
```

Anexo E. Interfaz de programación (API)

Tabla 54. *Rutas de la API.*

Método y ruta	Descripción
GET /salud	Indica si el servidor está activo
POST /api/analisis	Recibe uno o dos archivos (campo archivos) y, opcionalmente, la frecuencia de muestreo; devuelve el resultado del análisis y lo guarda en el historial
GET /api/historial	Devuelve los análisis más recientes
GET /api/visualizacion/demo	Devuelve un caso de ejemplo de PTB-XL con su diagnóstico de referencia
GET /docs	Documentación interactiva generada por FastAPI

La siguiente es la respuesta real del sistema al analizar el archivo de ejemplo ejemplo_con_iam.csv, sin indicar la frecuencia de muestreo. Se recortó el campo de visualización, que contiene las señales y el mapa completo.


```
{
  "nombre_archivo": "ejemplo_con_iam.csv",
  "tipo_entrada": "senal",
  "etiqueta": "iam_detectado",
  "probabilidad_iam": 0.5022,
  "confianza": 0.5022,
  "mensaje": "Patrones compatibles con IAM. Zonas resaltadas por Grad-CAM:
             isquemia (onda T), necrosis (onda Q). Resultado de apoyo;
             debe confirmarlo un médico.",
  "mapa_explicabilidad_disponible": true,
  "umbral_decision": 0.3204,
  "frecuencia_original": 100.0,
  "origen_frecuencia": "estimada",
  "duracion_original_segundos": 10.0,
  "frecuencia_cardiaca_lpm": 61.0,
  "advertencias": [],
  "digitalizacion": null,
  "visualizacion": { "...": "señales, mapa Grad-CAM y regiones" }
}
```


Tabla 55. *Campos de la respuesta del análisis.*

Campo	Significado
nombre_archivo	Nombre del archivo o archivos analizados
tipo_entrada	senal o documento_impreso
etiqueta	iam_detectado o sin_iam
probabilidad_iam	Probabilidad de infarto calculada por el modelo, de 0 a 1
confianza	Probabilidad de la clase elegida
mensaje	Resumen en texto con las zonas resaltadas y el aviso clínico
umbral_decision	Punto de corte aplicado (0.3204, 0.3623 o 0.9494)
frecuencia_original y origen_frecuencia	Frecuencia del archivo y de dónde se obtuvo: cabecera, declarada, columna_tiempo, estimada o papel
duracion_original_segundos	Duración de la señal recibida
frecuencia_cardiaca_lpm	Frecuencia cardiaca aproximada, en latidos por minuto
advertencias	Avisos sobre la frecuencia, la duración o la digitalización
digitalizacion	Solo en hojas impresas: cobertura del trazo, concordancia de la tira de

Campo	Significado
	ritmo, derivaciones de la tira, corrección de perspectiva, ángulo y píxeles por milímetro
visualizacion	Señales preprocesadas, mapa Grad-CAM, regiones destacadas e importancia por zona

Anexo F. Registro de decisiones técnicas

Durante el proyecto tomamos muchas decisiones que no son obvias al leer el código. Las reunimos aquí, con la razón de cada una, para que quien continúe el trabajo no tenga que redescubrirlas.

Tabla 56. *Decisiones técnicas principales y su justificación.*

Decisión	Alternativa descartada	Razón
Trabajar a 100 Hz	500 Hz	Mismo desempeño reportado en la literatura para PTB-XL, cinco veces menos datos y entrenamiento más rápido
Tarea binaria: infarto frente a todo lo demás	Infarto frente a solo normales	En la práctica el sistema debe distinguir el infarto de cualquier otro trazo, no solo de un corazón sano
No descartar registros con ruido	Eliminar registros con anotaciones de calidad	Los trazos reales también tienen ruido; el filtrado y el aumento de datos lo manejan
Respetar los pliegues oficiales de PTB-XL	Partición aleatoria	Evita que un mismo paciente aparezca en entrenamiento y prueba, y permite comparar con otros trabajos
Tomar los primeros 10 s y rellenar con ceros	Recortar el tramo central	Mismo tratamiento para archivos largos y cortos, sin depender de dónde está el latido
Corte con sensibilidad mínima de 0.85	Corte de 0.5 o índice de Youden	Prioriza no dejar pasar infartos, que es el error más grave en una herramienta de apoyo
Conservar el modelo de la época 12	Modelos de los experimentos de continuación	La mejora era de dos milésimas, dentro del error de medición, y cambiar después de ver la prueba habría sesgado los resultados
Estimar la frecuencia de muestreo por la forma del latido	Pedir siempre la frecuencia al usuario	Muchos usuarios no la conocen; el estimador acierta en 95.6 % de los casos y avisa cuando duda
Digitalizador propio basado en la cuadrícula	Servicios externos de digitalización	Funciona sin internet, no envía datos de pacientes fuera del equipo y se puede medir con hojas sintéticas
Identificar la derivación de la tira de ritmo	Suponer siempre la derivación II	En las hojas reales de Pakistán la tira era otra derivación en casi una de cada cuatro hojas
Modelo de impresos en dos etapas	Usar el modelo digital con hojas impresas	El modelo digital perdía desempeño con tres cuartas partes de cada derivación vacías y con los defectos del digitalizador
Validación cruzada de cinco pliegues con hojas reales	Una sola partición de entrenamiento y prueba	Con 523 hojas, una sola partición daría cifras muy inestables
Elegir el modelo de impresos por extensión de archivo	Un solo modelo para todas las hojas	El modelo de hojas reales perdía mucho con hojas de otro estilo y el anterior era peor con fotos reales
SQLite para el historial	PostgreSQL	Suficiente para un prototipo de un solo usuario; el esquema es compatible con PostgreSQL
Interfaz en HTML, CSS y JavaScript sin marcos de trabajo	React u otro marco	Menos dependencias y posibilidad de publicar la demostración como página estática

Anexo G. Resultados detallados de la digitalización

Esta tabla complementa la sección 3.18.2 con los conteos de aciertos y errores de cada tipo de documento, tanto con el modelo de la etapa 2 como con el modelo de la etapa 1 (sin ajuste con hojas digitalizadas). Cada tipo de documento contiene los mismos 500 electrocardiogramas de prueba, de los cuales 114 tienen infarto; las hojas que no se pudieron digitalizar no se cuentan.

Tabla 57. *Conteos por tipo de documento con el modelo de la etapa 2 (corte 0.3623) y el de la etapa 1 (corte 0.4303).*

Tipo de documento	Modelo	VP	FN	FP	VN	Sensibilidad	Especificidad
PDF del equipo	Etapa 2	105	9	75	310	0.921	0.805
PDF del equipo	Etapa 1	107	7	82	303	0.939	0.787
Imagen limpia	Etapa 2	106	8	76	309	0.930	0.803
Imagen limpia	Etapa 1	106	8	84	301	0.930	0.782
Escaneo	Etapa 2	104	10	74	311	0.912	0.808
Escaneo	Etapa 1	105	9	88	297	0.921	0.771
Foto con celular	Etapa 2	102	8	84	295	0.927	0.778
Foto con celular	Etapa 1	104	6	103	276	0.946	0.728
Todos	Etapa 2	417	35	309	1 225	0.923	0.799
Todos	Etapa 1	422	30	357	1 177	0.934	0.767

La comparación muestra el intercambio de forma concreta. En los cuatro tipos de documento juntos, el modelo de la etapa 2 deja pasar 5 infartos más que el de la etapa 1 (35 frente a 30), pero genera 48 falsas alarmas menos (309 frente a 357). En las fotos la diferencia es mayor: 19 falsas alarmas menos a cambio de 2 infartos más sin detectar. Para una herramienta que se usaría como segunda lectura, consideramos que ese intercambio es favorable, sobre todo porque la sensibilidad del modelo de la etapa 2 sigue por encima de 0.91 en todos los casos.